

Luščenje modelskih parametrov in razdelčni modeli

Teodor Jovanovski

28252048

11. november 2025

Kazalo

1	Uvod	3
2	Farmakološki odziv in Michaelis-Menten kinetika	4
2.1	Modeli in statistična metodologija	4
2.2	Rezultati in primerjava pristopov	5
2.3	Diskusija in zaključek	6
3	Analiza farmakokinetičnih podatkov z razdelčnimi modeli	7
3.1	Uvod v problem	7
3.2	Testirani modeli in statistična metodologija	7
3.3	Rezultati in izbira optimalnega modela	8
3.4	Statistična validacija in porazdelitev ostankov	10
3.5	Zaključek analize	10
4	Kalibracija magnetnega spektrometra	11
4.1	Modeli in statistična metodologija	11
4.2	Rezultati in izbira osnovnega modela	12
4.3	Prečno preverjanje in robustnost modelov	13
4.4	Zaključek analize	14
5	Zaključek	15

1 Uvod

V tej domači nalogi obravnavam enega izmed temeljnih procesov v eksperimentalni znanosti: luščenje modelskih parametrov in izbiro optimalnega modela. Osrednje vodilo pri vseh nalogah je bil **princip varčnosti**, ki narekuje izbiro najpreprostejšega modela, ki še vedno zadovoljivo opiše podatke znotraj merilnih napak. Ta princip nas sili v iskanje krhkega ravnovesja med preveliko poenostavitvijo, ki spregleda ključno fiziko (*underfitting*), in prekomerno kompleksnostjo, ki vodi v prilagajanje šumu in slabo napovedno moč (*overfitting*).

Skozi tri različne probleme sem se soočil s ključnimi izzivi modelske analize:

1. **Farmakološki odziv:** Na primeru Michaelis-Menten kinetike sem raziskoval, kdaj je **upravičeno povečati kompleksnost modela**. Z neposredno primerjavo osnovnega in razširjenega Hillovega modela sem s pomočjo statističnega kriterija χ^2 kvantitativno odgovoril na vprašanje, ali podatki podpirajo kompleksnejši mehanizem kooperativne vezave.
2. **Razdelčni modeli v farmakokinetiki:** Analiza kliničnih podatkov je služila za primerjavo več fizikalno utemeljenih modelov. Z uporabo reduciranega hi-kvadrata in F-testa sem sistematično ocenil, ali je za opis procesa izločanja snovi potrebna enorazdelčna, dvorazdelčna ali celo dvorazdelčna struktura z ozadjem, s čimer sem neposredno preizkusil meje principa varčnosti.
3. **Kalibracija magnetnega spektrometra:** Ta naloga je predstavljala nasproten izziv: kako **smiselno zmanjšati kompleksnost modela**, ki je preveč zapleten in numerično nestabilen. Soočen s problemom prekomerne parametrizacije sem uporabil močno orodje, **razcep na singularne vrednosti (SVD)**, da sem iz splošnega polinomskega modela izluščil statistično značilne komponente in našel numerično stabilen in varčen model, katerega napovedno moč sem preveril s prečnim preverjanjem.

Za numerično analizo, prilagajanje modelov in vizualizacijo sem v vseh nalogah uporabil programski jezik Python z znanstvenimi knjižnicami NumPy, SciPy in Matplotlib.

2 Farmakološki odziv in Michaelis-Menten kinetika

V prvem delu naloge sem se osredotočil na analizo farmakoloških podatkov, ki opisujejo odziv biološkega tkiva na različne koncentracije reagenta. Cilj je bil kvantitativno ovrednotiti in primerjati več pristopov za določanje parametrov modela ter ugotoviti, kateri teoretični model najustrezneje pojasni opazovane pojave. Ključno vprašanje je bilo, ali podatki statistično upravičujejo uvedbo kompleksnejšega modela, ki opisuje kooperativnost vezave.

2.1 Modeli in statistična metodologija

Za določitev parametrov, ki najbolje opišejo farmakološki odziv, sem uporabil in primerjal tri različne pristope, ki temeljijo na metodi najmanjših kvadratov.

Pristop 1: Linearizacija osnovnega modela

Osnovni Michaelis-Menten model predpostavlja neodvisno vezavo reagenta in je opisan z enačbo:

$$y(x; y_0, a) = \frac{y_0 x}{a + x} \quad (1)$$

Model je mogoče z Lineweaver-Burkovo transformacijo prevesti v linearno obliko $Y = C_2 X + C_1$, kjer so nove spremenljivke $Y = 1/y$ in $X = 1/x$, novi parametri pa $C_1 = 1/y_0$ in $C_2 = a/y_0$. Ključna pomanjkljivost tega pristopa je nelinearna transformacija merilnih napak. Če je bila napaka meritve odziva σ_y konstantna, napako transformirane količine σ_Y dobimo z uporabo formule za propagacijo napak:

$$\sigma_Y \approx \left| \frac{d(1/y)}{dy} \right| \sigma_y = \frac{\sigma_y}{y^2} \quad (2)$$

To pomeni, da imajo meritve z majhnim odzivom y po transformaciji izjemno veliko napako. Da bi dobil smiselne rezultate, sem zato izvedel **uteženo linearno prilagajanje** na transformiranih podatkih, kjer je bila utež vsake točke sorazmerna z $1/\sigma_Y^2$.

Pristop 2: Neposredno nelinearno prilagajanje osnovnega modela

Zaradi problematične transformacije napak pri linearizaciji je bolj robusten pristop neposredno prilagajanje originalne, nelinearne enačbe (1). Ta metoda deluje neposredno na originalnih podatkih in pravilno upošteva podane merilne napake σ_y .

Pristop 3: Neposredno nelinearno prilagajanje Hillovega modela

Tretji, najkompleksnejši pristop, uporablja razširjeni Hillov model, ki vpelje dodaten parameter, Hillov koeficient p , ki opisuje kooperativnost vezave:

$$y(x; y_0, a, p) = \frac{y_0 x^p}{a^p + x^p} \quad (3)$$

Tega modela ni mogoče enostavno linearizirati, zato je bila uporaba neposrednega nelinearnega prilagajanja edina ustrezna.

Metodologija prilagajanja

Za nelinearni pristop (2 in 3) sem uporabil metodo najmanjših kvadratov, ki temelji na minimizaciji funkcionala hi-kvadrat (χ^2), definiranega kot:

$$\chi^2(\mathbf{a}) = \sum_{i=1}^N \left(\frac{y_i - y(x_i, \mathbf{a})}{\sigma_i} \right)^2 \quad (4)$$


Za numerično minimizacijo sem uporabil Levenberg-Marquardtov algoritem. Končno primerjavo kakovosti prilagoditve med vsemi tremi pristopi sem izvedel z **reduciranim hi-kvadratom**, $\chi^2_\nu = \chi^2/(N - m)$. Za poglobljeno analizo negotovosti najboljšega modela sem izračunal tudi 95% pas zaupanja z uporabo celotne kovariančne matrike parametrov.

2.2 Rezultati in primerjava pristopov


Rezultati vseh treh pristopov so zbrani v tabeli 1 in grafično prikazani na slikah 1 in 2.

Pristop	y_0 [enote]	a [enote]	χ^2_ν
Linearizacija	104.68 ± 2.48	21.19 ± 1.86	4.35
Osnovni (nelinearni)	106.32 ± 2.48	24.76 ± 2.17	3.67
Hillov (nelinearni)	99.61 ± 2.58	19.77 ± 1.67	1.87

Tabela 1: Primerjava rezultatov za tri različne pristope. Hillov model z dodatnim parametrom $p = 1.36 \pm 0.13$ se izkaže za statistično najboljšega.



Slika 1: Primerjava prilagoditev vseh treh pristopov. Hillov model (modra polna črta) se vidno najboljše prilega podatkom. Modro senčeno območje predstavlja 95% pas zaupanja za Hillov model.



Slika 2: Primerjava absolutnih normaliziranih ostankov za vse tri pristope. Hillov model ima sistematično najmanjša odstopanja od meritev.

2.3 Diskusija in zaključek

Analiza rezultatov pokaže jasno hierarhijo pristopov.

1. **Linearizacija vs. Nelinearni fit:** Primerjava parametrov in vrednosti χ^2_ν (4.35 vs. 3.67) med lineariziranim in neposrednim nelinearnim fitom osnovnega modela kvantitativno potrди teoretične pomisleke. Je pa zanimivo, da je lineariziran model bolj natančen od nelinearnega po določeni točki.
2. **Osnovni model vs. Hillov model:** Primerjava najboljšega osnovnega modela ($\chi^2_\nu = 3.67$) s Hillovim modelom ($\chi^2_\nu = 1.87$) kaže, da dodatek parametra p bistveno izboljša kakovost prilagoditve. Vrednost χ^2_ν se prepolovi in se močno približa idealni vrednosti 1. Tudi graf ostankov (slika 2) jasno pokaže, da ima Hillov model sistematično najmanjša odstopanja.

Končni sklep je, da je **razširjeni Hillov model, določen z neposrednim nelinearnim prilagajanjem, nedvomno najboljši pristop.**

3 Analiza farmakokinetičnih podatkov z razdelčnimi modeli

3.1 Uvod v problem

V drugi nalogi sem se lotil analize kliničnih podatkov, ki opisujejo časovni potek koncentracije radioaktivnega sledilca v telesu. Takšni podatki so temelj farmakokinetike in omogočajo sklepanje o mehanizmih absorpcije, porazdelitve, presnove in izločanja snovi.

Pristop je temeljil na hierarhičnem testiranju modelov z naraščajočo kompleksnostjo. Začel sem z najpreprostejšim, enorazdelčnim modelom, in postopoma dodajal nove komponente (ozadje, drugi razdelek), da bi ugotovil, katera stopnja kompleksnosti je nujno potrebna in statistično upravičena za pojasnitev podatkov. Ta postopek omogoča, da na podlagi načela varčnosti pridemo do optimalnega modela, ki nudi najboljše ravnesje med natančnostjo in enostavnostjo.

3.2 Testirani modeli in statistična metodologija

Za opis časovnega upadanja koncentracije sledilca $c(t)$ sem preučil pet tekmovalnih modelov, ki predstavljajo različne fizikalne hipoteze:

1. **Model A: Enorazdelčni model.** Najenostavnejša hipoteza, ki obravnava telo kot en sam, dobro premešan volumen, iz katerega se snov izloča s konstantno relativno hitrostjo (proces prvega reda).

$$c(t) = C_0 e^{-\lambda t} \quad (5)$$

2. **Model B: Enorazdelčni model z ozadjem.** Razširitev modela A, ki upošteva možnost konstantnega ozadja B . To ozadje lahko predstavlja bodisi instrumentalni šum bodisi naravno, endogeno raven podobne snovi v telesu.

$$c(t) = C_0 e^{-\lambda t} + B \quad (6)$$

3. **Model C: Dvorazdelčni model.** Ta model predpostavlja, da je telo sestavljeno iz dveh razdelkov: centralnega (npr. kri), kamor je snov injicirana in iz katerega se izloča, ter periferne (npr. tkiva), med katerima poteka izmenjava. Dinamika je opisana kot vsota dveh eksponentnih funkcij, ki ustrezata hitri fazi porazdelitve in počasnejši fazi končnega izločanja.

$$c(t) = A e^{-\lambda_1 t} + B e^{-\lambda_2 t} \quad (7)$$

4. **Model D: Alternativni model.** Empirični model, ki testira hipotezo, da upadanje morda ne sledi klasičnemu eksponentnemu zakonu, temveč odvisnosti od $\sqrt{t}$.

$$c(t) = C_0 e^{-\lambda \sqrt{t}} \quad (8)$$

5. **Model F: Dvorazdelčni model z ozadjem.** Najkompleksnejši model, ki združuje fizikalno sliko dveh razdelkov z dodatkom konstantnega ozadja.

$$c(t) = A e^{-\lambda_1 t} + B e^{-\lambda_2 t} + C_{\text{ozadje}} \quad (9)$$

Metodologija

Parametre za vsak model sem določil z **uteženo metodo najmanjših kvadratov**, ki minimizira funkcional χ^2 . Ker podatki predstavljajo število sunkov N_i , sem predpostavil Poissonovo statistiko in za uteži uporabil standardno napako $\sigma_i = \sqrt{N_i}$. Za numerično minimizacijo sem uporabil Levenberg-Marquardtov algoritem, implementiran v funkciji `scipy.optimize.curve_fit`.

Kakovost prilagoditve sem primarno ovrednotil z **reduciranim hi-kvadratom** $\chi_\nu^2 = \chi^2/(N-m)$, kjer vrednost $\chi_\nu^2 \approx 1$ kaže na dober model. Za formalno primerjavo ugnezdenih modelov (npr. modela B, ki je razširitev modela A) sem uporabil **F-test**. Ta test kvantitativno oceni, ali je zmanjšanje vrednosti χ^2 dovolj veliko, da statistično upraviči uvedbo dodatnega parametra. Testno statistiko sem izračunal po formuli:

$$F = \frac{(\chi_1^2 - \chi_2^2)/(m_2 - m_1)}{\chi_2^2/(N - m_2)} \quad (10)$$

kjer indeks 1 označuje enostavnejši, indeks 2 pa kompleksnejši model.


3.3 Rezultati in izbira optimalnega modela

Rezultati prilagajanja vseh modelov so zbrani v tabeli 2. Hierarhija modelov glede na kakovost prilagoditve je očitna: vsak dodaten parameter, ki je fizikalno smiseln, prinese bistveno izboljšanje.

Model	Št. parametrov (m)	Reduciran χ_ν^2
A: Enorazdelčni	2	156.10
D: Alternativni ($e^{-\lambda\sqrt{t}}$)	2	13.82
B: Enorazdelčni z ozadjem	3	20.85
C: Dvorazdelčni	4	3.02
F: Dvorazdelčni z ozadjem	5	1.74


Tabela 2: Končna primerjava kakovosti prilagoditve za vse preučevane modele. Dvorazdelčni model z ozadjem (F) se izkaže za statistično najboljšega.

Na sliki 3 so prikazane krivulje za najslabši model (A), zanimivo alternativo (D) in končni zmagovalni model (F). Že na logaritemski skali je vidno, da enostaven eksponentni razpad (model A) ne more slediti podatkom, medtem ko se model F prilega skoraj popolno.



Slika 3: Primerjava prilagoditev enorazdelčnega (A), alternativnega (D) in zmagovalnega dvo-razdelčnega modela z ozadjem (F) na merilne podatke.

Graf relativnih odstopanj (slika 4) omogoča še natančnejši vpogled. Jasno prikazuje, kako vsak korak v kompleksnosti (od A do B, od C do F) zmanjša sistematična odstopanja in jih približa naključnemu šumu. Model F ima odstopanja, ki so večinoma znotraj $\pm 5\%$, kar je izjemen rezultat.




Slika 4: Relativna odstopanja različnih modelov od meritev. Model F (vijolična polna črta) ima daleč najmanjša odstopanja, ki so tudi najbolj naključno porazdeljena.

3.4 Statistična validacija in porazdelitev ostankov

Za potrditev sklepov sem izvedel dva ključna F-testa. Prvi, med modeloma B in A, je z vrednostjo $F \approx 169.6$ potrdil, da je dodatek ozadja nujen. Drugi, še pomembnejši test med modeloma F in C, pa je z vrednostjo $F \approx 18.8$ (daleč nad kritično vrednostjo $F_{krit} \approx 4.28$) dokazal, da je tudi dodatek ozadja k dvorazdelčnemu modelu statistično značilen.

Končni dokaz superiornosti modela F nudi analiza porazdelitve ostankov na sliki 5. Medtem ko so ostanki za model A široko in nesimetrično porazdeljeni, se porazdelitev ostankov za model F veliko bolje prilega idealni Gaussovi krivulji. To potrjuje, da model F ne le minimizira χ^2 , ampak tudi zadošča osnovnim statističnim predpostavkam metode.



Slika 5: Primerjava histogramov normaliziranih ostankov za najslabši (A) in najboljši (F) model. Porazdelitev za model F se veliko bolje ujema z idealno normalno porazdelitvijo $N(0,1)$.

3.5 Zaključek analize

Celovita statistična analiza je pokazala, da je **dvorazdelčni model z aditivno konstanto za ozadje (model F) optimalna izbira**. Podatki so dovolj natančni, da ne podpirajo le dveh različnih časovnih skal izločanja (hitre in počasne komponente), temveč tudi obstoj konstantnega ozadja.

4 Kalibracija magnetnega spektrometra

V zadnji nalogi sem se lotil empiričnega kalibracijskega modela za magnetni spektrometer. Cilj je bil iz izmerjenih podatkov v goriščni ravnini, položaja (x_{fp}) in kota (θ_{fp}), rekonstruirati sipalni kot delca na tarči (θ_{tg}). Ker natančna fizikalna enačba preslikave ni znana, sem uporabil polinomske modele. Ključna naloga je bila zgraditi **varčen model**, ki vsebuje le statistično značilne člene in se tako izogne prekomernemu prilagajanju (*overfitting*) in numerični nestabilnosti.

4.1 Modeli in statistična metodologija

Definicija modelov

Osnova za analizo je bil splošen polinomski model drugega reda s šestimi parametri ($M = 6$), ki je linearen v iskanih koeficientih a_j . V enačbah sem za večjo preglednost uporabil okrajšavi $x \equiv x_{fp}$ in $\theta \equiv \theta_{fp}$:

$$P_6(x, \theta) = a_0 + a_1x + a_2\theta + a_3x^2 + a_4\theta^2 + a_5x\theta \quad (11)$$

Za potrebe poglobljene analize robustnosti in preverjanja, ali dodatna kompleksnost prinese korist, sem ta osnovni model razširil z najpreprostejšimi kubičnimi členi in tako ustvaril serijo progresivno kompleksnejših modelov:

- **Model s 7 parametri** ($M = 7$): K osnovnemu modelu je dodan kubični člen položaja.

$$P_7(x, \theta) = P_6(x, \theta) + a_6x^3 \quad (12)$$

- **Model z 8 parametri** ($M = 8$): K prejšnjemu modelu je dodan še kubični člen kota.

$$P_8(x, \theta) = P_7(x, \theta) + a_7\theta^3 \quad (13)$$

- **Model z 9 parametri** ($M = 9$): Dopolnjen še z enim od mešanih kubičnih členov.

$$P_9(x, \theta) = P_8(x, \theta) + a_8x^2\theta \quad (14)$$

Ti bolj zapleteni modeli so bili uporabljeni izključno v testu robustnosti, da bi kvantitativno ocenili učinek prekomernega prilagajanja.

Statistična metodologija

Sistem enačb za vseh $N \approx 12000$ meritev sem za vsak model zapisal v matrični obliki $A \cdot \mathbf{a} = \mathbf{b}$. Zaradi visoke verjetnosti kolinearnosti med polinomskimi členi (npr. med x in x^2) sem se namesto klasične metode normalnih enačb odločil za numerično bistveno bolj robusten pristop z **razcepom na singularne vrednosti (SVD)**: $A = U W V^T$.

Ta metoda omogoča dvoje:

1. **Stabilno reševanje sistema:** Tudi v primeru slabe pogojenosti matrike A SVD vrne zanesljivo rešitev za parametre $\mathbf{a}$.


2. **Gradnjo varčnih modelov:** Velikost singularnih vrednosti w_j na diagonali matrike W je merilo za pomembnost posameznih linearnih kombinacij baznih funkcij. Z izključevanjem najmanjših singularnih vrednosti pri reševanju sistema (t.i. *SVD truncation*) sem lahko sistematično zmanjšal efektivno število parametrov modela (k) in preučil, kako to vpliva na kakovost prilagoditve.

Kakovost prilagoditve sem ovrednotil z **reduciranim hi-kvadratom** $\chi_\nu^2 = \chi^2/(N - k)$, pri čemer sem privzel merilno napako $\sigma_{\theta_{tg}} = 0.05$ stopinje. Za končno presojo napovedne moči in robustnosti modelov pa sem uporabil metodo **prečnega preverjanja**, kjer sem modele učil na podmnožici podatkov in njihovo uspešnost (merjeno z RMS napako) preverjal na celotni podatkovni množici.

4.2 Rezultati in izbira osnovnega modela

Analiza singularnih vrednosti matrike A je razkrila ogromno razmerje med največjo in najmanjšo vrednostjo, $w_{max}/w_{min} \approx 2.85 \times 10^4$. To je jasen znak, da je polni model s šestimi parametri preveč zapleten in numerično slabo pogojen.


Primerjava kakovosti prilagoditve za modele z različnim številom efektivnih parametrov k , prikazana na sliki 6, kaže dramatičen padec χ_ν^2 pri prehodu s $k = 4$ na $k = 5$, kar nakazuje na pomembnost pete komponente. Čeprav imajo vsi modeli $\chi_\nu^2 \gg 1$ (kar kaže na podcenjeno merilno napako), sta modela s $k = 5$ (varčni) in $k = 6$ (polni) očitna kandidata za nadaljnjo analizo.



Slika 6: Odvisnost reduciranega χ^2 (rdeče) in velikosti singularnih vrednosti (modro) od števila uporabljenih parametrov k .

4.3 Prečno preverjanje in robustnost modelov

Da bi ugotovil, kateri model ima dobro napovedno moč, sem izvedel analizo prečnega preverjanja. Modele sem “učil” na naraščajočem deležu podatkov (od 20% do 40%) in nato njihovo uspešnost preverjal na **celotni** podatkovni množici. Poleg varčnega ($k = 5$) in polnega ($k = 6$) modela sem v analizo vključil še tri bolj zapletene modele z dodanimi kubičnimi členi ($k = 7, 8, 9$), da bi preveril, ali dodatna kompleksnost prinese kakršnokoli korist. Uspešnost sem meril z RMS (Root Mean Square) napako.



Slika 7: Test robustnosti: RMS napaka različnih modelov v odvisnosti od velikosti učne množice. Prikazana je napovedna moč modela na celotni podatkovni množici.

Rezultati, prikazani na sliki 7, so izjemno zgovorni:

1. **Učna faza:** Pri zelo majhnih učnih množicah ($\sim 20\%$) so kompleksnejši modeli ($k \geq 6$) na videz boljši. To je pričakovano, saj imajo več prostosti za prilagajanje majhnemu, nereprezentativnemu vzorcu. Model $k = 5$ je sprva slabši.
2. **Točka stabilizacije:** Že pri približno 24% podatkov se zgodi preobrat. Napaka varčnega modela ($k = 5$) pade pod napako polnega modela ($k = 6$) in ostane nižja ali primerljiva skozi celotno območje. To nam pove, da se model $k = 6$ pri manjših množicah **prekomerno prilagaja** (overfitting) in ima slabšo zmožnost sploševanja.
3. **Zakon padajočih donosov:** Modeli, kompleksnejši od $k = 6$ (npr. $k = 8$ in $k = 9$), se sicer hitro naučijo in dosežejo najnižjo RMS napako, vendar se njihova prednost pred modelom $k = 6$ ne povečuje bistveno po približno 30% podatkov. Dosegli so plato, kjer dodajanje novih podatkov ne prinese večjega izboljšanja. To kaže, da je meja koristne kompleksnosti dosežena že pri modelu s 6 ali 7 parametri.

4.4 Zaključek analize

Na podlagi celovite analize lahko sklepam, da je **varčni model s $k = 5$ najboljša izbira**. Čeprav polni model ($k = 6$) na celotni podatkovni množici doseže nekoliko nižjo vrednost χ^2_ν , test robustnosti pokaže, da je ta prednost krhka in odvisna od velikosti učne množice. Model $k = 5$ nudi najboljše ravnovesje med natančnostjo in stabilnostjo, saj se izogne prilagajanju na najbolj negotovo komponento v podatkih.

Končna enačba izbranega varčnega modela je:

$$\begin{aligned}\theta_{tg} \approx & -0.00384 \\ & + 0.98571 \cdot x_{fp} \\ & - 0.85035 \cdot \theta_{fp} \\ & - 0.00175 \cdot x_{fp}^2 \\ & - 0.00007 \cdot \theta_{fp}^2 \\ & + 0.00016 \cdot x_{fp}\theta_{fp}\end{aligned}\tag{15}$$

5 Zaključek

Skozi to nalogo sem se ukvarjal s celotnim ciklom modelske analize, od postavitve hipoteze v obliki matematičnega modela do njegove rigorozne statistične validacije in končne izbire.

Analiza vsake naloge je prinesla specifična, a med seboj povezana spoznanja:

- Pri **farmakološkem odzivu** je bilo dokazano, da podatki statistično zavračajo enostaven Michaelis-Menten model in zahtevajo kompleksnejši Hillov model. Opazovani proces najverjetneje vključuje mehanizem **pozitivne kooperativnosti**, ki ga enostavnejši model ne more zajeti.
- Pri **analizi farmakokinetičnih podatkov** se je skozi hierarhično testiranje kot nedvomno najboljši izkazal **dvorazdelčni model z ozadjem**. Ta rezultat poudarja, da so biološki sistemi pogosto preveč kompleksni za najpreprostejše opise. Uspešnost tega modela kaže, da so bili podatki dovolj natančni, da so razkrili obstoj treh ključnih komponent: hitre faze porazdelitve, počasnejše faze izločanja in konstantnega ozadja.
- **Kalibracija spektrometra** je razkrila moč **razcepa na singularne vrednosti (SVD)** pri obravnavi slabo pogojenih, preveč zapletenih problemov. S to metodo sem uspel rešiti problem kolinearnosti v polinomskem modelu. Poglobljena analiza z metodo prečnega preverjanja je pokazala, da je “varčni” model s 5 parametri ne le natančnejši pri majhnih učnih množicah, temveč tudi bolj robusten od polnega 6-parametrskega modela. Morda najpomembnejše spoznanje te naloge pa je bilo, da je analiza χ^2 razkrila močno podcenjeno merilno napako, kar kaže, da je modelska analiza tudi močno diagnostično orodje za vrednotenje kakovosti samih meritev.

Skupno je ta naloga pokazala, da je princip varčnosti praktičen, s statistiko podprt proces iskanja optimalnega ravnovesja. Naučil sem se, kako prepoznati, kdaj je model preveč enostaven (nalogi 1 in 2) in kdaj je preveč zapleten (nalogi 3).