

Stohastični populacijski modeli

Teodor Jovanovski

28252048

3. december 2025

Kazalo

1	Uvod	3
2	Preprost model izumrtja	4
2.1	Metodologija in osnovna statistika	4
2.2	Validacija numerične metode	4
2.3	Vpliv variance: Primerjava modelov	6
2.4	Analitični pristop	6
3	Dinamika sistema Plenilec-Plen	8
3.1	Stohastični Lotka-Volterra model	8
3.2	Validacija modela in analiza konvergence	9
3.3	Stabilnost ekosistema in Arrheniusovo skaliranje	10
4	Epidemija in izguba imunosti	13
4.1	SIRS Model	13
4.2	Vpliv velikosti populacije	14
5	Zaključek	16

1 Uvod

V fiziki in biologiji dinamične sisteme pogosto opisujemo z determinističnimi diferencialnimi enačbami (npr. $\frac{dN}{dt} = -\beta N$), ki predpostavljajo zvezne spremenljivke in zanemarjajo fluktuacije. Tak opis je ustrezen v termodinamični limiti (ko gre $N \rightarrow \infty$), postane pa pomanjkljiv pri obravnavi majhnih populacij, kjer sta diskretna narava osebkov ($N \in \mathbb{N}$) in intrinzična naključnost dogodkov ključnega pomena.

V tej nalogi sem obravnaval **stohastične populacijske modele**, kjer razvoj sistema ni določen enolično, temveč ga opisujemo z verjetnostnimi porazdelitvami. Osrednji cilj naloge je bil raziskati pojave, ki so izključno posledica stohastike in jih deterministični modeli ne morejo napovedati. Mednje spadajo:

- **Izumrtje v končnem času:** Deterministična populacija asimptotično pada proti ničli, a je nikoli ne doseže, medtem ko stohastična populacija zaradi fluktuacij v končnem času zadene absorpcijsko stanje $N = 0$.
- **Destabilizacija ciklov:** V sistemih plenilec-plen (Lotka-Volterra) stohastični šum uniči stabilne orbite in povzroči propad ekosistema.
- **Vpliv variance:** Pokazali bomo, da dva sistema z enakim povprečnim vedenjem (driftom) doživljata drastično različne usode, če se razlikujeta v intenzivnosti fluktuacij (difuziji).

Za numerično modeliranje sem uporabil metodo časovne diskretizacije s Poissonovimi inkrementi (metoda τ -leaping). Ker gre za aproksimativno metodo, sem poseben poudarek namenil **validaciji in analizi napake**. Implementiral sem eksaktni Gillespiejev algoritem (SSA), ki simulira vsak dogodek posebej, in z njim preveril konvergenco in red natančnosti moje metode.

Poleg osnovne statistike sem nalogo poglobil z analizo **skaliranja stabilnosti**. Zanimalo me je, ali stohastično izumrtje sledi zakonom statistične mehanike (Arrheniusov zakon), kar bi pomenilo, da stabilnost populacij z njihovo velikostjo raste eksponentno. To sem preveril na primerih nelinearnega ekosistema in epidemiološkega modela SIRS.


2 Preprost model izumrtja

Prvi korak je analiza procesa čistega izumrtja (“Pure Death”), kjer populacija pada s hitrostjo βN . V stohastičnem modelu nas zanima porazdelitev časov izumrtja.

2.1 Metodologija in osnovna statistika

Za numerično modeliranje procesa sem uporabil metodo časovne diskretizacije, znano kot τ -leaping. Časovno os razdelimo na intervale Δt , znotraj katerih predpostavimo konstantno hitrost procesa. Število smrti v posameznem koraku ni deterministično, temveč ga generiramo kot naključno spremenljivko iz Poissonove porazdelitve: $\Delta N \sim \text{Poisson}(\beta N(t)\Delta t)$. Ta pristop nam omogoča, da s simulacijo zajamemo naravne fluktuacije, ki so značilne za radioaktivni razpad ali biološko umiranje.

Simulacijo sem ponovil 10.000-krat za majhno ($N_0 = 25$) in veliko ($N_0 = 250$) populacijo, da sem pridobil histogram časov izumrtja (slika 1).




Slika 1: Porazdelitev časov izumrtja. Pri majhnem N (levo) prevladuje stohastični šum, kar vodi do asimetrije. Pri večjem N (desno) postane porazdelitev bolj simetrična in normalna.

2.2 Validacija numerične metode


Točnost metode τ -leaping je kritično odvisna od izbire časovnega koraka Δt . Metoda namreč predpostavlja, da je hitrost procesa znotraj koraka konstantna. Če je Δt prevelik, parameter Poissonove porazdelitve $\lambda = \beta N \Delta t$ naraste, kar lahko vodi do fizikalno nerealističnih skokov, kjer algoritem v enem koraku “ubije” prevelik delež populacije, ne da bi upošteval sprotne zmanjševanje števila osebkov. Kot prikazuje slika 2, to vodi do sistematične napake – pri velikih korakih je izračunani čas izumrtja podcenjen. Za zanesljive rezultate sem ugotovil, da mora veljati pogoj $\beta N \Delta t \ll 1$.

Za rigorozno validacijo sem implementiral **eksaktni Gillespiejev algoritem (SSA)**, ki simulira vsak dogodek posebej in ne vsebuje napake časovne diskretizacije. Rezultate SSA sem uporabil kot referenco za izračun absolutne napake metode s fiksnim korakom. Graf konvergence na sliki 3 prikazuje napako v odvisnosti od Δt na logaritemski skali. Dejstvo, da točke sledijo

premici z naklonom 1, je numerični dokaz, da napaka pada linearno z manjšanjem koraka ($\epsilon \propto \Delta t$). To potrjuje, da je naša metoda prvega reda natančnosti in pri izbranem $\Delta t = 0.01$ daje zanemarljivo napako.



Slika 2: Odvisnost povprečnega časa izumrtja od Δt . Pri velikih korakih metoda odpove in umetno pospeši izumrtje.




Slika 3: Konvergenca metode fiksnega koraka. Ujemanje z referenčnim naklonom 1 (črtkana črta) potrjuje linearno konvergenco k točni Gillespiejevi rešitvi.

2.3 Vpliv variance: Primerjava modelov

Primerjal sem model “Samo smrt” ($\beta = 1$) z modelom “Rojstvo-Smrt” ($\beta_r = 4, \beta_s = 5$). Oba modela sta si deterministično enakovredna, saj imata enako **neto hitrost** upadanja populacije (drift $-\beta$). Razlikujeta pa se v **intenzivnosti fluktuacij** (difuziji), ki je sorazmerna vsoti hitrosti vseh procesov. Pri prvem modelu je difuzija sorazmerna z 1, pri drugem pa z $\beta_r + \beta_s = 9$, kar pomeni, da je drugi sistem 9-krat bolj stohastično aktiven.


Rezultati na sliki 4 prikazujejo posledice te povečane variance. Rdeči histogram (Rojstvo-Smrt) je bistveno širši, njegov vrh pa je premaknjen k **krajšim časom**. To je posledica problema prvega prehoda v prisotnosti absorpcijskega roba ($N = 0$). Zaradi močnejšega “divjanja” populacije je verjetnost, da sistem po naključju zadene ničlo predčasno, bistveno večja, čeprav je povprečni drift enak. Hkrati pa velika varianca omogoča, da redki “srečni” primerki preživijo dlje (zaradi serije rojstev), kar ustvari dolg rep porazdelitve na desni strani.



Slika 4: Vpliv variance na čas izumrtja. Rdeči histogram (večja varianca) je širši in ima modus premaknjen k krajšim časom (hitrejše izumrtje večine), ima pa tudi daljši rep preživelih.

2.4 Analitični pristop

Poleg simulacij sem verjetnostno porazdelitev preveril tudi analitično z izračunom efektivnega odmika $\sigma(t) = \sqrt{\langle N^2 \rangle - \langle N \rangle^2}$, ki meri širino porazdelitve oziroma negotovost stanja sistema. Graf časovnega razvoja $\sigma(t)$ na sliki 5 prikazuje, da negotovost sprva narašča, saj se zaradi stohastične narave smrti populacija razprši (nekateri osebki umrejo hitreje, drugi kasneje). Odmik doseže maksimum, ko je živa približno polovica populacije (največja entropija), nato pa ponovno pade proti ničli, saj sistem sčasoma neizogibno konvergira v edino možno končno stanje ($N = 0$), kjer ni več nikakršne negotovosti o stanju sistema.




Slika 5: Časovni razvoj efektivnega odmika. Negotovost najprej narašča, doseže maksimum, nato pa pada, ko sistem konvergira v absorpcijsko stanje.

3 Dinamika sistema Plenilec-Plen

Tretji del obravnava stohastični Lotka-Volterra model (Zajci in Lisice), ki je nelinearen sistem. Začeli smo v ravnovesnem stanju $Z_0 = 200, L_0 = 50$.


3.1 Stohastični Lotka-Volterra model

Sistem sem modeliral z upoštevanjem šestih neodvisnih stohastičnih procesov: rojstev in naravnih smrti za obe vrsti ter interakcije (lov), ki povezuje obe populaciji. Parametre rodnosti in umrljivosti sem nastavil tako, da deterministični del enačb predvideva stabilno dinamično ravnovesje pri $Z_0 = 200$ zajcih in $L_0 = 50$ lisicah. Na časovnem poteku (slika 6) jasno opazimo oscilacije s karakterističnim faznim zamikom – vrh populacije lisic vedno sledi vrhu populacije zajcev, saj plenilci potrebujejo čas, da se namnožijo ob obilici hrane, in čas, da populacija upade, ko hrane zmanjka.



Slika 6: Časovni potek populacij. Vidna so nihanja s faznim zamikom, značilna za sistem plenilec-plen, vendar so amplitude zaradi stohastike neenakomerne.

Še boljši vpogled v stabilnost sistema nudi fazni portret (slika 7), kjer rišemo trajektorijo v prostoru (Z, L) . Medtem ko deterministični model predvideva zaprte orbite (neskončno kroženje po isti poti z ohranitvijo energije), stohastični šum povzroči, da se amplituda nihanja naključno spreminja. Trajektorija se obnaša kot “difuzija” okoli deterministične orbite. Ker sta osi $Z = 0$ in $L = 0$ absorpcijski stanji, te fluktuacije neizogibno vodijo do točke, kjer se trajektorija dotakne osi, ena populacija izumre in ekosistem se zruši.




Slika 7: Fazni portret (metoda τ -leaping). Začetek je v črni točki. Trajektorija (zelena spirala) se zaradi šuma naključno širi in krči, dokler sistem ne zadene rdečega križca (izumrtje).

3.2 Validacija modela in analiza konvergence


Numerična simulacija nelinearnih sistemov, kot je Lotka-Volterra, je zahtevna, saj se hitrosti procesov (rates) drastično spreminjajo. Ko populacija plenilcev ali plena močno naraste, se dogodki vrstijo zelo hitro, kar zahteva kratek časovni korak. Metoda s fiksnim korakom Δt tu tvega napako: če je korak prevelik v času “eksplozije” populacije, lahko izračunamo fizikalno nesmiselna stanja (npr. negativno populacijo).

Za validacijo sem zato uporabil eksaktni Gillespiejev algoritem (SSA), ki se dinamiki prilagaja naravno – časovni korak τ je naključna spremenljivka, odvisna od trenutne aktivnosti sistema. Fazni portret, generiran z SSA (slika 8), nam razkrije pravo mikroskopsko strukturo procesa: trajektorija ni gladka krivulja, temveč zaporedje ortogonalnih skokov za ± 1 vzdolž osi, kar potrjuje diskretno naravo populacijske dinamike.

Poleg kvalitativne primerjave sem izvedel tudi kvantitativno analizo konvergence (slika 9). Primerjal sem povprečni čas izumrtja pri različnih fiksnih korakih Δt z referenčnim rezultatom SSA. Ugotovil sem, da napaka pada linearno z manjšanjem koraka ($\epsilon \propto \Delta t$), kar pomeni, da je metoda τ -leaping kljub nelinearnosti sistema stabilna in konvergentna, če izberemo dovolj majhen Δt (v mojem primeru 0.001).



Slika 8: Fazni portret z eksaktnim Gillespiejevim algoritmom. Graf jasno prikazuje diskretno naravo skokov v faznem prostoru, kar je bistvena razlika v primerjavi z zveznimi približki.



Slika 9: Konvergenca metode pri modelu Zajci-Lisice. Graf absolutne napake v odvisnosti od Δt potrjuje linearno konvergenco, kar opravičuje uporabo hitrejše metode fiksnega koraka za obsežne statistične analize.

3.3 Stabilnost ekosistema in Arrheniusovo skaliranje

Eno najpomembnejših vprašanj v populacijski dinamiki je dolgoročna stabilnost ekosistema. Medtem ko deterministični model predvideva neskončno obstojnost ciklov, stohastične simulacije


kažejo, da sistem v končnem času vedno propade. Histogram življenjskih dob (slika 10) za populacijo velikosti $N \approx 250$ kaže, da je povprečni čas do izumrtja relativno kratek ($\langle t \rangle \approx 14$). Porazdelitev je asimetrična, kar nakazuje, da večina sistemov propade hitro, redki pa preživijo dlje, če se jim uspe s cikli izogniti “nevarnim območjem” blizu koordinatnih osi.

Za globlje razumevanje stabilnosti sem preveril hipotezo, da se izumrtje v stohastičnem sistemu obnaša kot **prehod delca preko energetske bariere** (Arrheniusov proces). V tej analogiji stabilna orbita predstavlja “dno potencialne jame”, izumrtje pa “pobeg” iz te jame, ki ga omogoči redka, dovolj velika fluktuacija. Teorija velikih deviacij napoveduje, da mora povprečni čas izumrtja $\langle T \rangle$ naraščati eksponentno z velikostjo sistema N :


$$\langle T \rangle \sim e^{S \cdot N} \implies \ln \langle T \rangle \propto N \quad (1)$$

kjer konstanta S predstavlja efektivno “akcijo” oziroma višino bariere.

To hipotezo sem preveril s simulacijo sistemov različnih volumnov, pri čemer sem ohranil enake gostote populacij. Rezultati na sliki 11 kažejo izjemno linearno odvisnost logaritma časa od velikosti populacije. To je ključna ugotovitev naloge: stabilnost ekosistema z večanjem populacije ne raste linearno, ampak **eksponentno**. To pojasnjuje, zakaj so naravni ekosistemi z velikim številom osebkov dolgoročno stabilni, medtem ko majhne, izolirane populacije hitro izumrejo zaradi stohastičnega šuma.



Slika 10: Histogram življenjskih dob sistema. Povprečje $\langle t \rangle \approx 14$ nakazuje na nestabilnost majhnih populacij.



Slika 11: Arrheniusovo skaliranje stabilnosti. Logaritem povprečnega časa izumrtja narašča linearno z velikostjo sistema N .

4 Epidemija in izguba imunosti


Zadnji del naloge obravnava SIRS model, kjer imuni osebkki postopoma izgubljajo imunost (parameter γ) in postajajo spet dovzetni.

4.1 SIRS Model


Ključna nadgradnja osnovnega epidemiološkega modela (SIR) je vpeljava procesa izgube imunosti, kjer ozdravljeni posamezniki (R) s hitrostjo γ ponovno postanejo dovzetni (S). Fizikalno to deluje kot **obnavljanje goriva**: medtem ko v modelu SIR epidemija (“požar”) ugasne, ko zmanjka dovzetnih osebkov, povratna zanka v modelu SIRS omogoča, da se bolezen obdrži.

Na časovnem poteku (slika 12) vidimo posledico tega mehanizma: po začetnem visokem izbruhu število okuženih ne pade na nič, temveč se vzpostavi **kvazi-stacionarno (endemično) stanje**. Sistem oscilira okoli dinamičnega ravnovesja, kjer sta hitrost novih okužb in hitrost pritoka “svežih” dovzetnih osebkov uravnoteženi. Zaradi stohastičnega šuma te oscilacije niso dušene, ampak sistem neprestano fluktuira okoli atraktorja.

Slika 13 prikazuje dramatičen vpliv parametra γ . Pri $\gamma = 0$ (trajna imunost) je čas trajanja epidemije kratek (≈ 5 časovnih enot). Takoj ko γ postane neničeln, sistem doživi fazni prehod: čas do izumrtja bolezni skokovito naraste za več redov velikosti. V tem režimu je popolna eliminacija bolezni ($I = 0$) mogoča le še kot posledica redke, dovolj velike naključne fluktuacije, ki populacijo okuženih “brcne” v ničlo.



Slika 12: Potek SIRS epidemije. Za razliko od modela SIR ($I \rightarrow 0$), se tu vzpostavi dinamično ravnovesje (endemično stanje), kjer število bolnih fluktuira okoli povprečne vrednosti, dokler naključna fluktuacija ne povzroči izumrtja.




Slika 13: Vpliv hitrosti izgubljanja imunosti γ . Graf prikazuje prehod iz kratkotrajne epidemije ($\gamma = 0$) v dolgotrajno endemično stanje ($\gamma > 0$).


4.2 Vpliv velikosti populacije

Velikost populacije N igra odločilno vlogo pri obstojnosti bolezni. V majhnih populacijah je absolutno število okuženih majhno, zato so relativne fluktuacije ($\propto 1/\sqrt{N}$) velike. Lahko se zgodi, da v nekem trenutku vsi okuženi ozdravijo, preden uspejo prenesti bolezen naprej, kar vodi do t.i. **stohastičnega izumrtja**. Kot kaže slika 14, v populacijah z $N < 50$ bolezen izzveni zelo hitro, medtem ko pri večjih populacijah zakon velikih števil stabilizira rezervoar okuženih, kar bistveno podaljša trajanje epidemije.

Za kvantitativno analizo te stabilnosti sem ponovno preveril Arrheniusov zakon. Endemično stanje si lahko predstavljamo kot metastabilno stanje v potencialni jami, stanje brez bolezni ($I = 0$) pa kot globalni minimum. Prehod $I_{endemic} \rightarrow 0$ zahteva redko fluktuacijo preko “energetske bariere”, katere višina je sorazmerna z velikostjo populacije. Rezultat na sliki 15 prikazuje popolno linearno odvisnost $\ln\langle T \rangle \propto N$. To ima pomembno epidemiološko posledico: stabilnost bolezni z velikostjo populacije raste **eksponentno**. V velikih populacijah je torej spontano izumrtje bolezni (brez cepljenja ali karantene) statistično praktično nemogoč dogodek.



Slika 14: Vpliv velikosti populacije na čas trajanja epidemije. Pri majhnih N stohastični šum hitro uniči bolezen, pri večjih pa se vzpostavi stabilno kroženje virusa.



Slika 15: Eksponentna stabilnost epidemije. Linearna zveza na log-linearnem grafu potrjuje Arrheniusov zakon: čas eliminacije bolezni raste eksponentno z velikostjo populacije, kar pojasnjuje trdoživost epidemij v velikih urbanih središčih.

5 Zaključek

V tej nalogi sem skozi simulacijo štirih različnih populacijskih modelov raziskal vlogo stohastičnosti v dinamičnih sistemih. Ključno spoznanje naloge je, da vpeljava verjetnostnih dogodkov ne pomeni le dodajanja “šuma” determinističnim rešitvam, temveč vodi do kvalitativno novih fizikalnih pojavov, ki jih diferencialne enačbe ne morejo napovedati.

Povzamem lahko tri glavne ugotovitve:

1. **Neizogibnost izumrtja in vloga variance:** Pokazal sem, da je stabilnost sistema močno odvisna od intenzivnosti fluktuacij. Primerjava modelov “Samo smrt” in “Rojstvo-Smrt” je razkrila, da povečana varianca (pri enakem povprečnem driftu) drastično poveča verjetnost za zgodnje izumrtje zaradi problema prvega prehoda čez absorpcijski rob.
2. **Numerična strogost in validacija:** Z implementacijo eksaktnega Gillespiejevega algoritma (SSA) sem validiral metodo τ -leaping. Analiza konvergence je potrdila, da je metoda fiksnega koraka stabilna in prvega reda natančnosti ($\mathcal{O}(\Delta t)$), kar upravičuje njeno uporabo za obsežne statistične analize tudi pri nelinearnih sistemih, kot je Lotka-Volterra.
3. **Arrheniusovo skaliranje stabilnosti:** Kot najpomembnejši rezultat poglobljene analize sem za sisteme plenilec-plen in epidemiološke modele potrdil veljavnost Arrheniusovega zakona. Pokazal sem, da povprečni čas do izumrtja (oziroma eliminacije bolezni) z velikostjo populacije N ne raste linearno, temveč **eksponentno** ($\langle T \rangle \propto e^N$). To vzpostavlja povezavo med populacijsko dinamiko in statistično mehaniko, kjer izumrtje obravnavamo kot termični pobeg sistema iz metastabilnega stanja preko energetske bariere.

Stohastični modeli so se tako izkazali kot nepogrešljivo orodje za razumevanje realnih bioloških sistemov, zlasti ko gre za vprašanja stabilnosti majhnih populacij in dolgotrajne obstojnosti endemičnih bolezni.