

Spektralna analiza in filtriranje

Teodor Jovanovski

28252048

9. december 2025

Kazalo

1	Uvod	3
2	Spektralna analiza in okenske funkcije	4
2.1	Problem spektralnega puščanja	4
2.2	Kvantitativna analiza: Ločljivost vs. Dinamični razpon	6
2.3	Limit ločljivosti in Heisenbergovo načelo	7
3	Enodimenzionalna dekonvolucija	9
3.1	Teorija Wienerjevega filtra	9
3.2	Primerjava metod: Wiener proti naivni dekonvoluciji	9
3.3	Izboljšana rekonstrukcija z referenco	12
4	Obdelava slik (2D Dekonvolucija)	14
4.1	Rezultati rekonstrukcije po jedrih	14
4.2	Periodične motnje (NX)	16
4.3	Analiza robnih pogojev	17
4.4	Validacija algoritma in primerjava s knjižnicami	18
5	Zaključek	19

1 Uvod

V eksperimentalni fiziki so merjeni signali redko točna preslikava opazovanega pojava. Pogosto so popačeni zaradi končnega odzivnega časa merilne naprave (kar matematično opišemo s konvolucijo) in neizogibne prisotnosti elektronskega ali okoljskega šuma. Rekonstrukcija izvirnega signala iz takšnih nepopolnih meritev predstavlja enega temeljnih problemov obdelave signalov.

V tej nalogi sem obravnaval metode spektralne analize in filtriranja v frekvenčnem prostoru. Osrednji cilj je bil razumeti, kako pretvorba signala v Fourierov prostor omogoča vpogled v njegovo frekvenčno sestavo ter kako lahko z manipulacijo spektralnih komponent signal očistimo ali rekonstruiramo.

Delo je razdeljeno na tri vsebinske sklope, ki naslavljajo specifične fizikalne probleme:

- **Spektralno puščanje in okenske funkcije:** Analiza, kako končnost časovnega intervala meritve popači spekter (pojav “leakage”) in kako izbira ustrezne okenske funkcije vpliva na kompromis med frekvenčno ločljivostjo in dušenjem stranskih pasov.
- **Optimalno filtriranje (Wienerjev filter):** Primerjava naivne dekonvolucije z Wienerjevim filtrom, ki pri rekonstrukciji upošteva spektralno gostoto šuma in s tem prepreči ojačitev visokofrekvenčnih motenj.
- **Obdelava slik (2D dekonvolucija):** Razširitev metod na dvodimenzionalna polja za izostritev fotografij, pri čemer so ključni izzivi robni pogoji in periodične motnje.

Za numerično analizo sem uporabil hitro Fourierovo transformacijo (FFT). Ker je diskretna transformacija občutljiva na robne pogoje in diskretizacijo, sem poseben poudarek namenil **validaciji rezultatov**. To vključuje kvantitativno primerjavo spektralnih metrik (širina vrha FWHM) in analizo limit ločljivosti, ki so neposredna posledica Heisenbergovega načela nedoločenosti ($\Delta f \cdot \Delta t \geq 1$).

Poleg osnovnih zahtev sem nalogo poglobil z **analizo robnih artefaktov** pri slikah. Raziskal sem, kako različne tehnike obravnave robov (uporaba oken proti razširitvi slike - “padding”) vplivajo na kakovost rekonstrukcije in odpravo “zvonjenja” (ringing artifacts). Prav tako sem pri 1D signalih uporabil metodo referenčnega signala za demonstracijo teoretično optimalne rekonstrukcije v prisotnosti šuma.

2 Spektralna analiza in okenske funkcije

Osnovno orodje za analizo frekvenčne vsebine signalov je diskretna Fourierova transformacija (DFT). Fizikalno relevantna količina je enostranska spektralna gostota moči (PSD - Power Spectral Density), ki nam pove, koliko energije signala je vsebovane v določenem frekvenčnem intervalu. Za diskretni signal dolžine N jo izračunamo kot:

$$P_k = \frac{2}{W} |S_k|^2, \quad \text{kjer je} \quad W = \sum_{j=0}^{N-1} w_j^2 \quad (1)$$

Tu S_k predstavlja koeficiente FFT, w_j pa uteži okenske funkcije. Faktor W je nujen za ohranitev energije (Parsevalov teorem), faktor 2 pa upošteva prispevek negativnih frekvenc pri realnih signalih.


2.1 Problem spektralnega puščanja

Algoritem FFT privzame, da je signal periodičen s periodo $T_{meritve}$. Če se vrednosti na začetku in koncu intervala ne ujemajo ($x(0) \neq x(N-1)$), to FFT interpretira kot nezveznost (skok), ki v frekvenčnem prostoru generira neskončen nabor visokih frekvenc. Posledica je t.i. **spektralno puščanje** (spectral leakage), kjer se energija glavnega vrha "razlije" v stranske pasove, kar namasti spekter in zakrije šibkejša signale.


Da bi to omilili, signal pomnožimo z **okensko funkcijo**, ki na robovih gladko pade proti ničli. Preizkusil sem pet različnih oken:

- **Pravokotno (Rectangular):** Ekvivalentno brez okna.
- **Bartlett (Trikotno), Welch (Parabolno):** Enostavna polinomska okna.
- **Hann, Hamming:** Kosinusna okna, optimizirana za dušenje stranskih vrhov.

Rezultati na sliki 1 prikazujejo vpliv oken na signala `val2.dat` in `val3.dat`. Pri pravokotnem oknu (modra črta) opazimo oster glavni vrh, a visoko raven šuma v ozadju (počasno padanje stranskih vrhov). Uporaba gladkih oken (npr. Hann - oranžna črta) močno zaduši ozadje (za več redov velikosti), vendar za ceno razširitve glavnega vrha.



(a) Spekter signala val2.dat



(b) Spekter signala val3.dat

Slika 1: Vpliv okenskih funkcij na spektralno gostoto moči. Pravokotno okno nudi najboljše ločljivost (najožji vrh), a najslabši dinamični razpon zaradi puščanja. Gladka okna (Hann, Welch) uspešno znižajo prag šuma.


2.2 Kvantitativna analiza: Ločljivost vs. Dinamični razpon

Za natančnejšo oceno kompromisa med ločljivostjo in dušenjem sem izvedel kvantitativno analizo (slika 2). Izračunal sem širino vrha pri polovični višini (**FWHM**) in maksimalno moč vrha.


Rezultati potrjujejo teoretično pričakovanje:

- **Pravokotno okno** ima najmanjši FWHM, torej najboljšo frekvenčno ločljivost.
- **Hannovo in Hammingovo okno** povečata FWHM za približno 40-50%, kar pomeni poslabšanje ločljivosti.
- **Welch** predstavlja dober kompromis med zmerno razširitvijo vrha in dobrim dušenjem.

V fiziki izbira okna torej ni univerzalna, ampak odvisna od problema: če iščemo dve zelo blizu ležeči frekvenci, uporabimo pravokotno okno; če iščemo šibek signal v prisotnosti močnega motilca, uporabimo Hannovo ali Hammingovo okno.



(a) Metrike za val2.dat



(b) Metrike za val3.dat


Slika 2: Kvantitativna primerjava oken. Stolpični diagrami prikazujejo FWHM (širino vrha). Jasno je viden “davek” uporabe oken: za zadušitev stranskih pasov moramo žrtvovati ločljivost (večji FWHM).

2.3 Limit ločljivosti in Heisenbergovo načelo


Dodatno sem raziskal vpliv dolžine časovnega intervala meritve na spekter. Signal sem obrezal na krajše intervale ($N = 512, 128, 64$ točk).

Fizikalno ozadje tega pojava je analogno Heisenbergovemu načelu nedoločenosti: produkt negotovosti v času in frekvenci je omejen navzdol ($\Delta f \cdot \Delta t \gtrsim 1$). Če skrajšamo čas meritve (Δt), se minimalna razločljiva frekvenčna razlika (Δf) nujno poveča.

To je nazorno vidno na sliki 3 pri signalu `val3.dat`. Pri polni dolžini ($N = 512$, modra črta) jasno ločimo dva ločena vrhova. Ko interval skrajšamo na $N = 64$ (zelena črta), se vrhova zaradi razširitve skoraj zlijeta v eno samo “goro”. Informacija o obstoju dveh frekvenc je izgubljena, kar predstavlja fundamentalno fizikalno limito metode.



(a) Analiza intervalov: val2.dat



(b) Analiza intervalov: val3.dat

Slika 3: Demonstracija limita ločljivosti. Pri signalu val3.dat (spodaj) vidimo, da pri $N = 512$ (modra) obstajata dva ločena vrhova. Pri $N = 64$ (zeleni) se zaradi premajhne časovne dolžine signala vrhova skoraj zlijeta.

3 Enodimenzionalna dekonvolucija

V drugem delu naloge sem obravnaval problem rekonstrukcije izvirnega signala $u(t)$, ki je bil popačen s prenosno funkcijo $r(t)$ in dodatkom šuma $n(t)$. Matematika modela v časovnem prostoru je:

$$c(t) = (u * r)(t) + n(t) \quad (2)$$

kjer je prenosna funkcija podana kot $r(t) = \frac{1}{2\tau} \exp(-|t|/\tau)$ s parametrom $\tau = 16$. Naš cilj je določiti $u(t)$ iz izmerjenega signala $c(t)$.

3.1 Teorija Wienerjevega filtra

S prehodom v frekvenčni prostor s pomočjo Fourierove transformacije konvolucija postane produkt:

$$C(f) = U(f)R(f) + N(f) \quad (3)$$

Najbolj neposredna ("naivna") rešitev bi bila inverzno filtriranje: $U(f) = C(f)/R(f)$. Vendar ta pristop v praksi odpove. Prenosna funkcija $R(f)$ (ki deluje kot nizkoprepustni filter) pri visokih frekvencah pade proti ničli. Ker ima beli šum $N(f)$ konstantno spektralno gostoto, člen $N(f)/R(f)$ pri visokih frekvencah divergira. To pomeni, da naivna dekonvolucija katastrofalno ojača šum.

Rešitev je uporaba **Wienerjevega filtra**, ki minimizira srednjo kvadratno napako med rekonstruiranim in pravim signalom. Filter definiramo kot:


$$\Phi(f) = \frac{|S(f)|^2}{|S(f)|^2 + |N(f)|^2} \quad (4)$$

Rekonstrukcija se nato izvede kot $\tilde{U}(f) = \frac{C(f)}{R(f)} \cdot \Phi(f)$.


3.2 Primerjava metod: Wiener proti naivni dekonvoluciji

Implementiral sem obe metodi. Moč šuma $|N(f)|^2$ sem ocenil iz povprečja spektralne moči pri visokih frekvencah. Spodnji grafi prikazujejo rezultate za vse štiri signale.


Pri `signal0` (brez šuma) in `signal1` (malo šuma) Wienerjev filter deluje odlično. Pri `signal2` in `signal3` (več šuma) se pokaže moč filtra, saj naivna metoda (rdeča črta) popolnoma odpove, medtem ko Wienerjeva rekonstrukcija (modra) uspešno povrne obliko signalov.




Slika 4: Signal 0 (Referenca)



Slika 5: Signal 1 (Nizek šum)



Slika 6: Signal 2 (Srednji šum)




Slika 7: Signal 3 (Visok šum)

3.3 Izboljšana rekonstrukcija z referenco


Standardna implementacija Wienerjevega filtra mora “ugibati” spekter čistega signala $|S(f)|^2$ iz zašumljenih podatkov. To vnaša napake, ki se kažejo kot izguba amplitud pri močnem šumu.

Ker imamo na voljo `signal0.dat`, ki predstavlja čist signal istega tipa, sem uporabil spekter tega signala kot “idealen model” za filtriranje ostalih signalov (`signal1`, `signal2`, `signal3`).


Rezultati na spodnjih slikah kažejo teoretični limit kakovosti rekonstrukcije. Signali so gladki in brez artefaktov, kar je še posebej opazno pri `signal3`, kjer je bil šum prej dominanten.



(a) Ref: Signal 1



(b) Ref: Signal 2



(c) Ref: Signal 3

Slika 8: Idealna rekonstrukcija z uporabo referenčnega spektra (iz signal0). Z uporabo “pravega” modela signala filter natančno loči med signalom in šumom, kar drastično izboljša rezultat.

4 Obdelava slik (2D Dekonvolucija)

Zadnji del naloge razširja koncept filtriranja na dvodimenzionalne signale – digitalne slike. Slika Lene je bila popačena s tremi različnimi konvolucijskimi jedri (kernels) in različnimi stopnjami Gaussovega šuma ($RMS = 0, 4, 8, 16$) ter periodično motnjo.

Matematični model je enak kot v 1D, le da uporabljamo 2D Fourierovo transformacijo (FFT2):

$$G(u, v) = F(u, v)H(u, v) + N(u, v) \quad (5)$$

kjer je G spekter zamegljene slike, F spekter originala in H spekter jedra (OTF - Optical Transfer Function). Za rekonstrukcijo sem uporabil 2D Wienerjev filter:

$$\tilde{F}(u, v) = G(u, v) \cdot \frac{H^*(u, v)}{|H(u, v)|^2 + K} \quad (6)$$


Parameter K predstavlja razmerje med spektralno gostoto šuma in signala ($K \approx S_{nn}/S_{ff}$). Pri slikah brez šuma je $K \rightarrow 0$ (inverzno filtriranje), pri močnem šumu pa K povečamo, da preprečimo ojačitev zrnatosti.

Pomemben tehnični detajl implementacije je bila **normalizacija jedra**. Vsota elementov jedra mora biti enaka 1, sicer se energija (svetlost) slike pri konvoluciji spremeni, kar vodi do pretemnih ali presvetlih rekonstrukcij.


4.1 Rezultati rekonstrukcije po jedrih

Spodaj so prikazani rezultati za vsa tri jedra pri vseh stopnjah šuma.


- **Jedro 1 (Tresenje/Motion Blur):** To je usmerjena motnja. Rekonstrukcija pri $n = 0$ je skoraj popolna. Z večanjem šuma ($n = 16$) postane slika zrnata, vendar so robovi še vedno razpoznavni.
- **Jedro 2 (Razostritev/Defocus):** Izotropna motnja. Wienerjev filter uspešno povrne ostrino (npr. detajli na klobuku), pri visokem šumu pa filter deluje kot glajenje.
- **Jedro 3 (Uklon/Diffraction):** To jedro povzroči mehko zameglitev.



Slika 9: Rekonstrukcija slik, popačenih s tresenjem objektiva (Kernel 1).




Slika 10: Rekonstrukcija slik, popačenih s slabim fokusom (Kernel 2).




Slika 11: Rekonstrukcija slik, popačenih z uklonsko mrežico (Kernel 3).

4.2 Periodične motnje (NX)

Poseben primer so slike s končnico **nx**, ki vsebujejo periodično mrežasto motnjo. Na desni strani grafov je prikazan logaritem spektra moči. Svetle točke (zvezdice), ki niso v centru, predstavljajo frekvence motnje.



Slika 12: Periodična motnja: Jedro 1. V spektru (desno) so jasno vidni vrhovi motnje.



Slika 13: Periodična motnja: Jedro 2.



Slika 14: Periodična motnja: Jedro 3.


4.3 Analiza robnih pogojev

Pri vseh zgornjih rekonstrukcijah (še posebej pri $n = 0$) lahko ob robovih opazimo tanke črte ali "zvonjenje" (ringing). To je posledica dejstva, da FFT predpostavlja periodičnost slike (levi rob se stika z desnim). Ker slika ni periodična, FFT na robu vidi "skok", kar povzroči Gibbsov pojav.

Analiziral sem tri metode reševanja tega problema:

1. **Brez obdelave:** Vidni artefakti ob robovih.
2. **Okenska funkcija (Windowing):** Zatemni robove, kar odpravi artefakte, a izgubimo informacijo na obodu slike.
3. **Razširitev (Padding):** Sliko umetno povečamo s konstantno vrednostjo roba, izvedemo dekonvolucijo in nato obrežemo.

Rezultati na sliki 15 kažejo, da je metoda **Padding** superiorna, saj ohrani celotno sliko in artefakte "odrine" v nevidno območje.




Slika 15: Vpliv robnih pogojev. Metoda 1 (levo) kaže artefakte. Metoda 3 (desno, padding) da najboljši rezultat brez izgube vidnega polja.

4.4 Validacija algoritma in primerjava s knjižnicami

Za potrditev pravilnosti moje numerične implementacije sem rezultate primerjal s knjižnico za obdelavo slik `scikit-image` (funkcija `unsupervised_wiener`). Ta funkcija samodejno oceni razmerje signal-šum (K), medtem ko moja ročna metoda uporablja fizikalno znano vrednost RMS šuma.

Po uporabi operacije `fftshift` za uskladitev koordinatnih sistemov sta obe metodi dali primerljive rezultate (slika 16). Ročna metoda se je izkazala za rahlo superiorno, saj uporablja točno informacijo o količini dodanega šuma (RMS), medtem ko mora knjižnična metoda ta parameter statistično oceniti, kar lahko vodi do pretiranega glajenja ali ohranjanja zrnatosti.



Slika 16: Validacija ročne implementacije v primerjavi s knjižnico `scikit-image`. Leva slika prikazuje rezultat ročne metode (z znanim RMS šuma), srednja slika pa rezultat knjižnice (z avtomatsko oceno parametrov in popravljenimi kvadranti). Desni graf prikazuje razliko med metodama.

5 Zaključek

V nalogi sem uspešno implementiral metode spektralne analize in filtriranja za 1D signale in 2D slike.

Ključne ugotovitve so:

- **Kompromis oken:** Pri spektralni analizi ni “najboljšega” okna; pravokotno okno nudi najboljšo ločljivost, medtem ko gladka okna omogočajo zaznavo šibkih signalov z dušenjem puščanja.
- **Wienerjev filter:** Je nepogrešljiv pri dekonvoluciji v prisotnosti šuma. Naivna metoda (C/R) je numerično nestabilna. Uporaba referenčnega spektra (iz `signal0`) omogoča skoraj popolno rekonstrukcijo, kar kaže na teoretični limit metode.
- **Obdelava slik:** Pri 2D dekonvoluciji je ključna pravilna normalizacija jedra in obravnava robnih pogojev. Metoda razširitve slike (padding) se je izkazala za najučinkovitejšo pri odstranjevanju periodičnih artefaktov, ki nastanejo zaradi narave FFT.