

Optimalno filtriranje (Kalmanov filter)

Teodor Jovanovski

28252048

15. december 2025

Kazalo

1	Uvod	3
2	Naloga 1: Optimalno filtriranje (Kalmanov filter)	4
2.1	Osnovna rekonstrukcija	4
2.2	Validacija in konsistenca filtra	5
2.3	Notranja dinamika algoritma	5
2.4	Prostorska analiza napak in detekcija anomalij	6
2.5	Vzorčenje in geometrijska potujitev (aliasing)	7
3	Naloga 2: Simulacija omejenih senzorjev	10
3.1	Primerjava napak položaja	10
3.2	Analiza odvajanja (Scenarij: Samo GPS)	10
4	Naloga 3: Relativni koordinatni sistem	12
4.1	Primerjava modelov: Poln vs. Poenostavljen	12
4.2	Fizikalna analiza: Kdaj je tenzor pomemben?	13
4.3	Singularnost in Anizotropija	14
5	Zaključek	16

1 Uvod

V eksperimentalni fiziki in inženirstvu se pogosto srečujemo s problemom določanja točnega stanja dinamičnega sistema na podlagi nepopolnih, posrednih in zašumljenih meritev. Klasičen primer je sledenje objektu (vozilu), kjer senzorji (GPS, merilnik hitrosti, akcelerometer) ne podajajo zvezne in absolutno točne informacije, temveč diskretne vzorce, obremenjene s stohastičnim šumom.

V tej nalogi sem obravnaval uporabo Kalmanovega filtra za rekonstrukcijo poti in hitrosti vozila. Kalmanov filter je rekurzivni algoritem, ki optimalno (v smislu najmanjših kvadratov napake) združuje napoved fizikalnega modela z novimi meritvami. Njegova moč leži v sprotnem vodenju ocene negotovosti (kovariančna matrika napake), kar mu omogoča, da dinamično prilagaja zaupanje med teoretičnim modelom in empiričnimi podatki.


2 Naloga 1: Optimalno filtriranje (Kalmanov filter)

V prvem delu sem implementiral diskretni Kalmanov filter za rekonstrukcijo poti in hitrosti vozila na podlagi datoteke `kalman_cartesian_data.dat`. Posebnost problema je občasnost meritev: GPS podatki (položaj) so na voljo vsakih 10 korakov, meritve hitrosti pa vsakih 5 korakov. Filter mora v vmesnih korakih izvajati zgolj časovno napoved in s tem premostiti vrzeli.


2.1 Osnovna rekonstrukcija

Slika 1 prikazuje osnovne rezultate delovanja filtra. Na zemljevidu (zgoraj) je razvidno, da filter uspešno gladi šum meritev. Rdeča črtkana črta (ocena filtra) teče gladko skozi oblak meritev (črni križci).

Spodnji graf prikazuje rekonstrukcijo komponent hitrosti v_x in v_y .



(a) Rekonstrukcija trajektorije



(b) Komponente hitrosti s pasovi zaupanja

Slika 1: Osnovni rezultati. Filter uspešno rekonstruira zvezno pot iz diskretnih in občasnih meritev.


2.2 Validacija in konsistenca filtra

Za oceno kakovosti modela sem izvedel test konsistence. Filter je konsistenten, če je razlika med oceno in pravo vrednostjo statistično skladna z oceno lastne negotovosti (P).


Slika 2 (zgoraj) prikazuje časovni potek normalizirane napake:

$$\epsilon_n = \frac{x_{true} - x_{est}}{\sqrt{P_{xx}}} \quad (1)$$

Histogram vseh residualov (spodaj) kaže sprejemljivo ujemanje s teoretično Gaussovo porazdelitvijo $N(0, 1)$, kar potrjuje, da so parametri filtra globalno ustrezni.



(a) Normalizirana napaka (Consistency Check)




(b) Histogram residualov vs. Gaussova porazdelitev

Slika 2: Statistična validacija. Histogram (spodaj) potrjuje normalnost napak, časovna vrsta (zgoraj) pa razkriva odstopanja izven meja 2σ , kar nakazuje na prisotnost nelinearne dinamike.


2.3 Notranja dinamika algoritma

Da bi razumel delovanje filtra “pod pokrovom”, sem analiziral razvoj notranjih matrik (Slika 3).


1. **Dinamika negotovosti (levo zgoraj):** Graf $\sqrt{\text{Tr}(P)}$ kaže značilen “žagast” (sawtooth) vzorec. Negotovost med koraki napovedi narašča (zaradi procesnega šuma Q), ob vsaki meritvi pa strmo pade (vnos informacije). Stabilizacija dna žage dokazuje, da je sistem observabilen.
2. **Kalmanovo ojačanje (desno zgoraj):** Norma matrike K po začetnem prehodnem pojavu konvergira k stabilni vrednosti. Filter doseže stacionarno stanje.
3. **Korelacija (spodaj):** Koeficient korelacije med položajem in hitrostjo $\rho_{x,v}$ narašča v obdobjih brez meritev. To je fizikalno smiselno: če nimamo meritve, se napaka v hitrosti s časom “prelije” v napako položaja ($x = x + v\Delta t$), kar ustvari koplacijo.



(a) Dinamika negotovosti



(b) Konvergenca ojačanja K



(c) Korelacija položaj-hitrost


Slika 3: Analiza notranjih parametrov filtra.

2.4 Prostorska analiza napak in detekcija anomalij


Kje točno model odpove? Za odgovor na to vprašanje sem uporabil **Mahalanobisovo razdaljo** ($d^2 = \mathbf{y}^T S^{-1} \mathbf{y}$), ki deluje kot detektor statističnih anomalij (χ^2 test).

Slika 4 prikazuje časovni potek (zgoraj) in prostorsko porazdelitev (spodaj). Zgornji graf kaže grozde visokih vrednosti (nad rdečo črto). Ko te točke preslikamo na trajektorijo (spodnji

graf, barvna skala), vidimo izrazito korelacijo z geometrijo proge. Rdeče in rumene točke (visoka napaka) so koncentrirane izključno v **ostrih zavojih** (t.i. “kača”).



(a) Mahalanobisova razdalja skozi čas



(b) Prostorska karta napak (Heatmap)

Slika 4: Detekcija anomalij. Prostorska analiza (b) razkriva, da največja odstopanja nastajajo v območjih visoke ukrivljenosti trajektorije, kjer linearni model ne zajame centripetalnih pospeškov.


2.5 Vzorčenje in geometrijska potujitev (aliasing)

Preučil sem vpliv gostote meritev na natančnost filtra. Graf stabilnosti (Slika 5, zgoraj) prikazuje pričakovano naraščanje RMSE napake z večanjem intervala med meritvami GPS. Vendar pa graf razkriva anomalijo: pri intervalu $N = 100$ je napaka **manjša** kot pri intervalu $N = 60$ (20m proti 26m), kar je na videz protislovno (manj podatkov = boljši rezultat?).


Za pojasnitev sem izvedel statistično analizo korelacije med trenutki vzorčenja in dinamiko vozila (Slika 6):

- Pri $N = 60$ je povprečni pospešek vozila v trenutku meritve znašal **0.67 m/s²**.
- Pri $N = 100$ je povprečni pospešek znašal le **0.35 m/s²**.

To prikazuje pojav **geometrijske potujitve (aliasinga)**. Interval $N = 60$ je bil “v fazi” z ovinki proge, tako da je filter prejemal meritve ravno v trenutkih največje dinamike, kjer je model najbolj ranljiv. Interval $N = 100$ pa je statistično pogostejše zadel “ravnine”, kjer je napovedovanje lažje. Slika 5 (spodaj) vizualno potrjuje, da rdeči križci ($N = 60$) pogosto padejo v kritične dele zavojev.




(a) RMSE napaka vs. interval meritev



(b) Geometrija vzorčenja ($N = 60$ vs $N = 100$)

Slika 5: Analiza aliasinga. Anomalija padca napake pri $N = 100$ ni naključna, temveč posledica tega, da redkejšo vzorčenje v tem specifičnem primeru “preskoči” najbolj problematične ovinke.



Slika 6: Statistični dokaz potujitve. Histogrami kažejo, da vzorčenje $N = 60$ (rdeča) sistematično zajema stanja z visokim pospeškom (težja za model), medtem ko $N = 100$ (modra) meri v mirnejših obdobjih.

3 Naloga 2: Simulacija omejenih senzorjev

V drugem delu sem analiziral robustnost filtra v primeru odpovedi posameznih senzorjev. To predstavlja simulacijo realnih scenarijev, kot so vožnja skozi predor (izguba GPS signala) ali okvara merilnika hitrosti.

Simuliral sem dva limitna primera:

1. **Scenarij A (Samo GPS):** Filter prejema le podatke o položaju (x, y) . Hitrost mora “izpeljati” (numerično odvajati) iz sprememb položaja.
2. **Scenarij B (Samo Hitrost):** Filter prejema le podatke o hitrosti (v_x, v_y) . Položaj mora določiti z integracijo hitrosti (inercialna navigacija).


3.1 Primerjava napak položaja

Analiziral sem najprej časovni razvoj absolutne napake položaja:


$$E(t) = \sqrt{(x_{model}(t) - x_{true}(t))^2 + (y_{model}(t) - y_{true}(t))^2} \quad (2)$$

Slika 7 jasno prikazuje fundamentalno razliko med obema načinoma vodenja:

- **Scenarij A (Samo GPS - Modra črta):** Po začetnem skoku je napaka **omejena**. Niha okoli vrednosti, ki jo določa nenatančnost GPS senzorja ($\sigma_{xy} = 25$ m), vendar s časom ne narašča.
- **Scenarij B (Samo Hitrost - Rdeča črta):** Tudi ta napaka je omejena po začetnem naraščanju. Vendar je večja kot napaka modela z GPS-jem.



(a) Absolutno odstopanje od resnice




(b) Rekonstrukcija hitrosti izključno iz GPS

Slika 7: Kvantitativna primerjava. Levo: Relativne napake modelov. Desno: Uspešna ocena hitrosti zgolj iz podatkov o položaju.

3.2 Analiza odvajanja (Scenarij: Samo GPS)

V primeru, ko imamo le GPS, filter deluje kot numerični odvajalnik. To je inherentno ojačevalec šuma (saj diferenciranje poudari visoke frekvence).

Slika 9 prikazuje statistične lastnosti tega procesa. Na faznem portretu, oblak točk okoli izhodišča (0,0) kaže na sklopitev med napako položaja in hitrosti. “Megla” je rahlo asimetrična, kar nakazuje, da napaka v oceni položaja takoj povzroči napako v oceni hitrosti v isti smeri.



Slika 8: Fazni portret napake (Δv vs Δx)

Slika 9: Analiza sistema “Samo GPS”. Fazni portret kaže stohastično porazdelitev napak.

4 Naloga 3: Relativni koordinatni sistem

V zadnjem delu sem obravnaval realističen primer, kjer akcelorometer meri pospeške v telesnem koordinatnem sistemu vozila: a_t (tangencialni, plin/zavora) in a_r (radialni, centripetalni). Za uporabo v Kalmanovem filtru (ki deluje v globalnem kartezičnem sistemu) je potrebna nelinearna transformacija:

$$\mathbf{a}_{global} = B(\mathbf{v}) \cdot \mathbf{a}_{lokal} \quad (3)$$

Problem nastopi, ker je rotacijska matrika B odvisna od trenutne hitrosti vozila. Ker je ocena hitrosti obremenjena s šumom (kovarianca P_{vv}), se ta negotovost prenese v transformacijo pospeška. To zahteva uvedbo dodatnega **tenzorskega člena** v matriki procesnega šuma Q :

$$Q_{korigiran} = Q_{baza} + \text{Tenzorski popravek}(\mathbf{v}, P_{vv}, \mathbf{a}) \quad (4)$$


4.1 Primerjava modelov: Poln vs. Poenostavljen

Primerjal sem delovanje dveh modelov:


- **Poenostavljen model (Moder):** Ignorira negotovost smeri (uporablja fiksno Q).
- **Poln model (Rdeč):** Vključuje tenzorski popravek kovariance.

Slika 10 (zgoraj) prikazuje, da sta trajektoriji na večjem delu poti podobni, vendar se v kritičnih trenutkih razideta. Spodnji graf razkriva, da razlika med modeloma ni zanemarljiva – v določenih trenutkih (npr. okoli $t = 250$ s) odstopanje preseže 250 metrov.

Največja prednost polnega modela se pokaže pri **začetni inicializaciji**. Ker na začetku vozilo stoji (ali se premika počasi), je smer nedefinirana. Poenostavljen model tu “slepo verjame” pospeškomerom in se lahko začne premikati v napačno smer, medtem ko poln model poveča negotovost in počaka na zanesljivejše podatke GPS.



(a) Rekonstrukcija poti (Poln vs. Poenostavljen)




(b) Absolutno odstopanje med modeloma

Slika 10: Vpliv tenzorskega člena. Čeprav sta poti vizualno podobni, graf razlike (desno) kaže velika odstopanja v kritičnih odsekih.


4.2 Fizikalna analiza: Kdaj je tenzor pomemben?

Da bi razumel, kje točno tenzorski popravek igra vlogo, sem analiziral velikost procesnega šuma skozi čas (Slika 11).

- **Dinamični Q (levo):** Rdeča črta kaže špice, kjer tenzorski člen drastično poveča negotovost (tudi do 20-kratnik osnovnega šuma). Te špice se pojavijo na začetku ($t = 0$) in v trenutkih ostrih manevrov.
- **Prostorska karta (desno):** Heatmap prikazuje razmerje med tenzorskim in osnovnim šumom. Svetle (rumene) barve na začetku poti in v “kači” potrjujejo, da je korekcija nujna pri nizkih hitrostih in v zavojih, medtem ko je na ravninah (temno modra) zanemarljiva.



(a) Velikost procesnega šuma (Trace Q)




(b) Prostorska karta vpliva tenzorja

Slika 11: Analiza vpliva. Na desni sliki velikost in barva točk ponazarjata intenzivnost tenzorskega popravka. Jasno je vidno, da korekcija dominira v začetni fazi (spodaj levo) in v ostrih zavojih, medtem ko je na ravnih odsekih zanemarljiva.


4.3 Singularnost in Anizotropija

V okviru analize sem raziskal matematični izvor potrebe po tenzorski korekciji.

1. **Koordinatna singularnost (Slika 12a):** Negotovost smeri vozila (σ_ϕ) je obratno sorazmerna s hitrostjo ($\sigma_\phi \propto 1/v$). Ko $v \rightarrow 0$, negotovost divergira. To pojasni, zakaj brez tenzorskega člena (ki to divergenco kompenzira z večjim Q) filter pri speljevanju postane nestabilen.
2. **Residuali v telesnem sistemu (Slika 12b):** Ko napake projiciramo v sistem vozila, vidimo, da je oblak točk raztegnjen prečno na smer vožnje. To pomeni, da je glavna težava določanje *smeri* vektorja hitrosti, ne njegove *velikosti*.



(a) Singularnost kota pri $v \rightarrow 0$



(b) Residuali v telesnem sistemu

Slika 12: Graf (a) potrjuje teoretično odvisnost $1/v$, ki povzroča težave pri nizkih hitrostih. Graf (b) kaže, da je negotovost primarno transverzalna (smerna).

5 Zaključek

V nalogi sem celovito obravnaval problem optimalnega filtriranja s Kalmanovim filtrom, od osnovne implementacije do napredne analize robnih pogojev in nelinearnosti.

Ključne ugotovitve naloge so:

1. **Robustnost filtra:** Kalmanov filter se je izkazal kot izjemno robustno orodje za fuzijo senzorskih podatkov. Uspešno premošča vrzeli med občasnimi meritvami in gladi stohastični šum.
2. **Omejitve linearnega modela:** Analiza z Mahalanobisovo razdaljo je pokazala, da model konstantnega pospeška sistematično odpove v območjih visoke ukrivljenosti trajektorije (ovinki), kjer centripetalni pospeški niso zanemarljivi.
3. **Geometrijska potujitev (aliasing):** Ena najpomembnejših ugotovitev naloge je, da natančnost filtra ni odvisna le od frekvence vzorčenja, temveč tudi od *faze* vzorčenja. Statistična analiza je dokazala, da je redkejšo vzorčenje ($N = 100$) v tem specifičnem primeru dalo boljši rezultat kot gostejše ($N = 60$), ker se je slednje geometrijsko “ujemalo” z ovinki in sistematično zajemalo meritve v trenutkih največje modelske napake.
4. **Pomen tenzorske korekcije:** Pri uporabi relativnih senzorjev (akcelerator) je upoštevanje negotovosti rotacijske matrike ključno za stabilnost sistema pri nizkih hitrostih. Brez tenzorskega člena v Q matriki sistem ne more pravilno ovrednotiti singularnosti smeri pri $v \approx 0$.