

Nevronske mreže

Teodor Jovanovski

28252048

13. januar 2026



Kazalo

1	Uvod	2
2	Naloga 1: Osnovni model in učenje	3
2.1	Dinamika učenja	3
2.2	Validacija in diagnostika napak	3
2.3	Statistika po števkih in mejni primeri	4
3	Analiza parametrov in robustnost sistema	6
3.1	Vpliv velikosti skrite plasti in hitrosti učenja	6
3.2	Analiza robustnosti na šum	7
3.3	Globoka arhitektura: Primerjava 1 vs. 2 skriti plasti	9
3.4	Odziv na strukturirane neštevilske oblike	10
4	Naloga 2: Inverzni problem (Deep Dream)	12
4.1	Generiranje idealnih vhodov	12
4.2	Morfing in zveznost naučenega prostora	12
5	Zaključek	13

1 Uvod

Nevronske mreže v sodobnem fizikalnem modeliranju predstavljajo orodje za aproksimacijo kompleksnih, nelinearnih funkcij, ki jih je težko opisati z analitičnimi modeli. V osnovi gre za verigo linearnih preslikav, ki so prepletene z nelinearnimi aktivacijskimi funkcijami. Takšna struktura omogoča mreži, da se preko procesa učenja prilagodi poljubni funkcijski zvezi med vhodnimi podatki $\mathbf{y}^0$ in želenim izhodom.

V tej nalogi sem implementiral večplastni perceptron (MLP) s tremi plastmi (vhodna, skrita in izhodna) za klasifikacijo ročno napisanih števk iz standardne zbirke **MNIST**. Vhodni podatki so slike velikosti 28×28 pikslov, ki jih mreža obravnava kot vektorje v 784-dimenzijskem prostoru. Kot aktivacijsko funkcijo sem uporabil hiperbolični tangens:

$$f(x) = \tanh(x), \quad f'(x) = 1 - \tanh^2(x) \quad (1)$$

Zaradi uporabe funkcije $\tanh$ so bili ciljni izhodni vektorji kodirani z vrednostmi -1 (napačna številka) in 1 (pravilna številka). Učenje mreže temelji na **vzvratnem razširjanju napake** (backpropagation), kjer z uporabo gradientnega spusta minimiziramo kvadratni odklon napovedi od referenčnih vrednosti.


Pri reševanju te naloge sem ponovno uporabil programsko okolje **MATLAB**.

2 Naloga 1: Osnovni model in učenje

V prvem sklopu sem skonstruiral mrežo s tremi plastmi (vhodna, ena skrita in izhodna plast). Za skrito plast sem izbral dimenzijo $N_{hidden} = 100$ nevronov. Uteži sem inicializiral po Gaussovi porazdelitvi s priporočeno varianco, hitrost učenja pa nastavil na $\eta = 0.01$.

2.1 Dinamika učenja

Učenje sem izvajal 10 epoh (ciklov). Slika 1 prikazuje rezultate učenja na celotni učni množici 60.000 slik. Opazimo hiter in stabilen upad povprečne kvadratne napake E (zgoraj) ter sočasno rast točnosti klasifikacije (spodaj). Takšna oblika krivulje nakazuje, da je bila izbira parametrov ustrezna in da se sistem ni ujel v lokalne minimume.




Slika 1: Krivulja učenja za osnovni model ($N_{hidden} = 100, \eta = 0.01$). Gladko padanje napake in strma rast točnosti potrjujeta stabilnost algoritma.

2.2 Validacija in diagnostika napak

Po zaključenem učenju sem mrežo preizkusil na testni množici 10.000 slik, ki jih model med procesom optimizacije ni videl.


Za podrobnejšo analizo sem izrisal matriko zamenjav (Slika 2). Zaradi velike razlike med diagonalnimi (pravilni odgovori) in izvendiagonalnimi elementi (napake), sem uporabil logaritemsko barvno lestvico.



Slika 2: Matrika zamenjav (Confusion Matrix) v logaritemski skali. Prevladujoča diagonalna kaže na visoko uspešnost, svetlejše točke izven diagonale pa razkrivajo sistematичne zamenjave (npr. 4 namesto 9).


2.3 Statistika po števkih in mejni primeri

Fizikalno interpretacijo težavnosti problema ponuja Slika 3, ki prikazuje delež napak za vsako posamezno številko. Razvidno je, da sta števki 0 in 1 najlažje prepoznavni (napaka pod $\approx 1\%$).



Slika 3: Delež napak na testni množici po posameznih števkih. Števki 0 in 1 sta zaradi svoje enostavne oblike najlažje prepoznavni, medtem ko je številka 9 najtežja.

Zanimalo me je tudi, v katerih primerih mreža naredi največjo napako (najvišji residual). Slika 4 prikazuje pet takšnih primerov. Vidimo, da so te številke napisane izjemno nenavadno ali pa so pomanjkljive. To potrjuje, da so preostale napake modela posledica inherentne nejasnosti v vhodnih podatkih in ne nujno pomanjkljivosti v arhitekturi mreže.




Slika 4: Analiza petih primerov, kjer je mreža naredila največjo napako. Opazimo, da so številke nečitljive ali dvoumne celo za človeško oko.

3 Analiza parametrov in robustnost sistema

Nevronske mreže so izjemno občutljive na izbiro hiper-parametrov, ki določajo njihovo “anatomijo” in hitrost prilagajanja. V tem razdelku sem sistematično raziskal vpliv števila nevronov, hitrosti učenja ter odziv sistema na motnje in neznane oblike.

3.1 Vpliv velikosti skrite plasti in hitrosti učenja


Na Sliki 5 je prikazan vpliv števila nevronov v skriti plasti N_{hidden} . Opazimo, da mreža z le 20 nevroni (rdeča) doseže bistveno nižjo točnost ($\approx 95\%$) in počasneje zmanjšuje napako. Pri prehodu na 100 nevronov (zeleni) se zmogljivost znatno izboljša, medtem ko nadaljnje povečanje na 300 nevronov (modra) prinese le minimalen končen prirastek k točnosti, hkrati pa poveča računski čas. To nakazuje na obstoj optimalne informacijske kapacitete za dani problem.



Slika 5: Vpliv dimenzije skrite plasti na dinamiko učenja. Majhno število nevronov omejuje sposobnost generalizacije modela.

Še bolj kritičen parameter je hitrost učenja η (Slika 6). Pri prenizki vrednosti ($\eta = 0.001$) je proces konvergence preveč počasen za praktično uporabo. Pri previsoki vrednosti ($\eta = 0.5$, modra), sistem postane numerično nestabilen. Mreža v tem režimu “skače” čez minime funkcije


napake, kar povzroči, da se točnost ne premakne nad nivo naključnega ugibanja (10 %), temveč celo pade pod njim.



Slika 6: Odvisnost konvergence od hitrosti učenja η . Prevelik korak gradientnega spusta vodi v popolno nestabilnost sistema.


3.2 Analiza robustnosti na šum

Za fizikalno razumevanje meja delovanja mreže sem testiral njeno robustnost na dodajanje naključnega šuma (Slika 7). Slikam sem postopoma dodajal delež šuma α , od čiste slike do popolne popačenosti.




Slika 7: Vizualni prikaz postopnega dodajanja uniformnega šuma vhodnim podatkom.

Statistična analiza na 200 naključnih vzorcih (Slika 8) razkriva obnašanje, ki spominja na fazni prehod. Do približno 15 % deleža šuma mreža ohranja skoraj popolno točnost. Pri $\alpha \approx 0.25$ pride do strmega padca zmogljivosti. Zanimivo je, da aktivacija pravega izhoda (rdeča črtkana črta) pada skoraj linearno, kar pomeni, da mreža postopoma izgublja signal, vendar zaradi nelinearnosti na izhodu še vedno pravilno klasificira, dokler šum popolnoma ne prevlada.



Slika 8: Krivulja robustnosti klasifikacije v odvisnosti od deleža šuma. Opazimo plato stabilnosti in nato hiter razpad sistema.

Ob pošiljanju popolnoma naključnega šuma ($\alpha = 1.0$) skozi mrežo (Slika 9), model ne vrne nevtralne napovedi, temveč pogosto izbere določeno številko (v tem primeru 8) z nizko, a pozitivno aktivacijo, medtem ko ostale močno zaduši. To kaže na inherenten “bias” v utežeh naučene mreže.




Slika 9: Odziv mreže na čisti naključni šum. Mreža v šumu “išče” naučene vzorce in se odzove z neenakomerno aktivacijo izhodov.


3.3 Globoka arhitektura: Primerjava 1 vs. 2 skriti plasti

V sklopu analize modela sem primerjal plitvo mrežo z globoko različico, ki ima dve skriti plasti (100 $\rightarrow$ 50 nevronov). Slika 10 kaže, da se globoka mreža na začetku uči počasneje, kar je posledica težjega prenašanja gradientov skozi več plasti (vanishing gradient).

Vendar pa dolgoročno globoka mreža doseže nižjo končno napako. To potrjuje Slika 11, ki prikazuje relativni dobiček (Gain) globoke mreže. Vidimo, da po šesti epohi globoka mreža postane za približno 15 % boljša pri minimizaciji napake, njena točnost pa je za okoli 0.1 odstotne točke višja, kar nakazuje na boljšo sposobnost modeliranja finih podrobnosti.




Slika 10: Primerjava učenja plitve in globoke mreže. Več plasti omogoča boljši končni rezultat na račun počasnejšega začetnega učenja.



Slika 11: Relativna izboljšava globoke mreže. Pozitivne vrednosti v zgornjem grafu pomenijo manjšo napako globokega modela v primerjavi s plitvim.

3.4 Odziv na strukturirane neštevilske oblike

Zadnji test prve naloge je bil odziv na geometrijske like (črte, križ, kvadrat, šahovnica), ki niso vključeni v učno množico. Rezultati na Sliki 12 kažejo na pojav strojnega “delulu” obnašanja, kjer model vidi lepe jasnosti, ki jih v resnici ni. Mreža v vodoravni črti prepozna številko 1, v navpični črti številko 4, v križu pravilno ne prepozna ničesar, v kvadratu in šahovnici pa številko 8. To potrjuje, da model deluje kot napreden filter vzorcev, ki vsak vhod neizogibno projicira v naučeni prostor števk.




Slika 12: Odziv mreže na vhode, ki ne vsebujejo števk. Model vsako obliko interpretira kot najbolj podobno števko iz svojega spomina.

4 Naloga 2: Inverzni problem (Deep Dream)

Pri treniranju nevronske mreže običajno iščemo optimalne uteži $\mathbf{W}$, ki minimizirajo napako za fiksne vhode. Pri inverznem problemu, pogosto imenovanem “Deep Dream”, proces obrnemo: uteži mreže zamrznemo, nato pa s pomočjo gradientnega spusta (v tem primeru vzpona) spreminjam piksele vhodne slike $\mathbf{y}^0$ tako, da maksimiram aktivacijo želenega izhodnega nevrona. Ta postopek nam razkrije prototipne vzorce ali receptivna polja, ki jih je mreža razvila za posamezne kategorije.

4.1 Generiranje idealnih vhodov


Slika 13 prikazuje generirane idealne slike za vse številke od 0 do 9. Rezultati so vizualno fascinantni, saj dobimo »duhovne«, meglene oblike, ki povzemajo ključne lastnosti posameznih števk.



Slika 13: Idealne reprezentacije števk po mnenju nevronske mreže. Generirane so bile z iterativnim popravljanjem naključnega šuma v smeri gradienta za izbrano kategorijo.

4.2 Morfing in zveznost naučenega prostora

Nevronske mreže modelirajo svet kot zvezno funkcijo, kar pomeni, da bi moral biti prehod med naučenimi koncepti topološko gladek. To sem preizkusil s procesom “morfinga” (Slika 14), kjer sem začel z idealno sliko številke 0 in jo postopoma optimiziral proti cilju številke 8. Iz grafa je razvidno, da se slika ne spremeni skokovito, temveč se piksli počasi prerazporejajo.



Slika 14: Zvezna transformacija (morfing) idealne številke 0 v številko 8. Proces ilustrira, kako mreža vmesne oblike interpretira kot kombinacije naučenih značilnosti.

5 Zaključek

V nalogi sem podrobno raziskal delovanje nevronske mreže na primeru klasifikacije MNIST. Ključne ugotovitve naloge so:

1. **Učinkovitost in stabilnost:** Preprosta mreža s tremi plastmi in 100 nevroni doseže preko 98 % točnost, pri čemer so napake omejene na vizualno nejasne ali slabo napisane znake.
2. **Fizikalne meje (Robustnost):** Statistična analiza s šumom je pokazala obstoj kritične točke pri $\approx 15\%$ šuma, kjer klasifikacijski model razpade. Do te točke mreža kaže izjemno sposobnost rekonstrukcije signala.
3. **Pomen arhitekture:** Globoke mreže (več skritih plasti) ponujajo boljšo končno natančnost, vendar so zaradi numeričnih lastnosti gradientov težje in počasnejše za treniranje.
4. **Generativna narava:** Preko inverznega problema smo dokazali, da mreža v svojih utežeh nosi abstraktno predstavo o oblikah, kar nam omogoča vizualizacijo “strojnega razmišljanja”.