

Dodatki k učenju

Splošna fizika

T. Jovanovski

2. oktober 2026



Kazalo

1	Statistika pri fizikalnih meritvah	3
2	Modelska analiza 30.10.2025	13
3	Modelska analiza 06.11.2025: Luščenje parametrov	19
4	Kalmanov filter	27
5	Osnovno znanje za linearno napoved	30
6	Linearna napoved in avtoregresijski modeli	32
7	Fourierova vrsta	36
8	Michelsonov interferometer	45

1 Statistika pri fizikalnih meritvah

*

Meritve konstantnih količin in Gaussova porazdelitev

Pri merjenju fizikalnih količin, za katere predpostavljamo, da so konstantne, se rezultati posameznih meritev kljub temu razlikujejo. Te razlike so posledica naključnih napak oziroma šuma v merilnem procesu. Predpostavljamo, da so te napake porazdeljene po Gaussovi (normalni) porazdelitvi.

Če je a prava vrednost merjene količine in z je izmerjena vrednost, potem je ostanek (residual) r definiran kot:

$$r = z - a \quad (1)$$

Ta ostanek sledi normalni porazdelitvi $N(0, \sigma^2)$ z ničelno povprečno vrednostjo in varianco σ^2 . Naš cilj je na podlagi končnega števila meritev n oceniti pravo vrednost a in standardni odklon σ , ki karakterizira natančnost meritev.

Definicija 1.1 (Vzorčne statistike). Za vzorec n meritev $\{z_1, z_2, \dots, z_n\}$ definiramo dve ključni statistiki:

- **Vzorčno povprečje** ($\bar{z}$): Je najboljša ocena prave vrednosti a .

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i \quad (2)$$

- **Vzorčna varianca** (s^2): Je ocena variance porazdelitve meritev, σ^2 . Faktor $n - 1$ v imenovalcu zagotavlja nepristransko oceno variance.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2 \quad (3)$$

Ko število meritev n narašča proti neskončnosti, vzorčno povprečje $\bar{z}$ konvergira k pravi vrednosti a , vzorčna varianca s^2 pa k pravi varianci σ^2 .

*

Studentova t-porazdelitev

Kadar prava varianca σ^2 ni poznana in jo ocenjujemo z vzorčno varianco s^2 iz majhnega števila meritev, Gaussova porazdelitev ni več najboljši model. V tem primeru uporabimo Studentovo t-porazdelitev.

Definicija 1.2 (t-statistika). Definirajmo statistiko T kot:

$$T = \frac{\bar{z} - a}{s/\sqrt{n}} = \frac{\text{vzorčno povprečje} - \text{prava vrednost}}{\text{standardna napaka povprečja}} \quad (4)$$

Ta statistika meri, za koliko standardnih napak vzorčno povprečje odstopa od predpostavljene prave vrednosti a .

Verjetnostna gostota za statistiko T je podana s Studentovo t-porazdelitvijo $S(\nu)$ s $\nu = n - 1$ prostostnimi stopnjami:

$$\frac{dP}{dT} = S(n-1) = \frac{1}{\sqrt{n-1} \cdot B\left(\frac{1}{2}, \frac{n-1}{2}\right)} \left(1 + \frac{T^2}{n-1}\right)^{-\frac{n}{2}} \quad (5)$$

kjer je:

- n število meritev.
- $n - 1$ število prostostnih stopenj.
- $B(x, y)$ je Eulerjeva beta funkcija, definirana z integralom:

$$B(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt$$

Porazdelitev je zvonaste oblike, podobna Gaussovi, vendar ima širše repe, kar pomeni, da so ekstremne vrednosti bolj verjetne, posebej pri majhnem številu meritev n . Ko gre $n \rightarrow \infty$, t-porazdelitev konvergira k standardni normalni porazdelitvi.

*

Testiranje hipotez in intervali zaupanja

Studentova porazdelitev nam omogoča, da testiramo hipotezo o pravi vrednosti a in določimo interval zaupanja.

Postopek testiranja hipoteze:

1. Iz vzorca meritev $\{z_i\}$ izračunamo vzorčno povprečje $\bar{z}$ in varianco s^2 .
2. Postavimo ničelno hipotezo, da je prava vrednost enaka neki specifični vrednosti a_0 .
3. Izberemo stopnjo tveganja α , ki predstavlja verjetnost, da po pomoti zavrnemo pravilno hipotezo. Tipične vrednosti so $\alpha = 0.05$ (5%), $\alpha = 0.01$ (1%) ali $\alpha = 0.10$ (10%).
4. Izračunamo vrednost t-statistike T z uporabo enačbe 4, kjer za a vstavimo a_0 .
5. Iz tabel ali s programsko opremo poiščemo kritično vrednost t_{kr} za $n - 1$ prostostnih stopenj, za katero velja:

$$P(|T| > t_{kr}) = \alpha$$

6. Sprejmemo odločitev:

- Če je izračunana vrednost $|T| > t_{kr}$, potem hipotezo o vrednosti a_0 na stopnji tveganja α **zavrnemo**. Podatki statistično značilno nasprotujejo hipotezi.
- Če je $|T| \leq t_{kr}$, potem hipoteze o vrednosti a_0 **ne moremo zavreči**. To ne pomeni, da je hipoteza pravilna, ampak le, da podatki niso v dovolj močnem nasprotju z njo.

Interval zaupanja: Namesto testiranja ene same vrednosti lahko določimo celoten interval, v katerem se z določeno stopnjo zaupanja $1 - \alpha$ nahaja prava vrednost a . Interval zaupanja je območje vrednosti za parameter a , za katere ne bi zavrnili ničelne hipoteze.

Izhajamo iz pogoja:

$$P(-t_{kr} \leq T \leq t_{kr}) = 1 - \alpha \quad (6)$$

Vstavimo izraz za T :

$$-t_{kr} \leq \frac{\bar{z} - a}{s/\sqrt{n}} \leq t_{kr}$$

Z algebrsko preureditvijo osamimo a in dobimo $(1 - \alpha)$ -odstotni interval zaupanja za pravo vrednost a :

$$\left[\bar{z} - t_{kr} \frac{s}{\sqrt{n}}, \quad \bar{z} + t_{kr} \frac{s}{\sqrt{n}} \right] \quad (7)$$

To pomeni, da z verjetnostjo $1 - \alpha$ prava vrednost merjene količine leži znotraj tega intervala. Vrednosti a izven tega intervala bi na stopnji tveganja α zavrnili.

*

Porazdelitev hi-kvadrat (χ^2)

Podobno kot t-porazdelitev omogoča testiranje hipotez o povprečni vrednosti, nam porazdelitev χ^2 (hi-kvadrat) omogoča testiranje hipotez o pravi varianci σ^2 populacije. Predpostavljamo, da imamo vzorec $\{z_i\}$ iz normalno porazdeljene populacije $N(a, \sigma^2)$.

Definicija 1.3 (χ^2 -statistika). *Statistiko χ^2 definiramo kot:*

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} \quad (8)$$

kjer je n velikost vzorca, s^2 je vzorčna varianca in σ^2 je (hipotetična) prava varianca populacije. Ta statistika je porazdeljena po χ^2 -porazdelitvi z $\nu = n - 1$ prostostnimi stopnjami.

Verjetnostna gostota porazdelitve χ^2 z ν prostostnimi stopnjami je podana z izrazom:

$$\frac{dP}{d\chi^2} = f(\chi^2; \nu) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} (\chi^2)^{\frac{\nu}{2}-1} e^{-\frac{\chi^2}{2}} \quad (9)$$

kjer je:

- $\nu = n - 1$ število prostostnih stopenj.
- $\Gamma(z)$ je Eulerjeva gama funkcija, definirana z integralom:

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$$

Porazdelitev je normirana na 1 in je definirana samo za pozitivne vrednosti $\chi^2 > 0$. Z verjetnostjo $1 - \alpha$ pričakujemo, da bo izračunana vrednost χ^2 padla znotraj intervala $[\chi^2_{<}, \chi^2_{>}]$. Če pade izven tega intervala, hipotezo o vrednosti σ^2 zavrnemo na stopnji tveganja α .

Teoretična osnova za χ^2 porazdelitev je podana z naslednjim izrekom.

Izrek 1.1 (Vsota kvadratov normalnih spremenljivk). *Vsota kvadratov n neodvisnih, standardizirano normalno porazdeljenih naključnih spremenljivk $Z_i \sim N(0, 1)$, je porazdeljena po zakonu χ^2 z n prostostnimi stopnjami:*

$$\sum_{i=1}^n Z_i^2 \sim \chi^2(n) \quad (10)$$

Ta izrek, katerega dokaz tukaj izpustimo, potrjuje definicijo χ^2 statistike, saj je izraz $(n-1)s^2/\sigma^2$ sorazmeren vsoti kvadratov odklonov od povprečja.

Naslednji izrek elegantno poveže normalno, χ^2 in Studentovo t -porazdelitev.

Izrek 1.2 (Povezava med porazdelitvami). *Naj bo X naključna spremenljivka, porazdeljena po standardni normalni porazdelitvi, $X \sim N(0, 1)$, in naj bo Y neodvisna naključna spremenljivka, porazdeljena po χ^2 porazdelitvi z n prostostnimi stopnjami, $Y \sim \chi^2(n)$. Potem je nova spremenljivka T , definirana kot*

$$T = \frac{X}{\sqrt{Y/n}} \quad (11)$$

porazdeljena po Studentovi t -porazdelitvi z n prostostnimi stopnjami, $T \sim S(n)$.

*

Oblikovni testi (Goodness-of-Fit)

Ko smo s pomočjo metode najmanjših kvadratov določili optimalne parametre modela, se moramo še vprašati, ali je sam model (predpostavljena funkcijska oblika) sploh primeren za opis podatkov. Oblikovni testi nam omogočajo, da na statistično značilen način ocenimo, kako dobro se teoretična verjetnostna porazdelitev ujema z izmerjenimi podatki.

Pearsonov χ^2 test **Intuitivna ideja:** Ta test preverja, kako dobro se neka vnaprej določena verjetnostna gostota, dP/dz , ujema z našimi podatki. To storimo tako, da podatke razdelimo v razrede (naredimo histogram) in primerjamo, koliko meritev smo *dejansko* opazili v vsakem razredu (N_k) s številom meritev, ki bi jih v tem razredu *pričakovali* glede na teoretični model (N_{pk}). Če je model dober, bodo razlike med opazovanim in pričakovanim številom majhne, posledica zgolj statističnega nihanja.

Postopek:

1. Imamo vzorec n meritev $\{z_i\}$.
2. Podatkovni prostor razdelimo na ρ razredov (binov), ki se ne prekrivajo in nimajo vmesnih lukenj.
3. Za vsak razred k preštejemo število meritev N_k , ki so padle vanj.
4. Za vsak razred izračunamo teoretično verjetnost P_k , da meritev pade vanj, z integracijo predpostavljene porazdelitve dP/dz čez meje razreda:

$$P_k = \int_{z_{k-1}}^{z_k} \frac{dP}{dz} dz$$

Pričakovano število dogodkov v k -tem razredu je potem $N_{pk} = N \cdot P_k$.

5. Če je model dober, je število dogodkov N_k v vsakem razredu porazdeljeno po Poissonovi porazdelitvi s povprečjem N_{pk} . Za dovolj veliko število pričakovanih dogodkov ($N_{pk} \gtrsim 5$) ta porazdelitev preide v Gaussovo porazdelitev $N(N_{pk}, \sqrt{N_{pk}})$.
6. Sestavimo testno statistiko χ^2 , ki sešteje kvadrirana in normirana odstopanja:

$$\chi^2 = \sum_{k=1}^{\rho} \frac{(N_k - N_{pk})^2}{N_{pk}} \quad (12)$$

Ta statistika je porazdeljena po χ^2 porazdelitvi z $\nu = \rho - 1$ prostostnimi stopnjami. Eno prostostno stopnjo izgubimo, ker velja pogoj $\sum N_k = N$.

Primer 1.1 (Radioaktivni razpad). Pri merjenju radioaktivnega razpada smo zabeležili čas med dvema zaporednima sunkom. Dobili smo vzorec $N = 100$ meritev, pri čemer so vsi izmerjeni časi $t_k < 1.6$ s. Ali lahko na stopnji tveganja $\alpha = 5\%$ ovržemo hipotezo, da časi med sunki sledijo eksponencialni porazdelitvi s povprečnim časom $\tau = 1$ s?

Rešitev: Hipoteza je, da je porazdelitev dana z $dP/dt = \frac{1}{\tau}e^{-t/\tau}$ s fiksno vrednostjo $\tau = 1$ s.

1. **Razdelitev v razrede:** Interval $[0, 1.6]$ razdelimo na $\rho = 4$ enako široke razrede: $[0, 0.4)$, $[0.4, 0.8)$, $[0.8, 1.2)$, $[1.2, 1.6)$.

2. **Izračun pričakovanih frekvenc (N_{pk}):** Verjetnost za k -ti razred je

$$P_k = \int_{t_{k-1}}^{t_k} \frac{1}{\tau} e^{-t/\tau} dt = [-e^{-t/\tau}]_{t_{k-1}}^{t_k}.$$

- $P_1 = 1 - e^{-0.4/1} \approx 0.3297 \Rightarrow N_{p1} = 100 \cdot 0.3297 = 33.0$
- $P_2 = e^{-0.4} - e^{-0.8} \approx 0.2212 \Rightarrow N_{p2} = 22.1$
- $P_3 = e^{-0.8} - e^{-1.2} \approx 0.1481 \Rightarrow N_{p3} = 14.8$
- $P_4 = e^{-1.2} - e^{-1.6} \approx 0.0996 \Rightarrow N_{p4} = 10.0$
- *Opomba:* Vsota verjetnosti ni 1, ker smo upoštevali le meritve do 1.6 s. Za pravilen test bi morali vključiti še peti razred $[1.6, \infty)$, a ker vemo, da v njem ni bilo meritev, poenostavimo. Za natančnejšo analizo bi morali normirati verjetnosti.

3. **Izračun χ^2 :** Predpostavimo, da so bile izmerjene frekvence $N_1 = 35$, $N_2 = 20$, $N_3 = 25$, $N_4 = 20$. Vrednost χ^2 bi bila:

$$\chi^2 = \frac{(35 - 33.0)^2}{33.0} + \frac{(20 - 22.1)^2}{22.1} + \frac{(25 - 14.8)^2}{14.8} + \frac{(20 - 10.0)^2}{10.0} = 17.35$$

4. **Sklep:** Število prostostnih stopenj je $\nu = \rho - 1 = 4 - 1 = 3$. Kritična vrednost za $\chi^2(3)$ pri $\alpha = 0.05$ je $\chi^2_{kr} = 7.81$. Ker je naša izračunana vrednost $17.35 > 7.81$, hipotezo, da je $\tau = 1$ s, na stopnji tveganja 5% **zavrnamo**. Podatki statistično značilno odstopajo od predlaganega modela.

Metoda največje verjetnosti (Maximum Likelihood) **Intuitivna ideja:** Kaj pa, če parametrov porazdelitve (npr. τ v prejšnjem primeru) ne poznamo vnaprej? Metoda največje verjetnosti je postopek, s katerim poiščemo tiste vrednosti parametrov, pri katerih je verjetnost, da bi izmerili ravno naš set podatkov, največja možna. Modelu “pustimo”, da se optimalno prilagodi podatkom.

Postopek: Sestavimo **funkcijo zanesljivosti (likelihood)** L , ki je sorazmerna verjetnosti za opazovanje našega vzorca meritev $\{z_k\}$, če je porazdelitev $dP/dz(z, q_i)$ odvisna od parametrov q_i .

- **Brez razredov (unbinned):** Funkcija zanesljivosti je produkt vrednosti verjetnostne gostote na mestu vsake posamezne meritve:

$$L(q_i) = \prod_{k=1}^N \frac{dP}{dz}(z_k, q_i)$$

- **Z razredi (binned):** Funkcija zanesljivosti je verjetnost, da dobimo točno tak histogram, kot smo ga izmerili:

$$L^*(q_i) = \prod_{k=1}^{\rho} [P_k(q_i)]^{N_k}$$

Ker je lažje delati z vsotami kot s produkti, običajno maksimiziramo logaritem funkcije zanesljivosti ($\ln L$). Optimalne vrednosti parametrov $\hat{q}_i$ dobimo z reševanjem sistema enačb:

$$\frac{\partial(\ln L)}{\partial q_i} = 0$$

Ko imamo optimalne parametre, lahko izvedemo χ^2 test. Testna statistika je enaka kot pri Pearsonovem testu, le da sedaj uporabimo pričakovane frekvence $N_{p\hat{k}}$, izračunane z optimalnimi parametri. Število prostostnih stopenj pa se zmanjša, ker smo m parametrov določili iz podatkov:

$$\chi^2 = \sum_{k=1}^{\rho} \frac{(N_k - N_{p\hat{k}})^2}{N_{p\hat{k}}}, \quad \nu = \rho - 1 - m$$

Primer 1.2 (Radioaktivni razpad - iskanje optimalnega τ). Imamo vzorec meritev časov med sunki $\{t_k\}$. Kakšna je najboljša ocena za razpadni čas τ na podlagi teh podatkov?

Rešitev: Porazdelitev je $dP/dt = \frac{1}{\tau}e^{-t/\tau}$. Uporabimo metodo največje verjetnosti brez razredov.

1. Funkcija zanesljivosti:

$$L(\tau) = \prod_{k=1}^N \frac{1}{\tau} e^{-t_k/\tau}$$

2. Logaritem funkcije zanesljivosti:

$$\ln L(\tau) = \ln \left(\prod_{k=1}^N \frac{1}{\tau} e^{-t_k/\tau} \right) = \sum_{k=1}^N \left(\ln \left(\frac{1}{\tau} \right) - \frac{t_k}{\tau} \right) = -N \ln \tau - \frac{1}{\tau} \sum_{k=1}^N t_k$$

3. Iskanje maksimuma (odvod in enačanje z 0):

$$\frac{d(\ln L)}{d\tau} = -\frac{N}{\tau} - \left(-\frac{1}{\tau^2}\right) \sum_{k=1}^N t_k = 0$$

$$\frac{1}{\hat{\tau}^2} \sum_{k=1}^N t_k = \frac{N}{\hat{\tau}}$$

4. Rešitev za optimalni $\hat{\tau}$:

$$\hat{\tau} = \frac{1}{N} \sum_{k=1}^N t_k = \bar{t}$$

Interpretacija: Metoda največje verjetnosti nam da intuitiven in pričakovan rezultat. Najboljša ocena za povprečni življenjski čas τ je kar povprečje izmerjenih življenjskih časov.

Kolmogorov-Smirnov test **Intuitivna ideja:** Ta test se izogne razdelitvi podatkov v razrede, s čimer se izognemo izgubi informacije. Namesto primerjave histogramov (gostot verjetnosti) primerja **kumulativne porazdelitvene funkcije**. Teoretična kumulativna funkcija $F(z)$ pove, kolikšen delež meritev bi moral biti manjši od vrednosti z . Eksperimentalna kumulativna funkcija $f(z)$ pa pove, kolikšen delež meritev dejansko je manjši od z . Če se model dobro ujema s podatki, bosta ti dve funkciji povsod zelo blizu druga drugi. Test meri največjo vertikalno razdaljo med njima.

Postopek:

1. Imamo vzorec $\{z_i\}$. Privzamemo teoretično kumulativno porazdelitveno funkcijo $F(z)$:

$$F(z) = \int_{-\infty}^z \frac{dP}{dz'} dz'$$

2. Sestavimo eksperimentalno (empirično) kumulativno funkcijo. To je stopničasta funkcija, ki se pri vsaki izmerjeni vrednosti z_i poveča za $1/N$:

$$f(z) = \frac{k(z)}{N}, \quad \text{kjer je } k(z) \text{ število izmerkov, manjših ali enakih } z.$$

3. Izračunamo testno statistiko D , ki je definirana kot največja absolutna razlika med obema funkcijama po celotnem območju vrednosti z :

$$D = \sup_{z \in (-\infty, \infty)} |F(z) - f(z)| \quad (13)$$

4. Kolmogorov je pokazal, da je porazdelitev statistike $D\sqrt{N}$ za velike N neodvisna od same porazdelitve $F(z)$. Verjetnost, da je $D\sqrt{N}$ manjša od neke vrednosti d , je podana z:

$$P(D\sqrt{N} < d) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 d^2}$$

5. Izberemo stopnjo tveganja α in poiščemo kritično vrednost d_{kr} tako, da velja $P(D\sqrt{N} < d_{kr}) = 1 - \alpha$. Če je naša izračunana vrednost $D\sqrt{N} > d_{kr}$, potem s tveganjem α zavrnamo hipotezo, da porazdelitev $F(z)$ ustreza izmerkom.

*

Metoda najmanjših kvadratov v matrični obliki

Pogosto želimo podatke opisati z modelom, ki je linearna kombinacija znanih baznih funkcij, vendar z neznanimi koeficienti. Tak model lahko zapišemo kot:

$$z(t) = x_0 f_0(t) + x_1 f_1(t) + \cdots + x_m f_m(t) = \sum_{j=0}^m x_j f_j(t) \quad (14)$$

kjer so $f_j(t)$ znane funkcije (npr. polinomi, Gaussove funkcije, sinusi), x_j pa so neznani parametri, ki jih želimo določiti. Ključno je, da je model **linearen v parametrih** x_j .

Linearni model in Kalmanov formalizem

Za n meritev z_i ob časih (ali drugih neodvisnih spremenljivkah) t_i lahko problem zapišemo v elegantni matrični obliki:

$$\mathbf{z} = \mathbf{H}\mathbf{x} + \mathbf{r} \quad (15)$$

kjer je:

- $\mathbf{z}$ vektor meritev dimenzije $n \times 1$.
- $\mathbf{x}$ vektor neznanih parametrov dimenzije $(m+1) \times 1$.
- $\mathbf{H}$ je t.i. **načrtovalna matrika** (design matrix) dimenzije $n \times (m+1)$, ki vsebuje vrednosti baznih funkcij ob vsaki meritvi: $H_{ij} = f_j(t_i)$.
- $\mathbf{r}$ je vektor merilnega šuma dimenzije $n \times 1$.

Cilj metode najmanjših kvadratov je poiskati tak vektor parametrov $\hat{\mathbf{x}}$, ki minimizira vsoto kvadratov uteženih ostankov. Ta vsota je enaka χ^2 :

$$\chi^2(\mathbf{x}) = (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x}) \quad (16)$$

kjer je $\mathbf{R}$ kovariančna matrika meritev. Minimum najdemo z odvajanjem po $\mathbf{x}$ in enačenjem z nič: $\frac{\partial \chi^2}{\partial \mathbf{x}} = 0$.

Rešitev lahko izpeljemo s pomočjo Kalmanovega filtra. Za eno serijo meritev ("batch fit") predpostavimo, da nimamo predhodnega znanja o parametrih:

- Začetna ocena parametrov: $\bar{\mathbf{x}} = \mathbf{0}$.
- Začetna kovariančna matrika parametrov: $\mathbf{M} \rightarrow \infty$, kar pomeni $\mathbf{M}^{-1} = \mathbf{0}$.

Poleg tega predpostavimo najenostavnejši primer merilnega šuma: vse meritve so med seboj neodvisne in imajo enako, poznano varianco σ^2 . To pomeni, da je kovariančna matrika meritev diagonalna: $\mathbf{R} = \sigma^2 \mathbf{I}$, kjer je $\mathbf{I}$ identitetna matrika.

Kovariančna matrika ocenjenih parametrov $\mathbf{P}$ je podana z:

$$\mathbf{P}^{-1} = \mathbf{M}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}$$

Z našimi predpostavkami dobimo:

$$\mathbf{P}^{-1} = \mathbf{0} + \mathbf{H}^T (\sigma^2 \mathbf{I})^{-1} \mathbf{H} = \frac{1}{\sigma^2} \mathbf{H}^T \mathbf{H}$$

Inverz te matrike nam da iskano kovariančno matriko za parametre:

$$\mathbf{P} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1} \quad (17)$$

Optimalna ocena za parametre $\hat{\mathbf{x}}$ je podana z:

$$\hat{\mathbf{x}} = \bar{\mathbf{x}} + \mathbf{P} \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{z} - \mathbf{H} \bar{\mathbf{x}})$$

Po vstavitvi naših predpostavk:

$$\hat{\mathbf{x}} = \mathbf{0} + \mathbf{P} \mathbf{H}^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{z} - \mathbf{0}) = \frac{1}{\sigma^2} \mathbf{P} \mathbf{H}^T \mathbf{z}$$

Če sedaj vstavimo zgoraj izpeljan izraz za $\mathbf{P}$:

$$\hat{\mathbf{x}} = \frac{1}{\sigma^2} (\sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}) \mathbf{H}^T \mathbf{z}$$

Dobimo končno rešitev, znano kot **normalna enačba**:

$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{z} \quad (18)$$

Ta rešitev nam omogoča, da iz meritev $\mathbf{z}$ in poznavanja modela (matrika $\mathbf{H}$) neposredno izračunamo najboljšo oceno parametrov $\hat{\mathbf{x}}$ in njihovo kovariančno matriko $\mathbf{P}$. Minimalna vrednost χ^2 je porazdeljena po zakonu χ^2 z $n - (m + 1)$ prostostnimi stopnjami.

Primer: Luščenje vrhov v spektru

Predpostavimo, da merimo fotoemisijski spekter, kjer imamo dva bližnja vrhova na konstantnem ozadju. Model za število sunkov z_i pri energiji E_i je:

$$z_i = B \cdot 1 + A_1 \cdot f_1(E_i) + A_2 \cdot f_2(E_i) + r_i$$

kjer je B konstanta ozadja, A_1 in A_2 sta amplitudi vrhov, f_1 in f_2 pa sta znani obliki vrhov (npr. Gaussova, Lorentzova ali Voigtova funkcija, katerih položaj in širina sta fiksna). Želimo določiti parametre B, A_1, A_2 .

Postavitev problema v matrično obliko:

- **Vektor parametrov:** $\mathbf{x} = \begin{pmatrix} B \\ A_1 \\ A_2 \end{pmatrix}$

- **Vektor meritev:** $\mathbf{z} = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix}$

- **Načrtovalna matrika $\mathbf{H}$:** Bazne funkcije so $f_0(E) = 1$, $f_1(E)$ in $f_2(E)$.

$$\mathbf{H} = \begin{pmatrix} 1 & f_1(E_1) & f_2(E_1) \\ 1 & f_1(E_2) & f_2(E_2) \\ \vdots & \vdots & \vdots \\ 1 & f_1(E_n) & f_2(E_n) \end{pmatrix}$$

Rešitev: Za rešitev (18) moramo izračunati dva produkta: $\mathbf{H}^T \mathbf{H}$ in $\mathbf{H}^T \mathbf{z}$.

1. **Izračun matrike $\mathbf{H}^T \mathbf{H}$:**

$$\mathbf{H}^T \mathbf{H} = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n f_1(E_i) & \sum_{i=1}^n f_2(E_i) \\ \sum_{i=1}^n f_1(E_i) & \sum_{i=1}^n f_1(E_i)^2 & \sum_{i=1}^n f_1(E_i)f_2(E_i) \\ \sum_{i=1}^n f_2(E_i) & \sum_{i=1}^n f_1(E_i)f_2(E_i) & \sum_{i=1}^n f_2(E_i)^2 \end{pmatrix}$$

Ta 3×3 simetrična matrika vsebuje vse informacije o prekrivanju baznih funkcij.

2. **Izračun vektorja $\mathbf{H}^T \mathbf{z}$:**

$$\mathbf{H}^T \mathbf{z} = \begin{pmatrix} \sum_{i=1}^n z_i \\ \sum_{i=1}^n z_i f_1(E_i) \\ \sum_{i=1}^n z_i f_2(E_i) \end{pmatrix}$$

Ta vektor vsebuje projekcije meritev na vsako od baznih funkcij.

3. **Optimalni parametri $\hat{\mathbf{x}}$:** Rešitev je inverz prve matrike, pomnožen z drugim vektorjem:

$$\hat{\mathbf{x}} = \begin{pmatrix} \hat{B} \\ \hat{A}_1 \\ \hat{A}_2 \end{pmatrix} = (\mathbf{H}^T \mathbf{H})^{-1} (\mathbf{H}^T \mathbf{z})$$

4. **Kovariančna matrika $\mathbf{P}$:** Negotovosti parametrov so vsebovane v matriki $\mathbf{P}$:

$$\mathbf{P} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1} = \begin{pmatrix} \sigma_B^2 & \text{Cov}(B, A_1) & \text{Cov}(B, A_2) \\ \text{Cov}(A_1, B) & \sigma_{A_1}^2 & \text{Cov}(A_1, A_2) \\ \text{Cov}(A_2, B) & \text{Cov}(A_2, A_1) & \sigma_{A_2}^2 \end{pmatrix}$$

Diagonalni elementi so variance (kvadrati napak) iskanih parametrov.

Fizikalna interpretacija kovariančne matrike: Izvendiagonalni element $\text{Cov}(A_1, A_2)$ nam pove, kako sta oceni za amplitudi A_1 in A_2 med seboj statistično povezani.

- **Dobro ločljiva vrhova:** Če sta vrhova daleč narazen, se funkciji $f_1(E)$ in $f_2(E)$ praktično ne prekrivata. Zato bo produkt $f_1(E_i)f_2(E_i) \approx 0$ za vse i . Posledično bo izvendiagonalni element $\sum f_1 f_2$ v matriki $\mathbf{H}^T \mathbf{H}$ blizu nič. Matrika bo skoraj diagonalna, kar pomeni, da bo tudi njen inverz $(\mathbf{H}^T \mathbf{H})^{-1}$ skoraj diagonalen. Element $\text{Cov}(A_1, A_2)$ bo zelo majhen. **Intuitivno:** Ocena amplitude enega vrha je praktično neodvisna od ocene amplitude drugega. Algoritem zlahka loči, kateri foton pripada kateremu vrhu.
- **Zelo zlita vrhova:** Če se vrhova močno prekrivata, sta si funkciji $f_1(E)$ in $f_2(E)$ podobni na velikem delu intervala. To pomeni, da bosta drugi in tretji stolpec v matriki $\mathbf{H}$ skoraj linearno odvisna. Element $\sum f_1 f_2$ bo velik, matrika $\mathbf{H}^T \mathbf{H}$ pa bo skoraj singularna (determinanta blizu 0). Njen inverz $(\mathbf{H}^T \mathbf{H})^{-1}$, in s tem kovariančna matrika $\mathbf{P}$, bo imel zelo velike elemente, tako na diagonali kot izven nje. Element $\text{Cov}(A_1, A_2)$ bo velik in negativen. **Intuitivno:** Algoritem ne more z gotovostjo določiti, ali signal v območju prekrivanja pripada prvemu ali drugemu vrhu. Če fit poskuša povečati amplitudo A_1 , mora hkrati zmanjšati amplitudo A_2 , da se njuna vsota še vedno ujema s podatki. Ta negativna korelacija pomeni, da sta oceni močno povezani, kar se odraža v velikih napakah σ_{A_1} in σ_{A_2} .

2 Modelska analiza 30.10.2025

Analiza dinamike sistemov z velikim številom delcev, kot so kemijske reakcije, je pogosto prezahtevna za pristop *ab initio* (iz prvih principov, npr. z reševanjem Schrödingerjeve enačbe za vse vpletene molekule). Zato se zatekamo k stohastičnim modelom, ki opisujejo časovni razvoj sistema na višjem, bolj abstraktnem nivoju. Osredotočimo se le na časovno odvisnost števila molekul posameznih vrst.

*

Stohastično modeliranje kemijskih reakcij

Predpostavimo sistem z N različnimi vrstami molekul (angl. *chemical species*), ki sodelujejo v M možnih kemijskih reakcijah.

Definicija 2.1 (Vektor stanja). *Stanje sistema ob času t je popolnoma določeno z vektorjem stanja $\mathbf{X}(t)$, ki vsebuje število molekul vsake vrste:*

$$\mathbf{X}(t) = [X_1(t), X_2(t), \dots, X_N(t)] \quad (19)$$

kjer je $X_i(t)$ število molekul i -te vrste ob času t . Ker število molekul ne more biti negativno, so komponente vektorja stanja cela, nenegativna števila.

Spremembe v sistemu se dogajajo, ko poteče ena od M reakcij. Vsaka reakcija povzroči, da se stanje sistema $\mathbf{X}(t)$ spremeni za določen vektor.

Definicija 2.2 (Stehiometrični vektor). *Za vsako reakcijo $j \in \{1, \dots, M\}$ definiramo stehiometrični vektor ν_j , ki pove, kako se spremeni število molekul vsake vrste, ko ta reakcija poteče natanko enkrat. Komponente vektorja ν_j so cela števila (pozitivna za produkte, negativna za reaktante).*

$$\mathbf{X}(t) \xrightarrow{\text{reakcija } j} \mathbf{X}(t) + \nu_j$$

Primer 2.1 (Michaelis-Menten sistem). *Prototipni sistem encimske kinetike vključuje substrat (S_1), encim (S_2), kompleks encim-substrat (S_3) in produkt (S_4). Imamo $N = 4$ vrste molekul in $M = 3$ reakcije:*

1. $S_1 + S_2 \xrightarrow{c_1} S_3$ (tvorba kompleksa)
2. $S_3 \xrightarrow{c_2} S_1 + S_2$ (razpad kompleksa v reaktante)
3. $S_3 \xrightarrow{c_3} S_2 + S_4$ (razpad kompleksa v produkt in encim)

Vektor stanja je $\mathbf{X} = [X_1, X_2, X_3, X_4]$. Stehiometrični vektorji za posamezne reakcije so:

$$\nu_1 = [-1, -1, +1, 0]$$

$$\nu_2 = [+1, +1, -1, 0]$$

$$\nu_3 = [0, +1, -1, +1]$$

*

Propensity funkcija in Chemical Master Equation

Da bi modelirali dinamiko, moramo vsaki reakciji pripisati verjetnost, da se bo zgodila v majhnem časovnem intervalu. To vlogo prevzame **propensity funkcija** $a_j(\mathbf{X})$.

Definicija 2.3 (Propensity funkcija). *Funkcija $a_j(\mathbf{X}(t))$ je sorazmerna verjetnosti, da bo reakcija j potekla v infinitezimalno majhnem časovnem intervalu $[t, t + dt)$. Natančneje, $a_j(\mathbf{X})dt$ je ta verjetnost. Oblika funkcije je odvisna od reda reakcije:*

- **1. red (npr. razpad $S_m \rightarrow \dots$):** Hitrost je odvisna od števila molekul S_m .

$$a_j(\mathbf{X}) = c_j X_m(t)$$

- **2. red (npr. $S_m + S_k \rightarrow \dots$):** Hitrost je odvisna od števila možnih parov reaktantov.

$$a_j(\mathbf{X}) = c_j X_m(t) X_k(t)$$

- **2. red (dimerizacija $S_m + S_m \rightarrow \dots$):** Hitrost je odvisna od števila parov enakih molekul.

$$a_j(\mathbf{X}) = c_j \frac{X_m(t)(X_m(t) - 1)}{2}$$

Konstanta c_j je stohastična reakcijska konstanta.

Za Michaelis-Menten sistem so propensity funkcije:

$$a_1(\mathbf{X}) = c_1 X_1(t) X_2(t)$$

$$a_2(\mathbf{X}) = c_2 X_3(t)$$

$$a_3(\mathbf{X}) = c_3 X_3(t)$$

Če poznamo verjetnost $P(\mathbf{x}, t)$, da je sistem ob času t v stanju $\mathbf{x}$, lahko zapišemo enačbo za njen časovni razvoj. Ob času $t + \Delta t$ je sistem lahko v stanju $\mathbf{x}$ na dva načina:

1. Že ob času t je bil v stanju $\mathbf{x}$ in v intervalu Δt ni potekla nobena reakcija.
2. Ob času t je bil v enem od stanj $\mathbf{x} - \nu_j$, in je v intervalu Δt potekla ravno reakcija j , ki ga je pripeljala v stanje $\mathbf{x}$.

Z upoštevanjem verjetnosti za te dogodke pridemo do **Chemical Master Equation (CME)**:

$$\frac{dP(\mathbf{x}, t)}{dt} = \sum_{j=1}^M [a_j(\mathbf{x} - \nu_j) P(\mathbf{x} - \nu_j, t) - a_j(\mathbf{x}) P(\mathbf{x}, t)] \quad (20)$$

Fizikalna interpretacija: Sprememba verjetnosti, da smo v stanju $\mathbf{x}$, je enaka vsoti vseh verjetnostnih tokov *v* to stanje (prvi člen) minus vsota vseh verjetnostnih tokov *iz* tega stanja (drugi člen). To je enačba o ohranitvi verjetnosti.

CME je sistem sklopljenih navadnih diferencialnih enačb, po ena za vsako možno stanje $\mathbf{x}$. Število možnih stanj je lahko astronomsko veliko, zato je direktno reševanje praktično nemogoče.

*

Aproksimacije in poenostavitve

Tau-Leap aproksimacija (Gillespiejev algoritem): Namesto infinitezimalnega koraka naredimo korak končne dolžine τ , ki je dovolj majhen, da se propensity funkcije $a_j(\mathbf{X})$ v tem času bistveno ne spremenijo. Število, kolikokrat reakcija j poteče v času τ , je Poissonova naključna spremenljivka $\mathcal{P}_j$ s povprečjem $a_j(\mathbf{X}(t))\tau$.

$$\mathbf{X}(t + \tau) = \mathbf{X}(t) + \sum_{j=1}^M \mathcal{P}_j(a_j(\mathbf{X}(t))\tau) \cdot \nu_j \quad (21)$$

Algoritem je torej:

1. Izberi časovni korak τ .
2. Za vsako reakcijo $j = 1, \dots, M$ izžreбай naključno število p_j iz Poissonove porazdelitve s povprečjem $\lambda = a_j(\mathbf{X}(t))\tau$.
3. Posodobi stanje sistema: $\mathbf{X}(t + \tau) = \mathbf{X}(t) + \sum_{j=1}^M p_j \nu_j$.

Chemical Langevin Equation (CLE): Če je povprečje Poissonove porazdelitve $\lambda = a_j\tau$ dovolj veliko (veliko reakcij v koraku τ), lahko porazdelitev aproksimiramo z Gaussovo porazdelitvijo: $\mathcal{P}(\lambda) \approx N(\lambda, \lambda)$. Zapisano drugače:

$$\mathcal{P}_j(a_j\tau) \approx a_j(\mathbf{X})\tau + \sqrt{a_j(\mathbf{X})\tau} \cdot Z_j$$

kjer je Z_j standardna normalno porazdeljena naključna spremenljivka $N(0, 1)$. Ko to vstavimo v tau-leap enačbo, dobimo stohastično diferencialno enačbo, znano kot **Chemical Langevin Equation**:

$$d\mathbf{X} = \sum_{j=1}^M a_j(\mathbf{X})\nu_j dt + \sum_{j=1}^M \sqrt{a_j(\mathbf{X})}\nu_j dW_j(t) \quad (22)$$

Fizikalna interpretacija: Sprememba stanja $d\mathbf{X}$ je sestavljena iz dveh delov:

- **Deterministični del (drift):** $\sum a_j\nu_j dt$ opisuje povprečno, pričakovano spremembo sistema.
- **Stohastični del (difuzija/šum):** $\sum \sqrt{a_j}\nu_j dW_j$ opisuje naključna nihanja (fluktuacije) okoli povprečne poti, ki izvirajo iz diskretne narave kemijskih reakcij. dW_j je t.i. Wienerjev proces.

Ta pristop zmanjša problem z analize ogromnega števila diskretnih stanj na reševanje sistema N stohastičnih diferencialnih enačb za realne vrednosti $X_i(t)$.

Deterministična “Rate Equation”: Če je število molekul v sistemu zelo veliko, lahko naključna nihanja zanemarimo in opazujemo le povprečno obnašanje. To pomeni, da v CLE preprosto zavržemo stohastični člen.

$$\frac{d\mathbf{X}}{dt} = \sum_{j=1}^M a_j(\mathbf{X})\nu_j \quad (23)$$

To je klasična, deterministična **enačba hitrosti**, ki jo poznamo iz makroskopske kemijske kinetike.

Za Michaelis-Menten sistem dobimo: $\frac{d\mathbf{X}}{dt} = a_1(\mathbf{X})\nu_1 + a_2(\mathbf{X})\nu_2 + a_3(\mathbf{X})\nu_3$. Po komponentah:

$$\begin{aligned}\dot{X}_1 &= -c_1 X_1 X_2 + c_2 X_3 \\ \dot{X}_2 &= -c_1 X_1 X_2 + c_2 X_3 + c_3 X_3 = -c_1 X_1 X_2 + (c_2 + c_3) X_3 \\ \dot{X}_3 &= c_1 X_1 X_2 - c_2 X_3 - c_3 X_3 = c_1 X_1 X_2 - (c_2 + c_3) X_3 \\ \dot{X}_4 &= c_3 X_3\end{aligned}$$



Pomembno je poudariti, da deterministični pristop ni vedno pravilen, saj velja $\overline{XY} \neq \bar{X}\bar{Y}$. To pomeni, da povprečno obnašanje sistema, opisanega z reakcijskimi enačbami, ni nujno enako obnašanju povprečnih vrednosti, še posebej če so fluktuacije velike.

*

Analiza nalog iz modelske analize

V tem razdelku bomo obravnavali nekaj tipičnih problemov iz kinetike kemijskih reakcij, ki ilustrirajo uporabo aproksimacije stacionarnega stanja in analizo kompleksnih reakcijskih mehanizmov.

Naloga 1: Model binarne reakcije Obravnavamo reakcijski mehanizem, kjer dve molekuli A trčita in ena od njiju postane vzbujena (A^*). Vzbujena molekula lahko bodisi razpade nazaj v osnovno stanje ali pa reagira naprej v produkta B in C.



Sistem opišemo z diferencialnimi enačbami za koncentracije posameznih snovi:

$$\begin{aligned}\frac{d[A]}{dt} &= -p[A]^2 + q[A][A^*] \\ \frac{d[A^*]}{dt} &= p[A]^2 - q[A][A^*] - r[A^*] \\ \frac{d[B]}{dt} &= \frac{d[C]}{dt} = r[A^*]\end{aligned}$$

Fizikalna interpretacija: A^* je **kratkoživ vmesni produkt** (intermediat). Njegova koncentracija je v vsakem trenutku zelo majhna, saj takoj, ko nastane, tudi razpade (bodisi nazaj v A ali naprej v B+C). Zato lahko predpostavimo, da se njegova koncentracija skozi čas praktično ne spreminja.

Aproksimacija stacionarnega stanja: Predpostavimo, da je hitrost spreminjanja koncentracije intermedjata enaka nič:

$$\frac{d[A^*]}{dt} = p[A]^2 - (q[A] + r)[A^*] \approx 0$$

Iz tega pogoja lahko izrazimo stacionarno koncentracijo intermedjata:

$$[A^*]_{ss} = \frac{p[A]^2}{q[A] + r}$$


To oceno sedaj vstavimo v enačbo za hitrost porabe reaktanta A:

$$\frac{d[A]}{dt} = -p[A]^2 + q[A] \left(\frac{p[A]^2}{q[A] + r} \right) = -p[A]^2 \left(1 - \frac{q[A]}{q[A] + r} \right) = -\frac{pr[A]^2}{q[A] + r}$$

S tem smo kompleksen sistem treh sklopljenih enačb reducirali na eno samo, enostavnejšo diferencialno enačbo za koncentracijo $[A]$. To enačbo lahko nato (numerično) integriramo.

Veljavnost približka: Kdaj je ta približek dober? Ko sta hitrostni konstanti za razpad intermedjata, q in r , veliko večji od hitrostne konstante za njegov nastanek, p . Pogoj $q/p = 1000$ nam zagotavlja, da je vsaj povratna reakcija v A zelo hitra, kar podpira veljavnost aproksimacije. Parameter $\epsilon = r/(q[A(0)])$ primerja hitrosti obeh razpadnih poti. Če je $\epsilon \ll 1$, večina A^* razpade nazaj v A. Če je $\epsilon \gg 1$, večina A^* razpade v produkta B in C.

Naloga 2: Reakcija $H_2 + Br_2$ Celotna reakcija $H_2 + Br_2 \rightleftharpoons 2HBr$ poteka preko verige radikalskih reakcij:



Sistem opišemo s petimi enačbami za koncentracije $u = [H_2], v = [Br_2], x = [HBr], y = [H], z = [Br]$:

$$\begin{aligned} \dot{u} &= -rzu + sxy \\ \dot{v} &= -pv + qz^2 - tyv \\ \dot{x} &= rzu - sxy + tyv \\ \dot{y} &= rzu - sxy - tyv \\ \dot{z} &= 2pv - 2qz^2 - rzu + sxy + tyv \end{aligned}$$

Fizikalna interpretacija: Radikali H in Br (y in z) so izjemno reaktivni in zato kratkoživi. Njihove koncentracije so zelo majhne in se hitro prilagajajo koncentracijam stabilnih molekul.


Aproksimacija stacionarnega stanja: Predpostavimo $\dot{y} \approx 0$ in $\dot{z} \approx 0$. To nam da dve algebrski enačbi, iz katerih izrazimo stacionarni koncentraciji radikalov:

$$[H]_{ss} = \frac{r[Br][H_2]}{s[HBr] + t[Br_2]}; \quad [Br]_{ss} = \sqrt{\frac{p}{q}[Br_2]}$$


Ko ti dve stacionarni koncentraciji vstavimo v enačbo za hitrost nastanka produkta, $\dot{x} = [HBr]$, po nekaj algebre dobimo izraz, ki je zelo podoben empirično izmerjeni formuli. To pokaže, da je predlagan mehanizem verjetno pravilen.

Naloga 3: Jodova ura Jodova ura je klasičen primer kemijske ure, kjer se po določenem času zgodi nenadna, vidna sprememba. Mehanizem temelji na dveh ključnih reakcijah:

1. **Počasna reakcija (proizvodnja joda):** Persulfatni ioni počasi oksidirajo jodidne ione v elementarni jod.



2. **Hitra reakcija (poraba joda):** Tiosulfatni ioni pa takoj in zelo hitro reducirajo nastali jod nazaj v jodidne ione.



Intuitivna razlaga mehanizma: Dokler je v raztopini prisoten tiosulfat ($\text{S}_2\text{O}_3^{2-}$), se ves jod, ki počasi nastaja v prvi reakciji, sproti in takoj porabi v drugi reakciji. Koncentracija joda $[\text{I}_2]$ je praktično nič. Ko pa ves tiosulfat porabimo, se druga reakcija ustavi. Jod, ki še vedno nastaja v prvi reakciji, se začne kopičiti v raztopini. To kopičenje povzroči nenadno spremembo barve (običajno z dodatkom škroba, ki z jodom tvori temno moder kompleks). Čas, ki preteče do spremembe barve, je odvisen od začetnih koncentracij reaktantov in nam omogoča merjenje hitrosti prve, počasne reakcije.

3 Modelska analiza 06.11.2025: Luščenje parametrov

V tem poglavju se bomo osredotočili na praktične metode določanja parametrov iz eksperimentalnih podatkov, znane tudi kot prilagajanje (angl. *fitting*) ali luščenje parametrov. Obravnavali bomo tako linearne kot nelinearne modele.

*

Naloga 1: Farmakološki odziv in Michaelis-Menten kinetika

V tej nalogi analiziramo odziv biološkega tkiva na različne koncentracije zdravilne učinkovine ali reagenta. Model opisuje vezavo reagenta X na receptorje Y v tkivu, kar sproži merljiv odziv.

Model 1a: Nasična kinetika in linearizacija

Osnovni model predpostavlja, da je odziv tkiva y odvisen od koncentracije reagenta x po naslednji enačbi:

$$y(x) = \frac{y_0 x}{x + a} \quad (24)$$

Ta oblika je v biokemiji in farmakologiji izjemno pogosta in je znana kot Michaelis-Mentenova kinetika.

- **Parameter y_0 :** Predstavlja **nasičeni odziv**. To je maksimalni možni odziv, ki ga lahko tkivo doseže, tudi če koncentracijo reagenta x povečamo v neskončnost. Takrat so vsi receptorji zasedeni.
- **Parameter a :** Predstavlja **disociacijsko konstanto** oziroma koncentracijo reagenta, pri kateri je odziv tkiva enak natanko polovici nasičenega odziva ($y(a) = y_0 a / (a + a) = y_0 / 2$).

Naš cilj je iz niza meritev $(x_i, y_i \pm \sigma_i)$ določiti najboljše oceni za parametra y_0 in a .

Linearizacija modela. Čeprav je model (24) nelinearen v spremenljivki x , ga lahko z algebrائيčno preureditvijo prevedemo v obliko, ki je **linearna v parametrih**. To storimo z inverzijo enačbe:

$$\frac{1}{y} = \frac{x + a}{y_0 x} = \frac{x}{y_0 x} + \frac{a}{y_0 x} = \frac{1}{y_0} + \frac{a}{y_0} \cdot \frac{1}{x} \quad (25)$$

Če sedaj vpeljemo nove spremenljivke $Y = 1/y$ in $X = 1/x$, in nove parametre $c_1 = 1/y_0$ in $c_2 = a/y_0$, vidimo, da ima enačba obliko premice: $Y = c_1 + c_2 X$. Ta postopek je znan kot Lineweaver-Burkova transformacija.

Transformacija merilnih napak. Ključna pomanjkljivost linearizacije je, da spremeni statistične lastnosti meritev. Če je bila napaka meritve y_i konstantna in enaka σ_y , moramo izračunati, kakšna je napaka transformirane količine $Y_i = 1/y_i$. Z uporabo formule za prenos napak za majhne napake dobimo:

$$\sigma_{Y_i} \approx \left| \frac{d(1/y)}{dy} \right|_{y=y_i} \sigma_y = \left| -\frac{1}{y_i^2} \right| \sigma_y = \frac{\sigma_y}{y_i^2}$$

Interpretacija: Vidimo, da transformirana napaka σ_{Y_i} ni več konstantna! Meritve z majhno vrednostjo y_i (ki ustrezajo majhnim koncentracijam x_i) imajo po transformaciji

bistveno večjo napako in s tem manjšo statistično težo pri prilagajanju. Ignoriranje tega dejstva lahko vodi do sistematično napačnih ocen parametrov.

Linearna metoda najmanjših kvadratov. Po linearizaciji imamo model oblike $f(x; \mathbf{c}) = \sum_{j=1}^M c_j \phi_j(x)$, kjer so $\phi_j(x)$ bazne funkcije, $\mathbf{c}$ pa vektor parametrov. V našem primeru sta $M = 2$, $\phi_1(X) = 1$, $\phi_2(X) = X$, in $\mathbf{c} = (c_1, c_2)$. Parametre določimo z minimizacijo funkcionala χ^2 :

$$\chi^2(\mathbf{c}) = \sum_{i=1}^N \left(\frac{Y_i - f(X_i; \mathbf{c})}{\sigma_{Y_i}} \right)^2$$

Z odvajanjem $\frac{\partial \chi^2}{\partial c_k} = 0$ za $k = 1, \dots, M$ pridemo do sistema M linearnih enačb, znanih kot **normalne enačbe**:

$$\mathbf{A}\mathbf{c} = \mathbf{b}$$

kjer so elementi matrike $\mathbf{A}$ in vektorja $\mathbf{b}$ podani z:

$$A_{kj} = \sum_{i=1}^N \frac{\phi_k(X_i) \phi_j(X_i)}{\sigma_{Y_i}^2}, \quad b_k = \sum_{i=1}^N \frac{Y_i \phi_k(X_i)}{\sigma_{Y_i}^2}$$

Za naš konkretni primer ($Y_i = 1/y_i$, $X_i = 1/x_i$, $\sigma_{Y_i} = \sigma_y/y_i^2$) sta bazni funkciji $\phi_1 = 1$, $\phi_2 = 1/x$. Elementi matrike $\mathbf{A}$ so:

$$\begin{aligned} A_{11} &= \sum_{i=1}^N \frac{1^2}{(\sigma_y/y_i^2)^2} = \frac{1}{\sigma_y^2} \sum_{i=1}^N y_i^4 \\ A_{12} &= A_{21} = \sum_{i=1}^N \frac{1 \cdot (1/x_i)}{(\sigma_y/y_i^2)^2} = \frac{1}{\sigma_y^2} \sum_{i=1}^N \frac{y_i^4}{x_i} \\ A_{22} &= \sum_{i=1}^N \frac{(1/x_i)^2}{(\sigma_y/y_i^2)^2} = \frac{1}{\sigma_y^2} \sum_{i=1}^N \frac{y_i^4}{x_i^2} \end{aligned}$$

Ko izračunamo te vsote iz podatkov, rešimo sistem $\mathbf{A}\mathbf{c} = \mathbf{b}$ in dobimo ocenjena parametra $\hat{c}_1$ in $\hat{c}_2$. Iz teh enostavno izračunamo originalna parametra: $\hat{y}_0 = 1/\hat{c}_1$ in $\hat{a} = \hat{c}_2/\hat{c}_1$.

Kovariančna matrika parametrov $\mathbf{c}$ je enaka inverzu matrike $\mathbf{A}$, $\text{Cov}(\mathbf{c}) = \mathbf{A}^{-1}$. Diagonalni elementi te matrike so variance (kvadrati negotovosti) ocenjenih parametrov: $\sigma^2(c_1) = (\mathbf{A}^{-1})_{11}$, $\sigma^2(c_2) = (\mathbf{A}^{-1})_{22}$.

Model 1b: Nelinearna regresija in razširjeni model

Linearizacija je sicer elegantna metoda, vendar ima pomanjkljivosti, predvsem zaradi transformacije napak in potencialne vpeljave sistematskih napak v ocene parametrov. Sodobnejši in bolj robusten pristop je, da se prilagajanja lotimo neposredno na originalnem, nelinearnem modelu.

Razširjeni model, znan kot Hillova enačba, vpelje dodaten parameter p , ki opisuje kooperativnost vezave:

$$y(x) = \frac{y_0 x^p}{a^p + x^p} \quad (26)$$

- **Parameter p :** Imenovan Hillov koeficient.

– Če je $p = 1$, dobimo nazaj originalno Michaelis-Menten enačbo.

- Če je $p > 1$, govorimo o **pozitivni kooperativnosti**. To pomeni, da vezava ene molekule reagenta na receptor poveča afiniteto (verjetnost za vezavo) naslednjih molekul. Graf odziva je bolj strm, v obliki sigmoide.
- Če je $p < 1$, govorimo o **negativni kooperativnosti**, kjer vezava ene molekule zmanjša afiniteto za naslednje.

Naš cilj je določiti najboljše ocene za vse tri parametre (y_0, a, p) in statistično oceniti, ali je vpeljava dodatnega parametra p sploh upravičena.

Nelinearna metoda najmanjših kvadratov. Ker modela ne moremo linearizirati, moramo neposredno minimizirati funkcional χ^2 kot funkcijo treh parametrov:

$$\chi^2(y_0, a, p) = \sum_{i=1}^N \left(\frac{y_i - \frac{y_0 x_i^p}{a^p + x_i^p}}{\sigma_i} \right)^2 \quad (27)$$

kjer so y_i izmerjene vrednosti odziva z napako σ_i . Iskanje minimuma te funkcije v večdimenzionalnem prostoru parametrov je netrivialen problem, ki ga rešujemo z iterativnimi numeričnimi metodami.

Levenberg-Marquardtov algoritem. To je “delovni konj” nelinearnega prilagajanja. Gre za robusten algoritem, ki inteligentno združuje dve strategiji iskanja minimuma:

1. **Metoda najstrmejšega spusta (Gradient Descent):** Ko smo daleč od prave rešitve (minimuma), je najbolj učinkovito, da se premikamo v smeri, kjer χ^2 najhitreje pada. Ta smer je nasprotna smeri gradienta $-\nabla\chi^2$. Korak v tej smeri je $\mathbf{a}_{k+1} = \mathbf{a}_k - \gamma \nabla\chi^2(\mathbf{a}_k)$. Ta metoda zanesljivo zmanjšuje χ^2 , vendar je lahko blizu minimuma zelo počasna.
2. **Gauss-Newtonova metoda:** Ko smo že blizu minimuma, lahko funkcijo χ^2 lokalno aproksimiramo s kvadratno formo (paraboloidom). Minimum te aproksimacije najdemo v enem koraku z uporabo drugih odvodov (Hessianove matrike $\mathbf{H}$). Korak je $\mathbf{a}_{k+1} = \mathbf{a}_k - \mathbf{H}^{-1} \nabla\chi^2(\mathbf{a}_k)$. Ta metoda je blizu rešitve izjemno hitra, vendar lahko daleč od nje divergira.

Levenberg-Marquardtov algoritem v vsakem koraku izračuna nov približek za parametre in prilagaja parameter λ , ki neprestano prehaja med obema metodama. Za velike λ se obnaša kot metoda najstrmejšega spusta, za majhne λ pa kot Gauss-Newtonova metoda.

Praktični napotki za izvedbo.

- **Začetni približki:** Nelinearni algoritmi potrebujejo začetne vrednosti za parametre. Zelo dobra strategija je, da za začetne vrednosti y_0 in a vzamemo rezultate, ki smo jih dobili z linearizacijo v prejšnjem koraku (model 1a), za parameter p pa začnemo z vrednostjo $p = 1$.

- **Izračun odvodov:** Algoritem potrebuje parcialne odvode funkcije $y(x; y_0, a, p)$ po vseh parametrih. Ti so:

$$\begin{aligned}\frac{\partial y}{\partial y_0} &= \frac{x^p}{a^p + x^p} \\ \frac{\partial y}{\partial a} &= -y_0 x^p \frac{p a^{p-1}}{(a^p + x^p)^2} \\ \frac{\partial y}{\partial p} &= \frac{y_0 (a^p + x^p) (x^p \ln x) - y_0 x^p (a^p \ln a + x^p \ln x)}{(a^p + x^p)^2} = \frac{y_0 a^p x^p \ln(x/a)}{(a^p + x^p)^2}\end{aligned}$$

- **Analiza rezultatov:** Po konvergenci algoritma vrne optimalne vrednosti parametrov $(\hat{y}_0, \hat{a}, \hat{p})$, njihove negotovosti (standardne napake) in celotno kovariančno matriko. Veliki izvendiagonalni elementi v (normalizirani) kovariančni matriki pomenijo močno korelacijo med parametri, kar lahko kaže na to, da je model preveč zapleten za dane podatke. Prav tako dobimo minimalno vrednost χ_{min}^2 .

Statistično upravičenost vpeljave dodatnega parametra p preverimo tako, da primerjamo χ_{min}^2 za model z dvema parametroma in model s tremi parametri. Če se χ_{red}^2 bistveno ne zmanjša, potem dodaten parameter ni upravičen in po principu varčnosti ostanemo pri enostavnejšem modelu.

*

Naloga 2: Razdelčni modeli in farmakokinetika

V tej nalogi se srečamo s farmakokinetiko, vedo, ki preučuje časovno spreminjanje koncentracije zdravila ali druge snovi (imenovane sledilec, angl. *tracer*) v organizmu. Telo si poenostavljeno predstavljamo kot sistem enega ali več razdelkov (angl. *compartments*).

Intuitivna razlaga razdelka: Razdelek ne predstavlja nujno specifičnega organa, ampak je lahko kateri koli volumen (npr. celotna krvna plazma, zunajcelična tekočina), znotraj katerega se sledilec hitro in homogeno porazdeli. Sistem opazujemo tako, da merimo, kako se koncentracija sledilca, ki ga vbrizgamo v sistem, s časom zmanjšuje zaradi presnove ali izločanja (npr. skozi ledvice).

Enorazdelčni model

Najenostavnejši model si telo predstavlja kot en sam, dobro premešan razdelek z volumenom V . Predpostavimo, da se sledilec iz tega razdelka izloča s hitrostjo, ki je sorazmerna s trenutno koncentracijo $c(t)$. Ta proces je analogija radioaktivnega razpada in ga opisuje diferencialna enačba prvega reda:

$$\frac{dc(t)}{dt} = -\lambda c(t)$$

kjer je λ konstanta hitrosti izločanja. Rešitev te enačbe je monoeksponencialno padanje:

$$c(t) = c_0 e^{-\lambda t} \quad (28)$$

kjer je c_0 koncentracija ob času $t = 0$. Podatke iz datoteke 'ledvice.dat' lahko poskusimo prilagoditi temu modelu. Ker je model nelinearen, lahko uporabimo metodo nelinearnih

najmanjših kvadratov (npr. Levenberg-Marquardt), ali pa ga lineariziramo z logaritmiranjem:

$$\ln(c(t)) = \ln(c_0) - \lambda t$$

Če narišemo graf $\ln(c)$ v odvisnosti od t , bi morali dobiti premico. Smerni koeficient premice je $-\lambda$, presečišče z y-osjo pa $\ln(c_0)$. Pri tem se moramo zavedati, da logaritmiranje nelinearno transformira napake, kar lahko vpliva na rezultate linearne regresije.

Razširitve osnovnega modela

Pogosto se izkaže, da enorazdelčni model ne opisuje podatkov dovolj dobro. Krivulja koncentracije s časom morda ne sledi enostavnemu eksponentnemu padanju. Zato uvedemo kompleksnejše modele.

Model z ozadjem. Včasih merilna naprava zazna konstanten signal tudi v odsotnosti sledilca, ali pa v telesu obstaja naravna, endogena raven podobne snovi. To modeliramo z dodajanjem aditivne konstante (ozadja) B :

$$c(t) = c_0 e^{-\lambda t} + B \quad (29)$$

Ta model ima tri parametre (c_0, λ, B) in ga ni mogoče linearizirati. Za določitev parametrov je nujna uporaba nelinearne regresije.

Dvorazdelčni model. Bolj realističen model si organizem predstavlja kot sestavljen iz dveh razdelkov:

- **Centralni razdelek:** Običajno predstavlja kri in dobro prekrvavljena tkiva, kamor se sledilec vbrizga in hitro porazdeli.
- **Periferni razdelek:** Predstavlja slabše prekrvavljena tkiva (npr. mišice, maščevje), kamor sledilec prehaja počasneje.

Po vbrizgu v centralni razdelek koncentracija sprva hitro pada zaradi dveh procesov: hitre porazdelitve v periferni razdelek in izločanja iz telesa. Kasneje, ko se vzpostavi ravnovesje med razdelkoma, koncentracija pada počasneje, predvsem zaradi izločanja. Takšno obnašanje opišemo z vsoto dveh eksponentnih funkcij:

$$c(t) = Ae^{-\lambda_1 t} + Be^{-\lambda_2 t} \quad (30)$$

- **Hitra komponenta (λ_1):** Povezana je predvsem s hitro porazdelitvijo med razdelkoma in prevladuje na začetku.
- **Počasna komponenta (λ_2):** Povezana je predvsem z izločanjem iz celotnega sistema in prevladuje kasneje.

Ta model ima štiri parametre ($A, B, \lambda_1, \lambda_2$) in je primer nelinearnega modela. Začetne približke za iskanje rešitve je včasih težko uganiti. Namig v nalogi, da sta konstanti v razmerju 1:10 (npr. $\lambda_1 \approx 10\lambda_2$), je pri tem v veliko pomoč.

Izbira modela in princip varčnosti

Soočeni smo z več možnimi modeli (enorazdelčni, z ozadjem, dvorazdelčni, morda celo $\exp(-\lambda\sqrt{t})$). Kateri je "pravi"? **Princip varčnosti (parsimony principle ali Ockhama britev):** Med modeli, ki zadovoljivo pojasnijo podatke, izberemo najenostavnejšega – tistega z najmanjšim številom prostih parametrov.

Kako statistično upravičimo dodaten parameter? Recimo, da primerjamo enorazdelčni model (M_1 z m_1 parametri) in model z ozadjem (M_2 z $m_2 = m_1 + 1$ parametri).

1. Prilagodimo oba modela podatkom in dobimo minimalni vrednosti χ_1^2 in χ_2^2 . Vrednost χ_2^2 bo nujno manjša ali enaka χ_1^2 , saj ima model več prostosti.
2. Vprašanje je, ali je zmanjšanje $\Delta\chi^2 = \chi_1^2 - \chi_2^2$ "dovolj veliko", da upraviči dodaten parameter.
3. Za to uporabimo **F-test**. Testna statistika je:

$$F = \frac{(\chi_1^2 - \chi_2^2)/(m_2 - m_1)}{\chi_2^2/(N - m_2)}$$

kjer je N število podatkovnih točk. Ta statistika je porazdeljena po Fisher-Snedecorjevi porazdelitvi $F(m_2 - m_1, N - m_2)$.

4. Izračunamo vrednost F in jo primerjamo s kritično vrednostjo pri izbrani stopnji tveganja (npr. $\alpha = 0.05$). Če je izračunana vrednost F večja od kritične, potem je zmanjšanje statistično značilno in kompleksnejši model M_2 je upravičen. V nasprotnem primeru ostanemo pri enostavnejšem modelu M_1 .

S tem postopkom lahko sistematično primerjamo vse predlagane modele in izberemo tistega, ki nudi najboljši kompromis med kompleksnostjo in kvaliteto prilagoditve podatkom.

*

Naloga 3: Kalibracija magnetnega spektrometra

Ta naloga nas postavi v vlogo eksperimentalnega fizika, ki mora umeriti (kalibrirati) kompleksno napravo – magnetni spektrometer. Spektrometer ukrivi poti nabitih delcev, kar nam omogoča določanje njihove energije in gibalne količine.

Fizikalni problem: Meritve se opravijo v detektorski ravnini, ki jo imenujemo goriščna ravnina (angl. *focal plane*, od tod okrajšava 'fp'). Iz izmerjenih količin v tej ravnini – npr. položaja delca x_{fp} in njegovega kota θ_{fp} – želimo rekonstruirati kinematične količine delca ob njegovem izvoru, torej na tarči (angl. *target*, od tod 'tg'), kot je na primer njegov sipni kot θ_{tg} .

Cilj: Naš cilj je najti matematično preslikavo (model), ki iz vhodnih meritev (x_{fp}, θ_{fp}) kar se da natančno napove pravo vrednost na tarči θ_{tg} . Ker točne fizikalne enačbe za prehod skozi spektrometer niso znane ali so preveč zapletene, bomo model zgradili empirično, s prilagajanjem na znane kalibracijske podatke.

Postavitev modela in linearizacija

Ker ne poznamo prave funkcijske oblike preslikave, je smiselno, da jo poskusimo aproksimirati s polinomom v spremenljivkah x_{fp} in θ_{fp} . S tem gradimo “varčen” model – tak, ki z najmanjšim možnim številom parametrov dobro opiše podatke. Eden od možnih modelov, predlagan v zapiskih, je:

$$\theta_{tg}(x_{fp}, \theta_{fp}) = \underbrace{(a_0 + a_1 x_{fp} + a_2 x_{fp}^2)}_{\text{odvisnost od položaja}} + \underbrace{(a_3 + a_4 x_{fp} + a_5 x_{fp}^2) \theta_{fp}}_{\text{mešani členi, odvisni od kota}} \quad (31)$$

To je model s $M = 6$ neznanimi kalibracijskimi parametri $a_0, \dots, a_5$. Ključna lastnost tega modela je, da je **linearen v parametrih** a_j . To pomeni, da lahko za njihovo določitev uporabimo (relativno) enostavno linearno algebro, čeprav je model sam po sebi nelinearna funkcija meritev x_{fp} in θ_{fp} .

Matrična oblika in reševanje s singularnim razcepom (SVD)

Za vsako od N kalibracijskih meritev lahko zapišemo eno enačbo oblike (31). Celoten sistem N enačb z M neznankami lahko zapišemo v zgoščeni matrični obliki:

$$\mathbf{A}\mathbf{a} = \mathbf{b}$$

kjer je:

- $\mathbf{b}$ je vektor znanih rezultatov (meritev na tarči) dimenzije $N \times 1$: $\mathbf{b} = (\theta_{tg,1}, \theta_{tg,2}, \dots, \theta_{tg,N})^T$.
- $\mathbf{a}$ je vektor neznanih parametrov, ki jih iščemo, dimenzije $M \times 1$: $\mathbf{a} = (a_0, a_1, \dots, a_5)^T$.
- $\mathbf{A}$ je **načrtovalna matrika** (design matrix) dimenzije $N \times M$. Vsaka vrstica matrike ustreza eni meritvi, vsak stolpec pa eni od baznih funkcij v našem modelu. Za model (31) je i -ta vrstica matrike $\mathbf{A}$:

$$\mathbf{A}_i = (1 \quad x_{fp,i} \quad x_{fp,i}^2 \quad \theta_{fp,i} \quad x_{fp,i}\theta_{fp,i} \quad x_{fp,i}^2\theta_{fp,i})$$

Ker imamo veliko več meritev kot parametrov ($N \gg M$), je ta sistem **predoločen**. To pomeni, da ne obstaja natančna rešitev $\mathbf{a}$, ki bi popolnoma zadostila vsem enačbam hkrati (zaradi merilnih napak). Namesto tega iščemo rešitev, ki minimizira vsoto kvadratov ostankov, torej rešitev po metodi najmanjših kvadratov, ki minimizira $\|\mathbf{A}\mathbf{a} - \mathbf{b}\|^2$.

Singularni razcep (SVD). Čeprav bi lahko problem rešili z normalnimi enačbami ($\mathbf{A}^T \mathbf{A} \mathbf{a} = \mathbf{A}^T \mathbf{b}$), je ta pristop numerično nestabilen, če so stolpci matrike $\mathbf{A}$ med seboj skoraj linearno odvisni. Veliko bolj robustna in elegantna metoda je **singularni razcep (SVD)**. SVD razcepi poljubno matriko $\mathbf{A}$ v produkt treh matrik:

$$\mathbf{A} = \mathbf{U}\mathbf{W}\mathbf{V}^T \quad (32)$$

- $\mathbf{U}$ in $\mathbf{V}$ sta ortogonalni matriki.
- $\mathbf{W}$ je diagonalna matrika, ki na diagonalni vsebuje nenegativne **singularne vrednosti** w_j .

Rešitev po metodi najmanjših kvadratov je s pomočjo SVD podana eksplicitno:

$$\hat{\mathbf{a}} = \mathbf{V} \cdot [\text{diag}(1/w_j)] \cdot \mathbf{U}^T \cdot \mathbf{b}$$

S pomočjo SVD lahko izračunamo tudi celotno kovariančno matriko za parametre:

$$\text{Cov}(a_j, a_k) = \sum_{i=1}^M \frac{V_{ji} V_{ki}}{w_i^2}$$

Izbira varčnega modela s pomočjo SVD. Lepota SVD pristopa se pokaže pri gradnji varčnega modela. Velikost singularnih vrednosti w_j nam pove, kako “pomembne” so določene kombinacije baznih funkcij.

- Če je katera od singularnih vrednosti w_j zelo majhna (blizu nič), to pomeni, da je ustrezna kombinacija stolpcev v matriki $\mathbf{A}$ skoraj linearno odvisna. To pomeni, da podatki ne vsebujejo dovolj informacij za ločeno določitev vseh parametrov v modelu – model je preveč zapleten. Poskus reševanja takega sistema bi vodil do ogromnih negotovosti v parametrih.
- **Rešitev:** Te majhne singularne vrednosti preprosto “izničimo” tako, da v rešitvi postavimo $1/w_j = 0$. S tem iz rešitve odstranimo slabo določene kombinacije in dobimo stabilno, robustno oceno za parametre, ki jih podatki dejansko podpirajo. Ta postopek je osnova za izbiro relevantnih členov in gradnjo varčnega modela. Z analizo, katere bazne funkcije so povezane z majhnimi singularnimi vrednostmi, lahko ugotovimo, katere člene v polinomu je smiselno opustiti.

S primerjavo χ_{red}^2 za različno zapletene modele (z različnim številom uporabljenih singularnih vrednosti) lahko najdemo optimalen model, ki najbolje opiše podatke brez nepotrebnih parametrov.

4 Kalmanov filter

Kalmanov filter (KF) je rekurzivni algoritem za ocenjevanje notranjega *stanja* dinamičnega sistema na podlagi šumnih meritev in znanih dinamičnih zakonov. Uporablja se pogosto v robotiki, navigaciji, avtomatizaciji in drugih področjih, kjer je potrebno združevati informacije iz različnih virov v prisotnosti negotovosti.

*

Osnovna ideja

Glavna ideja Kalmanovega filtra je **kombiniranje dveh virov informacij**:

- *napovedi* stanja na podlagi preteklega stanja in modela dinamike sistema,
- *meritev* iz senzorjev (ki so obremenjene z naključnim šumom).

Kalmanov filter izračuna *najbolj verjetno* (optimalno v smislu minimalne srednje kvadratne napake) oceno stanja, pri čemer upošteva tudi **korelacije med spremenljivkami** (npr. med položajem in hitrostjo).

Opomba 4.1. *Korelacije med spremenljivkami stanja so ključne. Če poznamo hitrost, to vpliva na našo negotovost o položaju — in obratno. To zajamemo z kovariančno matriko.*

*

Matematični opis sistema

Stanje sistema v času $t_n = n\Delta t$ opišemo z vektorjem

$$\mathbf{x}_n = \begin{bmatrix} \mathbf{p}_n \\ \mathbf{v}_n \\ \omega_n \\ \vdots \end{bmatrix},$$

kjer so:

- $\mathbf{p}_n$ — položaj,
- $\mathbf{v}_n$ — hitrost,
- ω_n — kotna hitrost koles (ali drugi notranji parametri).

Model napovedi (dinamika sistema)

V najpreprostejši kinematični obliki (brez zunanjih vhodov) predpostavimo:

$$\mathbf{p}_{n+1} = \mathbf{p}_n + \mathbf{v}_n \Delta t, \quad (33)$$

$$\mathbf{v}_{n+1} = \mathbf{v}_n. \quad (34)$$

To lahko zapišemo v matrični obliki kot

$$\mathbf{x}_{n+1}^- = \mathbf{F}_n \mathbf{x}_n^+,$$

kjer je $\mathbf{x}_n^+$ *posterior* ocena stanja v trenutku n (po vključitvi meritev), $\mathbf{x}_{n+1}^-$ pa *prior* ocena (napoved pred novo meritvijo).

Za zgornji primer je matrika prehoda:

$$\mathbf{F}_n = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}.$$

Opomba 4.2. V tem zapisu sledimo oznakam iz predavanj: $\mathbf{x}^-$ pomeni napoved (*prior*), $\mathbf{x}^+$ pa posodobljeno stanje (*posterior*). Prof. Likar uporablja oznake $\tilde{\mathbf{x}}$ in $\hat{\mathbf{x}}$ — v tem dokumentu uporabljamo standardnejše $\mathbf{x}^-$, $\mathbf{x}^+$.

Napoved kovariančne matrike

Negotovost stanja opisujemo s kovariančno matriko $\mathbf{P}_n$. Če $\mathbf{P}_n^+$ predstavlja negotovost *po* posodobitvi, potem je napovedana kovarianca:

$$\mathbf{P}_{n+1}^- = \mathbf{F}_n \mathbf{P}_n^+ \mathbf{F}_n^\top.$$

Če v model vključimo *procesni šum* (npr. motnje, netočne predpostavke o dinamiki), dodamo še člen:

$$\mathbf{x}_{n+1}^- = \mathbf{F}_n \mathbf{x}_n^+ + \mathbf{B}_n \mathbf{u}_n + \mathbf{\Gamma}_n \mathbf{w}_n,$$

kjer je:

- $\mathbf{u}_n$ — znani vhod (npr. podatek o pospešku),
- $\mathbf{B}_n$ — matrika vhodov,
- $\mathbf{w}_n$ — naključni vektor procesnega šuma z $\langle \mathbf{w}_n \rangle = 0$ in $\langle \mathbf{w}_n \mathbf{w}_m^\top \rangle = \mathbf{Q}_n \delta_{nm}$,
- $\mathbf{\Gamma}_n$ — matrika, ki preslika šum v prostor stanja.

Tedaj se kovariančna matrika posodobi kot:

$$\mathbf{P}_{n+1}^- = \mathbf{F}_n \mathbf{P}_n^+ \mathbf{F}_n^\top + \mathbf{\Gamma}_n \mathbf{Q}_n \mathbf{\Gamma}_n^\top.$$

Primer 4.1 (Napoved z znanim pospeškom). *Recimo, da senzor pospeška meri a_n . Za enodimenzionalen sistem:*

$$\begin{aligned} p_{n+1} &= p_n + v_n \Delta t + \frac{1}{2} a_n (\Delta t)^2, \\ v_{n+1} &= v_n + a_n \Delta t. \end{aligned}$$

To zapišemo kot:

$$\mathbf{x}_{n+1}^- = \mathbf{F} \mathbf{x}_n^+ + \mathbf{B} u_n, \quad \mathbf{F} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} \frac{1}{2} (\Delta t)^2 \\ \Delta t \end{bmatrix}, \quad u_n = a_n.$$

*

Model meritve

Meritev v času $n + 1$ je povezana s stanjem prek:

$$\mathbf{z}_{n+1} = \mathbf{H}_{n+1} \mathbf{x}_{n+1} + \mathbf{r}_{n+1},$$

kjer je:

- $\mathbf{z}_{n+1}$ — vektor meritev (npr. GPS položaj),
- $\mathbf{H}_{n+1}$ — matrika opazovanja (npr. izbira, kateri del stanja merimo),
- $\mathbf{r}_{n+1}$ — senzorski šum z $\langle \mathbf{r}_{n+1} \mathbf{r}_m^\top \rangle = \mathbf{R}_{n+1} \delta_{n+1,m}$.

*

Posodobitev s Kalmanovim ojačenjem

Algoritem združi napoved in meritev s pomočjo *Kalmanovega ojačenja* $\mathbf{K}_{n+1}$:

1. **Izračun Kalmanovega ojačenja:**

$$\mathbf{K}_{n+1} = \mathbf{P}_{n+1}^- \mathbf{H}_{n+1}^\top (\mathbf{R}_{n+1} + \mathbf{H}_{n+1} \mathbf{P}_{n+1}^- \mathbf{H}_{n+1}^\top)^{-1}.$$

2. **Posodobitev stanja:**

$$\mathbf{x}_{n+1}^+ = \mathbf{x}_{n+1}^- + \mathbf{K}_{n+1} (\mathbf{z}_{n+1} - \mathbf{H}_{n+1} \mathbf{x}_{n+1}^-).$$

Izraz v oklepaju je *novost* (angl. *innovation*) — razlika med dejansko meritvijo in tisto, ki jo napovedujemo.

3. **Posodobitev kovariančne matrike:**

$$\mathbf{P}_{n+1}^+ = (\mathbf{I} - \mathbf{K}_{n+1} \mathbf{H}_{n+1}) \mathbf{P}_{n+1}^-.$$

Opomba 4.3. *Postopek poteka v zanki: napoved $\rightarrow$ posodobitev $\rightarrow$ napoved $\rightarrow \dots$ za vsak časovni korak $n = 0, 1, 2, \dots$*

*

Začetni pogoji

Za zagon filtra potrebujemo:

- začetno oceno stanja $\mathbf{x}_0^+$ (npr. iz znanih začetnih pogojev),
- začetno kovariančno matriko $\mathbf{P}_0^+$, ki izraža našo začetno negotovost (»začetno nevednost«).

*

Posebni primeri in razširitve

- **Manjkajoče meritve:** Če v določenem koraku ni meritev, lahko postavimo $\mathbf{z}_n = \mathbf{0}$ in ustrezno prilagodimo $\mathbf{H}_n$ in $\mathbf{R}_n$ — v praksi pa pogosteje preskočimo korak posodobitve in uporabimo le napoved.
- **Samo pospeški in lokacija:** Če merimo le pospeške in občasno lokacijo (brez direktnih meritev hitrosti), Kalmanov filter kljub temu omogoča oceno hitrosti, ker jo *dedukcijo* iz pospeškov in posodobitev s položajem.
- **Nelinearni sistemi:** Če so odvisnosti nelinearne (npr. pri raketnem pogonu), uporabimo *razširjeni Kalmanov filter* (*Extended Kalman Filter*, EKF), kjer lineariziramo dinamiko okoli trenutne ocene.

Opomba 4.4. *Vse enačbe v tem razdelku predpostavljajo **linearnost** sistema. To je osnovna predpostavka klasičnega Kalmanovega filtra.*

5 Osnovno znanje za linearno napoved

Preden se lotimo avtoregresijskih (AR) modelov in linearne napovedi, si predstavljajmo osnovne pojme iz verjetnosti, signalov in kompleksne analize, ki so nujni za razumevanje tega poglavja. Ta razdelek služi kot *most* med osnovno fiziko/analizo in naprednejšo modelno analizo.

*

Diskretni signali in časovne vrste

V fiziki pogosto merimo količine, ki se spreminjajo s časom: temperatura, položaj, jakost sevanja itd. Če meritve opravimo v **rednih časovnih intervalih** Δt , dobimo *diskretni signal*:

$$S_n = S(t_n), \quad t_n = n\Delta t, \quad n = 0, 1, 2, \dots, N-1.$$

Takemu zaporedju pravimo tudi **časovna vrsta**. V nadaljevanju bomo privzeli, da je $\Delta t = 1$ (brez izgube splošnosti — lahko vedno preštejemo čas v enotah Δt).

Opomba 5.1. *Diskretni signali so osnova vseh digitalnih meritev: osciloskopi, senzorji, sateliti, itd. Namesto zvezne funkcije $S(t)$ imamo torej vektor $(S_0, S_1, \dots, S_{N-1})$.*

*

Naključni signali in stacionarnost

V praksi so meritve pogosto obremenjene z **naključnim šumom**. Zato obravnavamo S_n kot *naključni proces* — vsaka vrednost S_n je naključna spremenljivka.

Definicija 5.1 (Stacionarnost). *Naključni proces S_n je **stacionaren v širšem smislu**, če:*

1. *Njegovo povprečje je konstantno: $\mu = \mathbb{E}[S_n] = \text{konst.}$,*
2. *Njegova avtokovarianca $\mathbb{E}[(S_n - \mu)(S_{n+\tau} - \mu)]$ je odvisna le od zamika τ , ne od časa n .*

Opomba 5.2. *Večina metod linearne napovedi (vključno z AR modeli) zahteva stacionarnost. Če signal vsebuje trend (npr. naraščajoča koncentracija CO_2), ga moramo odtrenditi, preden uporabimo AR analizo.*

*

Avtokorelacijska funkcija (ACF)

Za stacionaren signal definiramo **avtokorelacijsko funkcijo** (ACF):

$$R(\tau) = \mathbb{E}[S_n S_{n-\tau}].$$

V praksi imamo le končno dolg signal, zato ACF *ocenimo*:

$$\hat{R}(\tau) = \frac{1}{N-\tau} \sum_{n=\tau}^{N-1} S_n S_{n-\tau}, \quad \tau = 0, 1, \dots, p. \quad (35)$$

Primer 5.1 (ACF za sinusoido). Naj bo $S_n = \cos(\omega_0 n)$. Tedaj velja (za dolg signal):

$$R(\tau) \approx \frac{1}{2} \cos(\omega_0 \tau).$$

ACF ohranja informacijo o periodičnosti signala, a ne o njegovi fazi.

*

Osnovna verjetnost: pričakovanje in variance

Za naključni signal S_n so ključni naslednji pojmi:

- **Pričakovana vrednost (povprečje):** $\mu = \mathbb{E}[S_n] = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=0}^{N-1} S_n$,
- **Varianca:** $\sigma^2 = \mathbb{E}[(S_n - \mu)^2] = R(0) - \mu^2$,
- Za $\mu = 0$ (brez izrastka): $\sigma^2 = R(0)$.

Vse vrednosti $R(\tau)$ so simetrične: $R(-\tau) = R(\tau)$.

*

Linearni diferencialni sistemi

Veliko fizičnih sistemov lahko opišemo z **linearnimi diferencialnimi enačbami**. Najpreprostejši primer:

$$S_n = aS_{n-1} + bS_{n-2} + \dots$$

To je *homogena linearna rekurzija*. Če dodamo vhodni signal u_n , dobimo:

$$S_n = - \sum_{k=1}^p a_k S_{n-k} + G u_n.$$

Točno takšno obliko uporabljamo v AR modelih.

Opomba 5.3. Tak sistem je popolnoma določen z koeficienti a_k in začetnimi pogoji $S_0, S_1, \dots, S_{p-1}$.

*

Kompleksna števila in enotska krožnica

AR modeli uporabljajo *Z-transformacijo*, ki temelji na kompleksnih številih. Povzemimo osnovno:

Vsako kompleksno število zapišemo v polarni obliki:

$$z = r e^{i\theta}, \quad r = |z|, \quad \theta = \arg(z).$$

- Če $r = 1$, leži z na **enotski krožnici**.
- **Konjugat:** $z^* = r e^{-i\theta}$.

Stabilnost AR filtra je odvisna od tega, ali so *poli* z_k znotraj enotske krožnice ($|z_k| < 1$).

Primer 5.2 (Enostaven pol). Naj bo karakteristični polinom $1 - 0.8z^{-1} = 0$. Rešitev: $z = 0.8$. Ker je $|z| = 0.8 < 1$, je sistem stabilen.

*

Minimizacija in metodo najmanjših kvadratov

AR koeficiente določamo tako, da *minimiziramo napako napovedi*. Napaka za korak n :

$$e_n = S_n + \sum_{k=1}^p a_k S_{n-k}.$$

Ciljna funkcija:

$$\Sigma = \mathbb{E}[e_n^2].$$

Da bi našli minimum, uporabimo **prvi odvod**:

$$\frac{\partial \Sigma}{\partial a_k} = 0, \quad \forall k = 1, \dots, p.$$

To vodi do sistema linearnih enačb (Yule-Walkerjevih).

Opomba 5.4. *To je diskretna različica metode najmanjših kvadratov, ki jo uporabljamo že pri prileganju premic ali krivulj podatkom.*

*

Spektralna vsebina signala

Vsak stacionaren signal lahko (v smislu povprečja) razstavimo na sinusne komponente različnih frekvenc ω . Kako “močno” je v signalu prisotna določena frekvenca, nam pove **spektralna gostota moči** $P(\omega)$.

Klasična metoda: *Fourierova transformacija*. Naprednejša metoda: *avtoregresijski model* $\rightarrow$ MESE.

Opomba 5.5. *Fourierova metoda zahteva dolge signale za dobro ločljivost. AR modeli omogočajo visoko ločljivost že pri kratkih signalih, če je signal dobro opisan z rekurzijo.*

Opomba 5.6 (Kako naprej?). *Ko obvladaš to poglavje, si pripravljen za:*

- *Z-transformacijo,*
- *Yule-Walkerjeve enačbe,*
- *MESE spektralno analizo.*

6 Linearna napoved in avtoregresijski modeli

*

Signal in linearna napoved

V okviru modelne analize pogosto obravnavamo *časovne vrste* — signale, zbrane v rednih časovnih intervalih:

$$S_n = S(t_n), \quad t_n = n\Delta t, \quad n = 0, 1, 2, \dots$$

Linearna napoved (linear prediction, LP) temelji na predpostavki, da lahko trenutno vrednost signala izrazimo kot linearno kombinacijo preteklih vrednosti in vhodov:

$$S_n = - \sum_{k=1}^p a_k S_{n-k} + G \sum_{l=0}^q b_l u_{n-l}, \quad (36)$$

kjer je:

- p — *red* avtoregresijskega dela,
- q — *red* delu z vhodi (moving average),
- a_k, b_l — koeficienti modela,
- G — ojačenje (gain),
- u_n — znani vhodni signal (lahko tudi $u_n = \delta_{n0}$, če obravnavamo odziv sistema),
- po konvenciji $b_0 = 1$.

Trije osnovni tipi modelov izhajajo iz izbire koeficientov:

- **MA (moving average)**: $a_k = 0$ za vse $k \rightarrow$ model le iz vhodov,
- **AR (autoregressive)**: $b_l = 0$ za $l \geq 1$, $b_0 = 1 \rightarrow$ model le iz preteklih izhodov,
- **ARMA**: kombinacija obeh.

V tem razdelku se bomo osredotočili na **AR modele**, saj omogočajo učinkovito *frekvenčno analizo* brez predhodnega poznavanja vhodov.

*

Z-transformacija

Za analizo linearnih sistemov v diskretnem času uporabljamo *Z-transformacijo*:

$$\mathcal{Z}\{x_n\} = X(z) = \sum_{n=-\infty}^{\infty} x_n z^{-n}, \quad z \in \mathbb{C}. \quad (37)$$

Če $z = e^{i\omega}$ (enotska krožnica v kompleksni ravnini), Z-transformacija preide v *diskretno Fourierovo transformacijo*.

Uporabimo Z-transformacijo na enačbo (36) (za ARMA model z $b_0 = 1$):

$$S(z) = - \sum_{k=1}^p a_k z^{-k} S(z) + G \left(U(z) + \sum_{l=1}^q b_l z^{-l} U(z) \right).$$

Po preurejanju dobimo *prenosno funkcijo* sistema:

$$H(z) = \frac{S(z)}{U(z)} = G \frac{1 + \sum_{l=1}^q b_l z^{-l}}{1 + \sum_{k=1}^p a_k z^{-k}}. \quad (38)$$

Imenovalca imenujemo *poli* ($H(z) \rightarrow \infty$), števec pa *ničle* ($H(z) = 0$).

Opomba 6.1. Za **AR model** ($q = 0, b_0 = 1$) je:

$$H(z) = \frac{G}{1 + \sum_{k=1}^p a_k z^{-k}}.$$

*

Določitev AR koeficientov iz podatkov

Kadar vhodni signal u_n ni znan (npr. pri analizi podnebnih ali geofizikalnih podatkov), predpostavimo, da signal izvira iz AR procesa z belim šumom kot vhomom. Tedaj model postane:

$$S_n = - \sum_{k=1}^p a_k S_{n-k} + e_n,$$

kjer je e_n napaka napovedi (t.i. *innovation*).

Minimiziramo srednjo kvadratno napako:

$$\Sigma = \mathbb{E}[e_n^2] = \mathbb{E} \left[\left(S_n + \sum_{k=1}^p a_k S_{n-k} \right)^2 \right].$$

Pogoj $\partial \Sigma / \partial a_k = 0$ vodi do sistema **Yule-Walkerjevih enačb**:

$$\sum_{k=1}^p a_k R(|i-k|) = -R(i), \quad i = 1, 2, \dots, p, \quad (39)$$

kjer je $R(\tau) = \mathbb{E}[S_n S_{n-\tau}]$ avtokorelacijska funkcija (ACF).

Definicija 6.1 (Avtokorelacijska funkcija). Za **stacionaren** signal je ACF odvisna le od časovnega zamika τ , ne od absolutnega časa:

$$R(\tau) = \mathbb{E}[S_n S_{n-\tau}].$$

V praksi jo ocenimo iz končnega signala:

$$\hat{R}(k) = \frac{1}{N-k} \sum_{n=k}^{N-1} S_n S_{n-k}, \quad k = 0, 1, \dots, p.$$

Sistem (39) lahko zapišemo matrično:

$$\begin{bmatrix} R(0) & R(1) & \cdots & R(p-1) \\ R(1) & R(0) & \cdots & R(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ R(p-1) & R(p-2) & \cdots & R(0) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = - \begin{bmatrix} R(1) \\ R(2) \\ \vdots \\ R(p) \end{bmatrix}.$$

Primer 6.1 (Izračun AR(2) koeficientov). Recimo, da iz podatkov ocenimo: $R(0) = 1.0$, $R(1) = 0.6$, $R(2) = 0.2$. Za $p = 2$ Yule-Walkerjev sistem glasi:

$$\begin{bmatrix} 1.0 & 0.6 \\ 0.6 & 1.0 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = - \begin{bmatrix} 0.6 \\ 0.2 \end{bmatrix}.$$

Rešitev: $a_1 \approx -0.75$, $a_2 \approx 0.25$.

*

Stabilnost in postavitev polov

Poli prenosne funkcije $H(z)$ so rešitve enačbe:

$$1 + \sum_{k=1}^p a_k z^{-k} = 0 \quad \Leftrightarrow \quad z^p + a_1 z^{p-1} + \dots + a_p = 0.$$

Definicija 6.2 (Stabilnost AR filtra). *Fiter je **stabilen**, če so vsi poli znotraj enotske krožnice: $|z_k| < 1$.*

Če sistem ni stabilen, napoved divergira. To se lahko zgodi zaradi:

- prisotnosti **trenda** v signalu (npr. rast CO₂ koncentracije) — tak signal ni stacionaren,
- **zaokrožitvenih napak** pri reševanju Yule-Walkerjevih enačb.

Popravek nestabilnih polov: Če je pol z_k zunaj enotske krožnice ($|z_k| > 1$), ga preslikamo znotraj z :

$$z_k \mapsto \tilde{z}_k = \frac{1}{z_k^*},$$

in posledično preračunamo koeficiente a_k iz novih ničel.

*

Izbira reda modela in spektralna ocena

Kako izbrati ustrezen red p ? Empirično pravilo:

$$p \approx 2K,$$

kjer je K pričakovano število dominantnih frekvenčnih komponent v signalu.

Spektralna gostota moči (power spectral density) za AR model je:

$$|H(\omega)|^2 = \frac{G^2}{|1 + \sum_{k=1}^p a_k e^{-i\omega k}|^2}. \quad (40)$$

Ta metoda se imenuje **MESE** (**M**aximum **E**ntropy **S**pectral **E**stimate), saj med vsemi spektri, skladnimi s podatki, izbira tistega z *največjo entropijo* (najmanj predpostavk).

Opomba 6.2. *MESE omogoča visoko ločljivo spektralno analizo, tudi z majhnim številom točk, v primerjavi z običajno Fourierovo analizo.*

7 Fourierova vrsta

Naj bo $f(x)$ periodična funkcija s periodo 2π . Fourierova vrsta nam omogoča, da takšno funkcijo zapišemo kot neskončno vsoto trigonometričnih funkcij (sinusov in kosinusov).

*

Definicija trigonometrične Fourierove vrste

Naj bo funkcija $f(x)$ definirana na intervalu $[-\pi, \pi]$ in razširjena na celo realno os kot periodična funkcija $\tilde{f}(x)$ s periodo 2π , tako da velja $\tilde{f}(x + 2\pi) = \tilde{f}(x)$.

Klasična (trigonometrična) Fourierova vrsta za funkcijo $\tilde{f}(x)$ je podana z izrazom:

$$\tilde{f}(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} (a_n \cos(nx) + b_n \sin(nx)) \quad (41)$$

Fourierovi koeficienti a_0 , a_n in b_n so definirani z naslednjimi integrali:

$$a_0 = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) dx \quad (42)$$

$$a_n = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos(nx) dx \quad \text{za } n = 1, 2, 3, \dots \quad (43)$$

$$b_n = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin(nx) dx \quad \text{za } n = 1, 2, 3, \dots \quad (44)$$

*

Konvergenca in Dirichletovi pogoji

Če je funkcija $f(x)$ na intervalu $[-\pi, \pi]$ **odsekoma zvezno odvedljiva**, potem Fourierova vrsta konvergira k periodični razširitvi $\tilde{f}(x)$ povsod. V točkah, kjer je funkcija $f(x)$ zvezna, velja:

$$\tilde{f}(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} (a_n \cos(nx) + b_n \sin(nx)) \quad (45)$$

V točkah nezveznosti x_0 pa Fourierova vrsta konvergira k povprečju leve in desne limite:

$$\tilde{f}(x_0) = \frac{1}{2} \left[\lim_{x \rightarrow x_0^+} f(x) + \lim_{x \rightarrow x_0^-} f(x) \right] \quad (46)$$

Zaradi periodičnosti velja tudi na robovih intervala:

$$\tilde{f}(-\pi) = \tilde{f}(\pi) = \frac{1}{2} \left[\lim_{x \rightarrow -\pi^+} f(x) + \lim_{x \rightarrow \pi^-} f(x) \right] \quad (47)$$

*

Parsevalova enačba

Parsevalova enačba povezuje energijo (kvadrat norme) funkcije z njenimi Fourierovimi koeficienti. Če je $f(x)$ kvadratno integrabilna funkcija na intervalu $[-\pi, \pi]$, velja:

$$\frac{1}{\pi} \int_{-\pi}^{\pi} |f(x)|^2 dx = \frac{a_0^2}{2} + \sum_{n=1}^{\infty} (a_n^2 + b_n^2) \quad (48)$$

Fizikalno to pomeni, da je skupna moč signala enaka vsoti moči posameznih harmonskih komponent.

*

Primeri razvoja v Fourierovo vrsto

V spodnjih primerih razvijemo podane funkcije v trigonometrično Fourierovo vrsto na intervalu $[-\pi, \pi]$ ter določimo vrednost vsote vrste $S(x)$ na tem intervalu.

Primer 7.1 ($f(x) = \pi + x$). Razvijmo funkcijo $f(x) = \pi + x$ na intervalu $[-\pi, \pi]$.

Izračun koeficientov:

- $a_0 = \frac{1}{\pi} \int_{-\pi}^{\pi} (\pi + x) dx = \frac{1}{\pi} [\pi x + \frac{x^2}{2}]_{-\pi}^{\pi} = \frac{1}{\pi} (2\pi^2) = 2\pi.$
- $a_n = \frac{1}{\pi} \int_{-\pi}^{\pi} (\pi + x) \cos(nx) dx = 0$ (za $n \geq 1$), ker je integral konstante π enak 0, integral lihe funkcije $x \cos(nx)$ pa prav tako 0.
- $b_n = \frac{1}{\pi} \int_{-\pi}^{\pi} (\pi + x) \sin(nx) dx = \frac{1}{\pi} \int_{-\pi}^{\pi} x \sin(nx) dx.$ Z integracijo per partes dobimo:

$$b_n = \frac{2}{n} (-1)^{n+1}$$

Vsota vrste $S(x)$: Za $x \in (-\pi, \pi)$ je $S(x) = \pi + x$. Na robovih intervala velja:

$$S(\pi) = S(-\pi) = \frac{f(\pi^-) + f(-\pi^+)}{2} = \frac{2\pi + 0}{2} = \pi$$

Primer 7.2 ($f(x) = e^{ax}$). Naj bo $a \neq 0$. Razvijmo eksponentno funkcijo.

Izračun koeficientov: Z uporabo integracije $\int e^{ax} \cos(nx) dx$ in $\int e^{ax} \sin(nx) dx$ dobimo:

$$\begin{aligned} a_0 &= \frac{e^{a\pi} - e^{-a\pi}}{a\pi} = \frac{2 \sinh(a\pi)}{a\pi} \\ a_n &= \frac{2a \sinh(a\pi)}{\pi(a^2 + n^2)} (-1)^n \\ b_n &= \frac{-2n \sinh(a\pi)}{\pi(a^2 + n^2)} (-1)^n \end{aligned}$$

Vrednosti v specifičnih točkah:

- V $x = 0$ je funkcija zvezna: $S(0) = e^0 = 1.$
- V $x = \pi$ (točka nezveznosti periodične razširitve):

$$S(\pi) = \frac{e^{a\pi} + e^{-a\pi}}{2} = \cosh(a\pi)$$

Primer 7.3 ($f(x) = \cos(ax)$, $a \notin \mathbb{Z}$). Razvijmo funkcijo $\cos(ax)$, kjer a ni celo število. Ker je funkcija soda, so vsi $b_n = 0$.

Izračun koeficientov:

$$\begin{aligned} a_0 &= \frac{2 \sin(a\pi)}{a\pi} \\ a_n &= \frac{2a \sin(a\pi)}{\pi(a^2 - n^2)} (-1)^n \end{aligned}$$

Vrednosti v specifičnih točkah:

- $V x = 0$ je funkcija zvezna: $S(0) = \cos(0) = 1$.
- $V x = \pi$: Ker je periodična razširitev sode funkcije zvezna v π (če je $f(\pi) = f(-\pi)$), velja $S(\pi) = \cos(a\pi)$.

*

Kosinusna Fourierova vrsta

Naj bo funkcija $f(x)$ integrabilna na intervalu $(0, \pi)$. To funkcijo lahko razvijemo v vrsto, ki vsebuje le kosinusne pogoje, tako da naredimo **sodno periodično razširitev** $\tilde{f}(x)$.

Definicija: Sodno razširjena funkcija $\tilde{f}(x)$ je definirana kot:

$$\tilde{f}(x) = \begin{cases} f(x); & x \in [0, \pi] \\ f(-x); & x \in [-\pi, 0] \end{cases} \quad (49)$$

ter $\tilde{f}(x + 2\pi) = \tilde{f}(x)$. Ker je $\tilde{f}$ soda funkcija, so vsi koeficienti $b_n = 0$.

Fourierovi koeficienti: Kosinusna Fourierova vrsta je podana z:

$$\tilde{f}(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} a_n \cos(nx) \quad (50)$$

kjer koeficiente izračunamo na polovičnem intervalu:

$$a_0 = \frac{2}{\pi} \int_0^{\pi} f(x) dx \quad (51)$$

$$a_n = \frac{2}{\pi} \int_0^{\pi} f(x) \cos(nx) dx \quad (52)$$

Konvergenca: Če je $f(x)$ odsekoma zvezno odvedljiva na $(0, \pi)$, potem je $\tilde{f}$ definirana povsod na $\mathbb{R}$. V točkah nezveznosti x_0 (vključno z robovi, če se vrednosti ne ujemajo) velja:

$$S(x_0) = \frac{1}{2} \left[\lim_{x \uparrow x_0} \tilde{f}(x) + \lim_{x \downarrow x_0} \tilde{f}(x) \right] \quad (53)$$

Zaradi sode razširitve je periodična razširitev v točkah $n\pi$ pogosto zvezna, razen če ima originalna funkcija tam skok.

Parsevalova enačba za kosinusno vrsto: Ker so $b_n = 0$, se Parsevalova identiteta na intervalu $[0, \pi]$ glasi:

$$\frac{2}{\pi} \int_0^{\pi} |f(x)|^2 dx = \frac{a_0^2}{2} + \sum_{n=1}^{\infty} a_n^2 \quad (54)$$

Primer 7.4 (Kosinusni razvoj funkcije $f(x) = \sin x$). Razvijmo funkcijo $f(x) = \sin x$ v kosinusno Fourierovo vrsto na intervalu $[0, \pi]$. To pomeni, da funkcijo sodno razširimo na interval $[-\pi, \pi]$, kar nam da funkcijo $\tilde{f}(x) = |\sin x|$.

Izračun koeficientov: Ker iščemo kosinusno vrsto, so vsi $b_n = 0$. Izračunamo a_n :

- $a_0 = \frac{2}{\pi} \int_0^\pi \sin x \, dx = \frac{2}{\pi} [-\cos x]_0^\pi = \frac{2}{\pi} (1 - (-1)) = \frac{4}{\pi}.$

- $Za \, n \geq 1:$

$$a_n = \frac{2}{\pi} \int_0^\pi \sin x \cos(nx) \, dx$$

Uporabimo trigonometrično identiteto $\sin \alpha \cos \beta = \frac{1}{2}(\sin(\alpha + \beta) + \sin(\alpha - \beta))$:

$$a_n = \frac{1}{\pi} \int_0^\pi (\sin((1+n)x) + \sin((1-n)x)) \, dx$$

Po integraciji dobimo:

$$a_n = \frac{1}{\pi} \left[-\frac{\cos((1+n)x)}{1+n} - \frac{\cos((1-n)x)}{1-n} \right]_0^\pi$$

Za sode n ($n = 2, 4, \dots$):

$$a_n = \frac{2}{\pi} \left(\frac{-1}{n^2-1} - \frac{1}{n^2-1} \right) = \frac{-4}{\pi(n^2-1)}$$

Za lihe $n > 1$ je $a_n = 0$. Za $n = 1$ dobimo prav tako $a_1 = 0$.

Zapis vrste: Fourierova vrsta se glasi:

$$\tilde{f}(x) = \frac{2}{\pi} - \frac{4}{\pi} \sum_{k=1}^{\infty} \frac{\cos(2kx)}{4k^2-1} \quad (55)$$

Vsota vrste $S(x)$ na intervalu $[-\pi, \pi]$: Ker je funkcija $f(x) = \sin x$ na intervalu $[0, \pi]$ zvezna in sta njeni vrednosti na robovih $f(0) = 0$ in $f(\pi) = 0$ enaki, je sode periodična razširitev $\tilde{f}(x) = |\sin x|$ zvezna povsod na $\mathbb{R}$. Zato velja:

$$S(x) = |\sin x| \quad \text{za vse } x \in [-\pi, \pi] \quad (56)$$

*

Sinusna Fourierova vrsta

Naj bo funkcija $f(x)$ integrabilna na intervalu $(0, \pi)$. Če želimo funkcijo razviti le po sinusih, uporabimo **liho periodično razširitev** $\tilde{f}(x)$.

Definicija: Liho razširjena funkcija $\tilde{f}(x)$ je definirana kot:

$$\tilde{f}(x) = \begin{cases} f(x); & x \in (0, \pi) \\ 0; & x = 0, \pi \\ -f(-x); & x \in (-\pi, 0) \end{cases} \quad (57)$$

ter $\tilde{f}(x + 2\pi) = \tilde{f}(x)$. Ker je $\tilde{f}$ liha funkcija, so vsi koeficienti $a_n = 0$ (vključno z a_0).

Fourierovi koeficienti: Sinusna Fourierova vrsta je podana z:

$$\tilde{f}(x) = \sum_{n=1}^{\infty} b_n \sin(nx) \quad (58)$$

kjer koeficiente izračunamo kot:

$$b_n = \frac{2}{\pi} \int_0^\pi f(x) \sin(nx) \, dx \quad (59)$$

Konvergenca: Če je $f(x)$ odsekoma zvezno odvedljiva na $(0, \pi)$, vrsta konvergira k $\tilde{f}(x)$ povsod, kjer je $\tilde{f}$ zvezna. V točkah nezveznosti velja:

$$S(x_0) = \frac{1}{2} \left[\lim_{x \uparrow x_0} \tilde{f}(x) + \lim_{x \downarrow x_0} \tilde{f}(x) \right] \quad (60)$$

Pomembno: Pri lihi razširitvi je $S(0) = S(\pi) = 0$, ne glede na vrednosti originalne funkcije na robovih, razen če je $f(0^+) = f(\pi^-) = 0$.

Parsevalova enačba za sinusno vrsto:

$$\frac{2}{\pi} \int_0^\pi |f(x)|^2 dx = \sum_{n=1}^{\infty} b_n^2 \quad (61)$$

Primer 7.5. Dana je funkcija:

$$f(x) = \begin{cases} x; & -\frac{2\pi}{3} < x < \frac{2\pi}{3} \\ 0; & \text{sicer na } [-\pi, \pi] \end{cases}$$

Razvijmo jo v trigonometrično Fourierovo vrsto na intervalu $[-\pi, \pi]$.

1. Izračun koeficientov: Ker je funkcija $f(x)$ liha ($f(-x) = -f(x)$), so vsi $a_n = 0$. Izračunamo le b_n :

$$\begin{aligned} b_n &= \frac{2}{\pi} \int_0^{\frac{2\pi}{3}} x \sin(nx) dx \\ &= \frac{2}{\pi} \left[-\frac{x \cos(nx)}{n} + \frac{\sin(nx)}{n^2} \right]_0^{\frac{2\pi}{3}} \\ &= \frac{2}{\pi} \left(-\frac{2\pi}{3n} \cos\left(\frac{2n\pi}{3}\right) + \frac{1}{n^2} \sin\left(\frac{2n\pi}{3}\right) \right) \end{aligned}$$

Izračunajmo prvih nekaj členov:

- $n = 1 : b_1 = \frac{2}{\pi} \left(-\frac{2\pi}{3} \cdot \left(-\frac{1}{2}\right) + \frac{\sqrt{3}}{2} \right) = \frac{2}{3} + \frac{\sqrt{3}}{\pi}$
- $n = 2 : b_2 = \frac{2}{\pi} \left(-\frac{\pi}{3} \cdot \left(-\frac{1}{2}\right) + \left(-\frac{\sqrt{3}}{2}\right) \right) = \dots$ (nadaljujemo do $n = 4$)

2. Izračun vrednosti $\tilde{f}(-10\pi/3)$: Upoštevamo periodičnost Fourierove vrste s periodo 2π :

$$-\frac{10\pi}{3} + 4\pi = \frac{-10\pi + 12\pi}{3} = \frac{2\pi}{3}$$

Vrednost Fourierove vrste v točki nezveznosti $x_0 = \frac{2\pi}{3}$ je povprečje limit:

$$\begin{aligned} \tilde{f}\left(\frac{2\pi}{3}\right) &= \frac{1}{2} \left[\lim_{x \uparrow \frac{2\pi}{3}} f(x) + \lim_{x \downarrow \frac{2\pi}{3}} f(x) \right] \\ &= \frac{1}{2} \left[\frac{2\pi}{3} + 0 \right] = \frac{\pi}{3} \end{aligned}$$

Torej je $f_{vijuga}(-10\pi/3) = \frac{\pi}{3}$.

*

Fourierova vrsta na poljubnem simetričnem intervalu

Naj bo funkcija $f(x)$ integrabilna na intervalu $[-l, l]$. Želimo jo razviti v Fourierovo vrsto s periodo $T = 2l$.

Definicija: Trigonometrična Fourierova vrsta za periodično razširitev $\tilde{f}(x)$ s periodo $2l$ je podana kot:

$$\tilde{f}(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} \left(a_n \cos\left(\frac{n\pi x}{l}\right) + b_n \sin\left(\frac{n\pi x}{l}\right) \right) \quad (62)$$

Fourierovi koeficienti so v tem primeru definirani kot:

$$a_0 = \frac{1}{l} \int_{-l}^l f(x) dx \quad (63)$$

$$a_n = \frac{1}{l} \int_{-l}^l f(x) \cos\left(\frac{n\pi x}{l}\right) dx \quad (64)$$

$$b_n = \frac{1}{l} \int_{-l}^l f(x) \sin\left(\frac{n\pi x}{l}\right) dx \quad (65)$$

Lastnosti in konvergenca: Funkcija $\tilde{f}(x)$ je periodična s periodo $2l$. Če je $f(x)$ na intervalu $[-l, l]$ **odsekoma zvezno odvedljiva**, potem vrsta konvergira povsod na $\mathbb{R}$.

V **notranjih točkah** intervala $(-l, l)$, kjer je funkcija zvezna, velja:

$$\tilde{f}(x) = f(x) \quad (66)$$

V točkah nezveznosti $x_0 \in (-l, l)$ vrsta konvergira k povprečni vrednosti limit:

$$\tilde{f}(x_0) = \frac{1}{2} \left[\lim_{x \rightarrow x_0^+} f(x) + \lim_{x \rightarrow x_0^-} f(x) \right] \quad (67)$$

Na robovih intervala ($x = \pm l$) pa velja:

$$\tilde{f}(l) = \tilde{f}(-l) = \frac{1}{2} \left[\lim_{x \rightarrow -l^+} f(x) + \lim_{x \rightarrow l^-} f(x) \right] \quad (68)$$

Parsevalova enačba: Za kvadratno integrabilno funkcijo na intervalu $[-l, l]$ se Parsevalova identiteta glasi:

$$\frac{1}{l} \int_{-l}^l |f(x)|^2 dx = \frac{a_0^2}{2} + \sum_{n=1}^{\infty} (a_n^2 + b_n^2) \quad (69)$$

Primer 7.6. Razvijmo funkcijo

$$f(x) = \begin{cases} 0; & -1 \leq x \leq 0 \\ x; & 0 < x \leq 1 \end{cases}$$

v trigonometrično Fourierovo vrsto na intervalu $[-1, 1]$. Tukaj je $l = 1$.

1. Izračun koeficientov:

- **Enosmerna komponenta:**

$$a_0 = \frac{1}{1} \int_{-1}^1 f(x) dx = \int_0^1 x dx = \left[\frac{x^2}{2} \right]_0^1 = \frac{1}{2}$$

- **Kosinusni koeficienti:**

$$a_n = \int_0^1 x \cos(n\pi x) dx = \left[\frac{x \sin(n\pi x)}{n\pi} \right]_0^1 - \int_0^1 \frac{\sin(n\pi x)}{n\pi} dx$$

$$a_n = 0 + \left[\frac{\cos(n\pi x)}{(n\pi)^2} \right]_0^1 = \frac{(-1)^n - 1}{n^2\pi^2}$$

Opazimo: $a_n = 0$, če je n sod, in $a_n = -\frac{2}{n^2\pi^2}$, če je n lih.

- **Sinusni koeficienti:**

$$b_n = \int_0^1 x \sin(n\pi x) dx = \left[-\frac{x \cos(n\pi x)}{n\pi} \right]_0^1 + \int_0^1 \frac{\cos(n\pi x)}{n\pi} dx$$

$$b_n = -\frac{(-1)^n}{n\pi} + 0 = \frac{(-1)^{n+1}}{n\pi}$$

2. Vsota Fourierove vrste $S(x)$: Fourierova vrsta $\tilde{f}(x)$ je periodična razširitev z $T = 2$.

3. Vrednost v celih številih: Zanima nas vrednost vsote $S(k)$ za $k \in \mathbb{Z}$. Zaradi periodičnosti $T = 2$ ločimo dva primera:

- **Soda cela števila ($x = 0, \pm 2, \pm 4, \dots$):** V točki $x = 0$ je funkcija zvezna, saj je $f(0^-) = 0$ in $f(0^+) = 0$.

$$S(2k) = S(0) = f(0) = 0$$

- **Liha cela števila ($x = \pm 1, \pm 3, \dots$):** To so točke na robovih osnovnega intervala (npr. $x = 1$ in $x = -1$). Periodična razširitev ima tam skok, saj je $f(-1^+) = 0$ in $f(1^-) = 1$. Po Dirichletovem izreku je vsota enaka povprečju limit:

$$S(2k+1) = S(1) = \frac{f(1^-) + f(-1^+)}{2} = \frac{1+0}{2} = \frac{1}{2}$$

*

Fourierova vrsta na poljubnem intervalu $[u, v]$

Naj bo funkcija $f(x)$ integrabilna na poljubnem intervalu $[u, v]$. Definiramo polovično dolžino intervala $l = \frac{v-u}{2}$.

Definicija: Trigonometrična Fourierova vrsta za periodično razširitev $\tilde{f}(x)$ s periodo $T = v - u = 2l$ je podana z izrazom:

$$\tilde{f}(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} \left(a_n \cos\left(\frac{n\pi x}{l}\right) + b_n \sin\left(\frac{n\pi x}{l}\right) \right) \quad (70)$$

Fourierovi koeficienti so v tem splošnem primeru:

$$a_0 = \frac{1}{l} \int_u^v f(x) dx \quad (71)$$

$$a_n = \frac{1}{l} \int_u^v f(x) \cos\left(\frac{n\pi x}{l}\right) dx \quad (72)$$

$$b_n = \frac{1}{l} \int_u^v f(x) \sin\left(\frac{n\pi x}{l}\right) dx \quad (73)$$

Lastnosti in konvergenca: Funkcija $\tilde{f}(x)$ je periodična razširitev funkcije $f(x)$ s periodo $v - u$. Če je $f(x)$ na intervalu $[u, v]$ odsekoma zvezno odvedljiva, potem Fourierova vrsta konvergira povsod na $\mathbb{R}$:

$$\tilde{f}(x) = \frac{1}{2} \left[\lim_{t \rightarrow x^+} \tilde{f}(t) + \lim_{t \rightarrow x^-} \tilde{f}(t) \right] \quad (74)$$

V **notranjih točkah** intervala $x \in (u, v)$, kjer je funkcija zvezna, velja:

$$\tilde{f}(x) = f(x) \quad (75)$$

Na **robovih intervala** in v točkah $x = u + k(v - u)$ za $k \in \mathbb{Z}$ pa vrsta konvergira k vrednosti:

$$\tilde{f}(u) = \tilde{f}(v) = \frac{f(u^+) + f(v^-)}{2} \quad (76)$$

Parsevalova enačba: Za kvadratno integrabilno funkcijo na intervalu $[u, v]$ se Parsevalova identiteta glasi:

$$\frac{1}{l} \int_u^v |f(x)|^2 dx = \frac{a_0^2}{2} + \sum_{n=1}^{\infty} (a_n^2 + b_n^2) \quad (77)$$

Primer 7.7. Razvijmo funkcijo $f(x) = x^2$ v trigonometrično Fourierovo vrsto na intervalu $[1, 3]$.

1. Parametri: Interval je $[1, 3]$, torej je $u = 1$ in $v = 3$. Polovična dolžina intervala: $l = \frac{3-1}{2} = 1$. Perioda: $T = 2l = 2$.

2. Izračun koeficientov:

• **Koeficient a_0 :**

$$a_0 = \frac{1}{1} \int_1^3 x^2 dx = \left[\frac{x^3}{3} \right]_1^3 = \frac{27}{3} - \frac{1}{3} = \frac{26}{3}$$

• **Koeficienti a_n ($n \geq 1$):**

$$a_n = \int_1^3 x^2 \cos(n\pi x) dx$$

Z dvojno integracijo per partes dobimo:

$$a_n = \left[x^2 \frac{\sin(n\pi x)}{n\pi} + 2x \frac{\cos(n\pi x)}{(n\pi)^2} - 2 \frac{\sin(n\pi x)}{(n\pi)^3} \right]_1^3$$

Ker je $\sin(n\pi) = \sin(3n\pi) = 0$ in $\cos(3n\pi) = \cos(n\pi) = (-1)^n$:

$$a_n = \frac{2(3)(-1)^n}{(n\pi)^2} - \frac{2(1)(-1)^n}{(n\pi)^2} = \frac{4(-1)^n}{n^2\pi^2}$$

• **Koeficienti** b_n :

$$b_n = \int_1^3 x^2 \sin(n\pi x) dx = \left[-x^2 \frac{\cos(n\pi x)}{n\pi} + 2x \frac{\sin(n\pi x)}{(n\pi)^2} + 2 \frac{\cos(n\pi x)}{(n\pi)^3} \right]_1^3$$

$$b_n = \left(-\frac{9(-1)^n}{n\pi} + \frac{2(-1)^n}{(n\pi)^3} \right) - \left(-\frac{1(-1)^n}{n\pi} + \frac{2(-1)^n}{(n\pi)^3} \right) = -\frac{8(-1)^n}{n\pi}$$

3. Vrednost vrste v točki $x = 8$: Fourierova vrsta $\tilde{f}(x)$ je periodična s periodo $T = 2$. Da izračunamo vrednost v $x = 8$, točko preslikamo na osnovni interval $[1, 3]$:

$$8 = 4 \cdot T + 0 \implies 8 \equiv 0 \pmod{2}$$

Vendar točka 0 ni v najinem intervalu $[1, 3]$. Uporabimo premik: $8 - 3 \cdot T = 8 - 6 = 2$. Točka $x = 2$ leži znotraj intervala $(1, 3)$, kjer je funkcija $f(x) = x^2$ zvezna.

Zato velja:

$$S(8) = S(2) = f(2) = 2^2 = 4$$

8 Michelsonov interferometer

Michelsonov interferometer je optična naprava, ki temelji na delitvi amplitude svetlobnega snopa. Sestavljen je iz treh osnovnih optičnih elementov: dveh ravnih zrcal (Z_1 in Z_2) ter polprepustnega zrcala (P), ki deluje kot delilnik snopa.

Osnovna zgradba in princip delovanja

Shema interferometra (Slika 1) prikazuje naslednjo pot svetlobe:

1. Vpadni snop svetlobe zadene polprepustno zrcalo P , postavljeno pod kotom 45° .
2. Zrcalo P razdeli svetlobo na dva delna snopa:
 - Prvi snop se odbije proti zrcalu Z_1 .
 - Drugi snop se prepusti proti zrcalu Z_2 .
3. Oba snopa se na zrcalih Z_1 in Z_2 odbijeta nazaj proti polprepustnemu zrcalu P .
4. Tam se snopa ponovno združita in potujeta proti zaslonu ali detektorju.

Interferenčno sliko opazujemo na zaslonu, če je svetloba dovolj močna. V nasprotnem primeru (npr. pri šibkih izvorih) gledamo neposredno v interferometer (proti delilniku snopa).

Matematični opis in optična pot

Polprepustno zrcalo P opišemo z **amplitudno odbojnostjo** r in **prepustnostjo** t . To sta kompleksni količini, za kateri v idealnem primeru (brez absorpcije) velja ohranitev energije:

$$|r|^2 + |t|^2 = 1 \quad (78)$$

Zaradi simetrije poti (vsak snop se enkrat odbije in enkrat prepusti na P) sta amplitudi obeh delnih snopov ob ponovnem srečanju enaki, kar zagotavlja visok kontrast interferenčnih prog.

Opis polja: Za teoretični opis predpostavimo ravno monokromatsko valovanje s krožno frekvenco ω . Električno polje zapišemo kot:

$$\vec{E} = \vec{E}_0 \cos(kl - \omega t) \quad (79)$$

kjer so:

- $\vec{E}_0$: amplituda električnega polja,
- $k = \frac{\omega}{c_0} = \frac{2\pi}{\lambda}$: valovni vektor v vakuumu,
- $l = \int n(s) ds$: **optična pot**, kjer je n lomni količnik sredstva.

Kolimiran snop: V praksi se takemu idealnemu valovanju približamo s **kolimiranim** laserskim snopom.

Kaj pomeni kolimiran? Kolimiran snop je snop svetlobe, pri katerem so svetlobni žarki med seboj vzporedni. To pomeni, da se snop med širjenjem ne razširja (ne divergira) ali se razširja minimalno, njegova valovna fronta pa je ravna.

Ponovitev: Kompleksni zapis in fizikalne količine

V optiki namesto realnega zapisa polja $\vec{E} = \vec{E}_0 \cos(kl - \omega t)$ pogosto uporabljamo kompleksni zapis, kjer električno polje zapišemo kot:

$$\vec{E} = \vec{E}_0 e^{i(kl - \omega t)} \quad (80)$$

Fizikalno polje dobimo kot realni del tega izraza. Spodaj so podrobneje definirane ključne količine:

- **Krožna frekvenca ω :** Povezana je s frekvenco nihanja svetlobe ν kot $\omega = 2\pi\nu$. Določa časovni del faze in barvo svetlobe.
- **Valovni vektor k :** V vakuumu je definiran kot $k = \frac{\omega}{c_0} = \frac{2\pi}{\lambda}$, kjer je λ valovna dolžina v vakuumu. Pove nam, koliko faze val pridobi na enoto dolžine potovanja.
- **Optična pot l :** V homogenem sredstvu z lomnim količnikom n na razdalji s je optična pot $l = n \cdot s$. Splošno jo zapišemo z integralom $l = \int n(s) ds$. Optična pot predstavlja razdaljo, ki bi jo svetloba v istem času prepotovala v vakuumu.
- **Faza valovanja:** Celoten argument v eksponentu (ali kosinusu) $\phi = kl - \omega t$ imenujemo faza. Razlika v optični poti dveh snopov povzroči fazno razliko $\Delta\phi = k\Delta l$, kar vodi do interference.

Kompleksna odbojnost (r) in prepustnost (t): Na polprepustnem zrcalu se amplituda vpadnega polja E_{vp} spremeni. Odbojno in prepuščeno polje zapišemo kot:

$$E_{odb} = rE_{vp}, \quad E_{pre} = tE_{vp} \quad (81)$$

Količini r in t sta kompleksni, ker ne spremenita le amplitude, temveč lahko povzročita tudi **fazni skok** ob odboju ali prehodu:

- $r = |r|e^{i\delta_r}$ (kjer je δ_r fazni premik pri odboju),
- $t = |t|e^{i\delta_t}$ (kjer je δ_t fazni premik pri prehodu).

Intenzivnost svetlobe (tisto, kar dejansko zaznamo z očesom ali detektorjem) je sorazmerna kvadratu amplitude:

$$I \propto |E|^2 \quad (82)$$

Zato velja $|r|^2 + |t|^2 = 1$, kar pomeni, da je vsota intenzivnosti odbitega in prepuščenega snopa enaka intenzivnosti vpadnega snopa (če ni absorpcije).

Interferenca na opazovalnem zaslonu

Električno polje svetlobe na opazovalnem zaslonu ($\vec{E}_z$) je vektorska vsota polj obeh delnih snopov, ki se po odboju od zrcal Z_1 in Z_2 ponovno srečata na delilniku snopa P :

$$\vec{E}_z = \vec{E}_1 + \vec{E}_2 \quad (83)$$

Upoštevamo, da vsak snop enkrat doživi odboj (r) in enkrat prehod (t) na polprepustnem zrcalu. Če je vpadno polje $\vec{E}_0 e^{-i\omega t}$, sta polji ob ponovnem srečanju:

$$\vec{E}_1 = rt\vec{E}_0 e^{i(kl_1 - \omega t)} \quad (84)$$

$$\vec{E}_2 = tr\vec{E}_0 e^{i(kl_2 - \omega t)} \quad (85)$$

kjer sta l_1 in l_2 celotni optični poti, ki ju snopa opravita od delilnika do zrcal in nazaj.

Amplitudni predfaktor: Opazimo, da sta amplitudi obeh snopov enaki ($rt = tr$). Če vzamemo idealno polprepustno zrcalo, kjer je $|r| = |t| = 1/\sqrt{2}$, produkt rt v kvadratu intenzitete povzroči predfaktor $1/2$. To pomeni, da vsak snop nosi polovico amplitude (oz. četrtno intenzitete) prvotnega vpadnega snopa, preden se ponovno združita.

Fazna razlika: Fazna razlika $\Delta\phi$ med snopoma je ključna za vrsto interference:

$$\Delta\phi = k(l_2 - l_1) = k\Delta l = \frac{2\pi}{\lambda}\Delta l \quad (86)$$

$\Delta\phi$ je odvisen od:

- razlike v geometrijski dolžini krakov interferometra,
- razlike v lomnih količnikih sredstev v krakih (n_1, n_2),
- valovne dolžine svetlobe λ .

Simetrična struktura: V praksi želimo čim bolj simetrično strukturo interferometra (enaka krakova, uporaba kompenzacijske ploščice), da izničimo vpliv disperzije in okolice. Tako postane $\Delta\phi$ odvisen le od tiste količine, ki jo želimo meriti (npr. premik enega zrcala).

Definicija intenzitete svetlobe

V optiki z detektorji (oko, fotodioda, CCD kamera) ne moremo neposredno meriti nihajočega električnega polja $\vec{E}$, saj so frekvence svetlobe (v redu velikosti 10^{14} Hz) previsoke za odzivni čas snovi. Detektorji namesto tega zaznajo **povprečni energijski tok** na enoto površine.

Intenziteto I definiramo kot časovno povprečje velikosti Poyntingovega vektorja. Za monokromatsko valovanje v kompleksnem zapisu velja:

$$I = \frac{1}{2}c_0\epsilon_0 n |E|^2 \quad (87)$$

kjer je $|E|$ amplituda električnega polja. Ker nas pri interferometru običajno zanimajo le relativne spremembe svetlosti, predfaktorje pogosto združimo v konstanto in zapišemo:

$$I \propto \langle |\vec{E}(t)|^2 \rangle_t \quad (88)$$

Intenziteta je torej premo sorazmerna kvadratu amplitude polja.

Intenziteta na opazovalnem zaslonu

Sedaj izpeljimo intenziteto za primer Michelsonovega interferometra, kjer se združita dva snopa z enakima amplitudama. Skupno polje na zaslonu je:

$$\vec{E}_z = \vec{E}_1 + \vec{E}_2 = \vec{E}_{0z} e^{i(kl_1 - \omega t)} + \vec{E}_{0z} e^{i(kl_2 - \omega t)} \quad (89)$$

kjer je $\vec{E}_{0z} = rt\vec{E}_0$ amplituda posameznega delnega snopa. Izpostavimo skupne faktorje:

$$\vec{E}_z = \vec{E}_{0z} e^{-i\omega t} e^{ikl_1} (1 + e^{ik(l_2 - l_1)}) \quad (90)$$

Intenziteto I_z izračunamo kot produkt polja s konjugirano kompleksno vrednostjo:

$$I_z \propto \vec{E}_z \cdot \vec{E}_z^* = |\vec{E}_{0z}|^2 (1 + e^{i\Delta\phi}) (1 + e^{-i\Delta\phi}) \quad (91)$$

$$= |\vec{E}_{0z}|^2 (1 + e^{-i\Delta\phi} + e^{i\Delta\phi} + 1) \quad (92)$$

$$= |\vec{E}_{0z}|^2 (2 + 2\cos(\Delta\phi)) \quad (93)$$

Upoštevamo, da je $|\vec{E}_{0z}|^2$ intenziteta enega delnega snopa, ki je zaradi delitve na P enaka $\frac{1}{4}I_0$ (ker gre svetloba dvakrat skozi/od delilnika, $|rt|^2 = |1/2|^2 = 1/4$).

Končna enačba za intenziteto: Z uporabo trigonometrične identitete $1 + \cos(x) = 2\cos^2(x/2)$ dobimo:

$$I_z = \frac{1}{2}I_0(1 + \cos \Delta\phi) = I_0 \cos^2\left(\frac{\Delta\phi}{2}\right) \quad (94)$$

,

Analiza interferenčnih robov in ohranitev energije

Kot smo izpeljali, je intenziteta na opazovalnem izhodu odvisna od fazne razlike $\Delta\phi$:

- **Maksimumi (konstruktivna interferenca):** Nastopijo, ko je fazni zaostanek enak celoštevilskemu večkratniku 2π :

$$\Delta\phi = N \cdot 2\pi, \quad N \in \mathbb{Z} \quad (95)$$

- **Minimumi (destruktivna interferenca):** Nastopijo, ko so valovi v protifazi:

$$\Delta\phi = (2N + 1)\pi, \quad N \in \mathbb{Z} \quad (96)$$

V idealnem interferometru brez izgub velja zakon o ohranitvi energije. Če imamo pri $\Delta\phi = N2\pi$ na opazovalnem izhodu (proti zaslonu) maksimalno intenziteto ($I_z = I_0$), to pomeni, da je vsa svetloba konstruktivno interferirala v tej smeri. Takrat na **drugem izhodu** (tistem, ki kaže nazaj proti izvoru) vlada popolna destruktivna interferenca. Ko fazno razliko zvezno spreminjamo, se svetloba “preliva” med obema izhodoma.

Zvezno spreminjanje faze in premik zrcal

Razliko optičnih poti Δl in s tem fazni zaostanek $\Delta\phi$ najlažje zvezno spreminjamo s premikanjem enega izmed zrcal (običajno Z_1) s pomočjo mikrometrskega vijaka ali piezoelektričnega kristala.

Če zrcalo Z_1 premaknemo za razdaljo Δd_1 stran od delilnika, se geometrijska pot svetlobe poveča za $2\Delta d_1$ (pot do zrcala in nazaj). Optična pot se tako poveča za:

$$\Delta l_1 = 2n\Delta d_1 \quad (97)$$

Posledično se fazna razlika poveča za:

$$\Delta(\Delta\phi) = k \cdot \Delta l_1 = \frac{2\pi}{\lambda}(2n\Delta d_1) = \frac{4\pi n\Delta d_1}{\lambda} \quad (98)$$

Med premikanjem zrcala opazujemo periodično pojavo svetlih in temnih prog (maksimumov in minimumov). Vsakič, ko se zrcalo premakne za $\lambda/2$, prepotujemo eno celo interferenčno progo (2π).

Posebne nastavitve in bela svetloba

Ekvidistančna lega zrcal: To je nastavev, pri kateri sta optični poti obeh krakov popolnoma enaki ($\Delta l = 0$). V tej točki je fazna razlika $\Delta\phi = 0$ (oz. konstantna glede na morebitne fazne skoke na zrcalu) za **vse valovne dolžine** (barve) hkrati.

Bela svetloba: Ker je bela svetloba zmes širokega spektra valovnih dolžin, bo vsaka barva ustvarila svoj interferenčni vzorec z različnim razmikom med progami.

- Daleč od ekvidistančne lege se vzorci različnih barv prekrijejo in “izperejo” v enakomerno belino (koherentna dolžina bele svetlobe je zelo kratka).
- Le v bližini $\Delta l \approx 0$ opazimo barvne interferenčne proge. V sami točki ničelne poti dobimo oster centralni minimum ali maksimum (odvisno od konstrukcije delilnika).

Ta pojav je ekvivalenten interferenci na **tanki plasti**, kjer Michelsonov interferometer efektivno ustvari “zračno plast” med zrcalom Z_2 in navidezno sliko zrcala Z_1 .