

Splošna fizika

Dodatki k učenju

T. Jovanovski

31. oktober 2025

Kazalo

1	Statistika pri fizikalnih meritvah	3
1.1	Meritve konstantnih količin in Gaussova porazdelitev	3
1.2	Studentova t-porazdelitev	3
1.3	Testiranje hipotez in intervali zaupanja	4
1.4	Porazdelitev hi-kvadrat (χ^2)	5
1.5	Oblikovni testi (Goodness-of-Fit)	6
1.6	Metoda najmanjših kvadratov v matrični obliki	9
1.6.1	Linearni model in Kalmanov formalizem	10
1.6.2	Primer: Luščenje vrhov v spektru	11

1 Statistika pri fizikalnih meritvah

1.1 Meritve konstantnih količin in Gaussova porazdelitev

Pri merjenju fizikalnih količin, za katere predpostavljamo, da so konstantne, se rezultati posameznih meritev kljub temu razlikujejo. Te razlike so posledica naključnih napak oziroma šuma v merilnem procesu. Predpostavljamo, da so te napake porazdeljene po Gaussovi (normalni) porazdelitvi.

Če je a prava vrednost merjene količine in z je izmerjena vrednost, potem je ostanek (residual) r definiran kot:

$$r = z - a \quad (1)$$

Ta ostanek sledi normalni porazdelitvi $N(0, \sigma^2)$ z ničelno povprečno vrednostjo in varianco σ^2 . Naš cilj je na podlagi končnega števila meritev n oceniti pravo vrednost a in standardni odklon σ , ki karakterizira natančnost meritev.

Definicija 1.1 (Vzorčne statistike). Za vzorec n meritev $\{z_1, z_2, \dots, z_n\}$ definiramo dve ključni statistiki:

- **Vzorčno povprečje ($\bar{z}$):** Je najboljša ocena prave vrednosti a .

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i \quad (2)$$

- **Vzorčna varianca (s^2):** Je ocena variance porazdelitve meritev, σ^2 . Faktor $n - 1$ v imenovalcu zagotavlja nepristransko oceno variance.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2 \quad (3)$$

Ko število meritev n narašča proti neskončnosti, vzorčno povprečje $\bar{z}$ konvergira k pravi vrednosti a , vzorčna varianca s^2 pa k pravi varianci σ^2 .

1.2 Studentova t-porazdelitev

Kadar prava varianca σ^2 ni poznana in jo ocenjujemo z vzorčno varianco s^2 iz majhnega števila meritev, Gaussova porazdelitev ni več najboljši model. V tem primeru uporabimo Studentovo t-porazdelitev.

Definicija 1.2 (t-statistika). Definirajmo statistiko T kot:

$$T = \frac{\bar{z} - a}{s/\sqrt{n}} = \frac{\text{vzorčno povprečje} - \text{prava vrednost}}{\text{standardna napaka povprečja}} \quad (4)$$

Ta statistika meri, za koliko standardnih napak vzorčno povprečje odstopa od predpostavljene prave vrednosti a .

Verjetnostna gostota za statistiko T je podana s Studentovo t-porazdelitvijo $S(\nu)$ s $\nu = n - 1$ prostostnimi stopnjami:

$$\frac{dP}{dT} = S(n-1) = \frac{1}{\sqrt{n-1} \cdot B\left(\frac{1}{2}, \frac{n-1}{2}\right)} \left(1 + \frac{T^2}{n-1}\right)^{-\frac{n}{2}} \quad (5)$$

kjer je:

- n število meritev.
- $n - 1$ število prostostnih stopenj.
- $B(x, y)$ je Eulerjeva beta funkcija, definirana z integralom:

$$B(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt$$

Porazdelitev je zvonaste oblike, podobna Gaussovi, vendar ima širše repe, kar pomeni, da so ekstremne vrednosti bolj verjetne, posebej pri majhnem številu meritev n . Ko gre $n \rightarrow \infty$, t-porazdelitev konvergira k standardni normalni porazdelitvi.

1.3 Testiranje hipotez in intervali zaupanja

Studentova porazdelitev nam omogoča, da testiramo hipotezo o pravi vrednosti a in določimo interval zaupanja.

Postopek testiranja hipoteze:

1. Iz vzorca meritev $\{z_i\}$ izračunamo vzorčno povprečje $\bar{z}$ in varianco s^2 .
2. Postavimo ničelno hipotezo, da je prava vrednost enaka neki specifični vrednosti a_0 .
3. Izberemo stopnjo tveganja α , ki predstavlja verjetnost, da po pomoti zavrnemo pravilno hipotezo. Tipične vrednosti so $\alpha = 0.05$ (5%), $\alpha = 0.01$ (1%) ali $\alpha = 0.10$ (10%).
4. Izračunamo vrednost t-statistike T z uporabo enačbe 4, kjer za a vstavimo a_0 .
5. Iz tabel ali s programsko opremo poiščemo kritično vrednost t_{kr} za $n - 1$ prostostnih stopenj, za katero velja:

$$P(|T| > t_{kr}) = \alpha$$

6. Sprejmemo odločitev:

- Če je izračunana vrednost $|T| > t_{kr}$, potem hipotezo o vrednosti a_0 na stopnji tveganja α **zavrnemo**. Podatki statistično značilno nasprotujejo hipotezi.
- Če je $|T| \leq t_{kr}$, potem hipoteze o vrednosti a_0 **ne moremo zavreči**. To ne pomeni, da je hipoteza pravilna, ampak le, da podatki niso v dovolj močnem nasprotju z njo.

Interval zaupanja: Namesto testiranja ene same vrednosti lahko določimo celoten interval, v katerem se z določeno stopnjo zaupanja $1 - \alpha$ nahaja prava vrednost a . Interval zaupanja je območje vrednosti za parameter a , za katere ne bi zavrnili ničelne hipoteze.

Izhajamo iz pogoja:

$$P(-t_{kr} \leq T \leq t_{kr}) = 1 - \alpha \quad (6)$$

Vstavimo izraz za T :

$$-t_{kr} \leq \frac{\bar{z} - a}{s/\sqrt{n}} \leq t_{kr}$$

Z algebrsko preureditvijo osamimo a in dobimo $(1 - \alpha)$ -odstotni interval zaupanja za pravo vrednost a :

$$\left[\bar{z} - t_{kr} \frac{s}{\sqrt{n}}, \quad \bar{z} + t_{kr} \frac{s}{\sqrt{n}} \right] \quad (7)$$

To pomeni, da z verjetnostjo $1 - \alpha$ prava vrednost merjene količine leži znotraj tega intervala. Vrednosti a izven tega intervala bi na stopnji tveganja α zavrnili.

1.4 Porazdelitev hi-kvadrat (χ^2)

Podobno kot t-porazdelitev omogoča testiranje hipotez o povprečni vrednosti, nam porazdelitev χ^2 (hi-kvadrat) omogoča testiranje hipotez o pravi varianci σ^2 populacije. Predpostavljamo, da imamo vzorec $\{z_i\}$ iz normalno porazdeljene populacije $N(a, \sigma^2)$.

Definicija 1.3 (χ^2 -statistika). *Statistiko χ^2 definiramo kot:*

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} \quad (8)$$

kjer je n velikost vzorca, s^2 je vzorčna varianca in σ^2 je (hipotetična) prava varianca populacije. Ta statistika je porazdeljena po χ^2 -porazdelitvi z $\nu = n - 1$ prostostnimi stopnjami.

Verjetnostna gostota porazdelitve χ^2 z ν prostostnimi stopnjami je podana z izrazom:

$$\frac{dP}{d\chi^2} = f(\chi^2; \nu) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} (\chi^2)^{\frac{\nu}{2}-1} e^{-\frac{\chi^2}{2}} \quad (9)$$

kjer je:

- $\nu = n - 1$ število prostostnih stopenj.
- $\Gamma(z)$ je Eulerjeva gama funkcija, definirana z integralom:

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$$

Porazdelitev je normirana na 1 in je definirana samo za pozitivne vrednosti $\chi^2 > 0$. Z verjetnostjo $1 - \alpha$ pričakujemo, da bo izračunana vrednost χ^2 padla znotraj intervala $[\chi^2_{<}, \chi^2_{>}]$. Če pade izven tega intervala, hipotezo o vrednosti σ^2 zavrnemo na stopnji tveganja α .

Teoretična osnova za χ^2 porazdelitev je podana z naslednjim izrekom.

Izrek 1.1 (Vsota kvadratov normalnih spremenljivk). *Vsota kvadratov n neodvisnih, standardizirano normalno porazdeljenih naključnih spremenljivk $Z_i \sim N(0, 1)$, je porazdeljena po zakonu χ^2 z n prostostnimi stopnjami:*

$$\sum_{i=1}^n Z_i^2 \sim \chi^2(n) \quad (10)$$

Ta izrek, katerega dokaz tukaj izpustimo, potrjuje definicijo χ^2 statistike, saj je izraz $(n-1)s^2/\sigma^2$ sorazmeren vsoti kvadratov odklonov od povprečja.

Naslednji izrek elegantno poveže normalno, χ^2 in Studentovo t-porazdelitev.

Izrek 1.2 (Povezava med porazdelitvami). Naj bo X naključna spremenljivka, porazdeljena po standardni normalni porazdelitvi, $X \sim N(0, 1)$, in naj bo Y neodvisna naključna spremenljivka, porazdeljena po χ^2 porazdelitvi z n prostostnimi stopnjami, $Y \sim \chi^2(n)$. Potem je nova spremenljivka T , definirana kot

$$T = \frac{X}{\sqrt{Y/n}} \quad (11)$$

porazdeljena po Studentovi t -porazdelitvi z n prostostnimi stopnjami, $T \sim S(n)$.

1.5 Oblikovni testi (Goodness-of-Fit)

Ko smo s pomočjo metode najmanjših kvadratov določili optimalne parametre modela, se moramo še vprašati, ali je sam model (predpostavljena funkcijska oblika) sploh primeren za opis podatkov. Oblikovni testi nam omogočajo, da na statistično značilen način ocenimo, kako dobro se teoretična verjetnostna porazdelitev ujema z izmerjenimi podatki.

Pearsonov χ^2 test **Intuitivna ideja:** Ta test preverja, kako dobro se neka vnaprej določena verjetnostna gostota, dP/dz , ujema z našimi podatki. To storimo tako, da podatke razdelimo v razrede (naredimo histogram) in primerjamo, koliko meritev smo dejansko opazili v vsakem razredu (N_k) s številom meritev, ki bi jih v tem razredu pričakovali glede na teoretični model (N_{pk}). Če je model dober, bodo razlike med opazovanim in pričakovanim številom majhne, posledica zgolj statističnega nihanja.

Postopek:

1. Imamo vzorec n meritev $\{z_i\}$.
2. Podatkovni prostor razdelimo na ρ razredov (binov), ki se ne prekrivajo in nimajo vmesnih lukenj.
3. Za vsak razred k preštejemo število meritev N_k , ki so padle vanj.
4. Za vsak razred izračunamo teoretično verjetnost P_k , da meritev pade vanj, z integracijo predpostavljene porazdelitve dP/dz čez meje razreda:

$$P_k = \int_{z_{k-1}}^{z_k} \frac{dP}{dz} dz$$

Pričakovano število dogodkov v k -tem razredu je potem $N_{pk} = N \cdot P_k$.

5. Če je model dober, je število dogodkov N_k v vsakem razredu porazdeljeno po Poissonovi porazdelitvi s povprečjem N_{pk} . Za dovolj veliko število pričakovanih dogodkov ($N_{pk} \gtrsim 5$) ta porazdelitev preide v Gaussovo porazdelitev $N(N_{pk}, \sqrt{N_{pk}})$.
6. Sestavimo testno statistiko χ^2 , ki sešteje kvadrirana in normirana odstopanja:

$$\chi^2 = \sum_{k=1}^{\rho} \frac{(N_k - N_{pk})^2}{N_{pk}} \quad (12)$$

Ta statistika je porazdeljena po χ^2 porazdelitvi z $\nu = \rho - 1$ prostostnimi stopnjami. Eno prostostno stopnjo izgubimo, ker velja pogoj $\sum N_k = N$.

Primer 1.1 (Radioaktivni razpad). Pri merjenju radioaktivnega razpada smo zabeležili čas med dvema zaporednima sunkom. Dobili smo vzorec $N = 100$ meritev, pri čemer so vsi izmerjeni časi $t_k < 1.6$ s. Ali lahko na stopnji tveganja $\alpha = 5\%$ ovržemo hipotezo, da časi med sunki sledijo eksponencialni porazdelitvi s povprečnim časom $\tau = 1$ s?

Rešitev: Hipoteza je, da je porazdelitev dana z $dP/dt = \frac{1}{\tau}e^{-t/\tau}$ s fiksno vrednostjo $\tau = 1$ s.

1. **Razdelitev v razrede:** Interval $[0, 1.6]$ razdelimo na $\rho = 4$ enako široke razrede: $[0, 0.4)$, $[0.4, 0.8)$, $[0.8, 1.2)$, $[1.2, 1.6)$.

2. **Izračun pričakovanih frekvenc (N_{pk}):** Verjetnost za k -ti razred je

$$P_k = \int_{t_{k-1}}^{t_k} \frac{1}{\tau} e^{-t/\tau} dt = [-e^{-t/\tau}]_{t_{k-1}}^{t_k}.$$

$$\bullet P_1 = 1 - e^{-0.4/1} \approx 0.3297 \Rightarrow N_{p1} = 100 \cdot 0.3297 = 33.0$$

$$\bullet P_2 = e^{-0.4} - e^{-0.8} \approx 0.2212 \Rightarrow N_{p2} = 22.1$$

$$\bullet P_3 = e^{-0.8} - e^{-1.2} \approx 0.1481 \Rightarrow N_{p3} = 14.8$$

$$\bullet P_4 = e^{-1.2} - e^{-1.6} \approx 0.0996 \Rightarrow N_{p4} = 10.0$$

• **Opomba:** Vsota verjetnosti ni 1, ker smo upoštevali le meritve do 1.6 s. Za pravilen test bi morali vključiti še peti razred $[1.6, \infty)$, a ker vemo, da v njem ni bilo meritev, poenostavimo. Za natančnejšo analizo bi morali normirati verjetnosti.

3. **Izračun χ^2 :** Predpostavimo, da so bile izmerjene frekvence $N_1 = 35, N_2 = 20, N_3 = 25, N_4 = 20$. Vrednost χ^2 bi bila:

$$\chi^2 = \frac{(35 - 33.0)^2}{33.0} + \frac{(20 - 22.1)^2}{22.1} + \frac{(25 - 14.8)^2}{14.8} + \frac{(20 - 10.0)^2}{10.0} = 17.35$$

4. **Sklep:** Število prostostnih stopenj je $\nu = \rho - 1 = 4 - 1 = 3$. Kritična vrednost za $\chi^2(3)$ pri $\alpha = 0.05$ je $\chi_{kr}^2 = 7.81$. Ker je naša izračunana vrednost $17.35 > 7.81$, hipotezo, da je $\tau = 1$ s, na stopnji tveganja 5% **zavrnamo**. Podatki statistično značilno odstopajo od predlaganega modela.

Metoda največje verjetnosti (Maximum Likelihood) **Intuitivna ideja:** Kaj pa, če parametrov porazdelitve (npr. τ v prejšnjem primeru) ne poznamo vnaprej? Metoda največje verjetnosti je postopek, s katerim poiščemo tiste vrednosti parametrov, pri katerih je verjetnost, da bi izmerili ravno naš set podatkov, največja možna. Modelu "pustimo", da se optimalno prilagodi podatkom.

Postopek: Sestavimo **funkcijo zanesljivosti (likelihood)** L , ki je sorazmerna verjetnosti za opazovanje našega vzorca meritev $\{z_k\}$, če je porazdelitev $dP/dz(z, q_i)$ odvisna od parametrov q_i .

- **Brez razredov (unbinned):** Funkcija zanesljivosti je produkt vrednosti verjetnostne gostote na mestu vsake posamezne meritve:

$$L(q_i) = \prod_{k=1}^N \frac{dP}{dz}(z_k, q_i)$$

- **Z razredi (binned):** Funkcija zanesljivosti je verjetnost, da dobimo točno tak histogram, kot smo ga izmerili:

$$L^*(q_i) = \prod_{k=1}^{\rho} [P_k(q_i)]^{N_k}$$

Ker je lažje delati z vsotami kot s produkti, običajno maksimiziramo logaritem funkcije zanesljivosti ($\ln L$). Optimalne vrednosti parametrov $\hat{q}_i$ dobimo z reševanjem sistema enačb:

$$\frac{\partial(\ln L)}{\partial q_i} = 0$$

Ko imamo optimalne parametre, lahko izvedemo χ^2 test. Testna statistika je enaka kot pri Pearsonovem testu, le da sedaj uporabimo pričakovane frekvence $N_{p\hat{k}}$, izračunane z optimalnimi parametri. Število prostostnih stopenj pa se zmanjša, ker smo m parametrov določili iz podatkov:

$$\chi^2 = \sum_{k=1}^{\rho} \frac{(N_k - N_{p\hat{k}})^2}{N_{p\hat{k}}}, \quad \nu = \rho - 1 - m$$

Primer 1.2 (Radioaktivni razpad - iskanje optimalnega τ). *Imamo vzorec meritev časov med sunki $\{t_k\}$. Kakšna je najboljša ocena za razpadni čas τ na podlagi teh podatkov?*

Rešitev: Porazdelitev je $dP/dt = \frac{1}{\tau}e^{-t/\tau}$. Uporabimo metodo največje verjetnosti brez razredov.

1. Funkcija zanesljivosti:

$$L(\tau) = \prod_{k=1}^N \frac{1}{\tau} e^{-t_k/\tau}$$

2. Logaritem funkcije zanesljivosti:

$$\ln L(\tau) = \ln \left(\prod_{k=1}^N \frac{1}{\tau} e^{-t_k/\tau} \right) = \sum_{k=1}^N \left(\ln \left(\frac{1}{\tau} \right) - \frac{t_k}{\tau} \right) = -N \ln \tau - \frac{1}{\tau} \sum_{k=1}^N t_k$$

3. Iskanje maksimuma (odvod in enačenje z 0):

$$\frac{d(\ln L)}{d\tau} = -\frac{N}{\tau} - \left(-\frac{1}{\tau^2} \right) \sum_{k=1}^N t_k = 0$$

$$\frac{1}{\hat{\tau}^2} \sum_{k=1}^N t_k = \frac{N}{\hat{\tau}}$$

4. Rešitev za optimalni $\hat{\tau}$:

$$\hat{\tau} = \frac{1}{N} \sum_{k=1}^N t_k = \bar{t}$$

Interpretacija: Metoda največje verjetnosti nam da intuitiven in pričakovan rezultat. Najboljša ocena za povprečni življenjski čas τ je kar povprečje izmerjenih življenjskih časov.

Kolmogorov-Smirnov test **Intuitivna ideja:** Ta test se izogne razdelitvi podatkov v razrede, s čimer se izognemo izgubi informacije. Namesto primerjave histogramov (gostot verjetnosti) primerja **kumulativne porazdelitvene funkcije**. Teoretična kumulativna funkcija $F(z)$ pove, kolikšen delež meritev bi moral biti manjši od vrednosti z . Eksperimentalna kumulativna funkcija $f(z)$ pa pove, kolikšen delež meritev dejansko je manjši od z . Če se model dobro ujema s podatki, bosta ti dve funkciji povsod zelo blizu druga drugi. Test meri največjo vertikalno razdaljo med njima.

Postopek:

1. Imamo vzorec $\{z_i\}$. Privzamemo teoretično kumulativno porazdelitveno funkcijo $F(z)$:

$$F(z) = \int_{-\infty}^z \frac{dP}{dz'} dz'$$

2. Sestavimo eksperimentalno (empirično) kumulativno funkcijo. To je stopničasta funkcija, ki se pri vsaki izmerjeni vrednosti z_i poveča za $1/N$:

$$f(z) = \frac{k(z)}{N}, \quad \text{kjer je } k(z) \text{ število izmerkov, manjših ali enakih } z.$$

3. Izračunamo testno statistiko D , ki je definirana kot največja absolutna razlika med obema funkcijama po celotnem območju vrednosti z :

$$D = \sup_{z \in (-\infty, \infty)} |F(z) - f(z)| \quad (13)$$

4. Kolmogorov je pokazal, da je porazdelitev statistike $D\sqrt{N}$ za velike N neodvisna od same porazdelitve $F(z)$. Verjetnost, da je $D\sqrt{N}$ manjša od neke vrednosti d , je podana z:

$$P(D\sqrt{N} < d) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 d^2}$$

5. Izberemo stopnjo tveganja α in poiščemo kritično vrednost d_{kr} tako, da velja $P(D\sqrt{N} < d_{kr}) = 1 - \alpha$. Če je naša izračunana vrednost $D\sqrt{N} > d_{kr}$, potem s tveganjem α zavrnemo hipotezo, da porazdelitev $F(z)$ ustreza izmerkom.

1.6 Metoda najmanjših kvadratov v matrični obliki

Pogosto želimo podatke opisati z modelom, ki je linearna kombinacija znanih baznih funkcij, vendar z neznanimi koeficienti. Tak model lahko zapišemo kot:

$$z(t) = x_0 f_0(t) + x_1 f_1(t) + \cdots + x_m f_m(t) = \sum_{j=0}^m x_j f_j(t) \quad (14)$$

kjer so $f_j(t)$ znane funkcije (npr. polinomi, Gaussove funkcije, sinusi), x_j pa so neznani parametri, ki jih želimo določiti. Ključno je, da je model **linearen v parametrih** x_j .

1.6.1 Linearni model in Kalmanov formalizem

Za n meritev z_i ob časih (ali drugih neodvisnih spremenljivkah) t_i lahko problem zapišemo v elegantni matrični obliki:

$$\mathbf{z} = \mathbf{H}\mathbf{x} + \mathbf{r} \quad (15)$$

kjer je:

- $\mathbf{z}$ vektor meritev dimenzije $n \times 1$.
- $\mathbf{x}$ vektor neznanih parametrov dimenzije $(m + 1) \times 1$.
- $\mathbf{H}$ je t.i. **načrtovalna matrika** (design matrix) dimenzije $n \times (m + 1)$, ki vsebuje vrednosti baznih funkcij ob vsaki meritvi: $H_{ij} = f_j(t_i)$.
- $\mathbf{r}$ je vektor merilnega šuma dimenzije $n \times 1$.

Cilj metode najmanjših kvadratov je poiskati tak vektor parametrov $\hat{\mathbf{x}}$, ki minimizira vsoto kvadratov uteženih ostankov. Ta vsota je enaka χ^2 :

$$\chi^2(\mathbf{x}) = (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{R}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x}) \quad (16)$$

kjer je $\mathbf{R}$ kovariančna matrika meritev. Minimum najdemo z odvajanjem po $\mathbf{x}$ in enačenjem z nič: $\frac{\partial \chi^2}{\partial \mathbf{x}} = 0$.

Rešitev lahko izpeljemo s pomočjo Kalmanovega filtra. Za eno serijo meritev ("batch fit") predpostavimo, da nimamo predhodnega znanja o parametrih:

- Začetna ocena parametrov: $\mathbf{x}_{povp} = \mathbf{0}$.
- Začetna kovariančna matrika parametrov: $\mathbf{M} \rightarrow \infty$, kar pomeni $\mathbf{M}^{-1} = \mathbf{0}$.

Poleg tega predpostavimo najenostavnejši primer merilnega šuma: vse meritve so med seboj neodvisne in imajo enako, poznano varianco σ^2 . To pomeni, da je kovariančna matrika meritev diagonalna: $\mathbf{R} = \sigma^2 \mathbf{I}$, kjer je $\mathbf{I}$ identitetna matrika.

Kovariančna matrika ocenjenih parametrov $\mathbf{P}$ je podana z:

$$\mathbf{P}^{-1} = \mathbf{M}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}$$

Z našimi predpostavkami dobimo:

$$\mathbf{P}^{-1} = \mathbf{0} + \mathbf{H}^T (\sigma^2 \mathbf{I})^{-1} \mathbf{H} = \frac{1}{\sigma^2} \mathbf{H}^T \mathbf{H}$$

Inverz te matrike nam da iskano kovariančno matriko za parametre:

$$\mathbf{P} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1} \quad (17)$$

Optimalna ocena za parametre $\hat{\mathbf{x}}$ je podana z:

$$\hat{\mathbf{x}} = \mathbf{x}_{povp} + \mathbf{P} \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{z} - \mathbf{H} \mathbf{x}_{povp})$$

Po vstavitvi naših predpostavk:

$$\hat{\mathbf{x}} = \mathbf{0} + \mathbf{P} \mathbf{H}^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{z} - \mathbf{0}) = \frac{1}{\sigma^2} \mathbf{P} \mathbf{H}^T \mathbf{z}$$

Če sedaj vstavimo zgoraj izpeljan izraz za $\mathbf{P}$:

$$\hat{\mathbf{x}} = \frac{1}{\sigma^2} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{z}$$

Dobimo končno rešitev, znano kot **normalna enačba**:

$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{z} \quad (18)$$

Ta rešitev nam omogoča, da iz meritev $\mathbf{z}$ in poznavanja modela (matrika $\mathbf{H}$) neposredno izračunamo najboljšo oceno parametrov $\hat{\mathbf{x}}$ in njihovo kovariančno matriko $\mathbf{P}$. Minimalna vrednost χ^2 je porazdeljena po zakonu χ^2 z $n - (m + 1)$ prostostnimi stopnjami.

1.6.2 Primer: Luščenje vrhov v spektru

Predpostavimo, da merimo fotoemisijski spekter, kjer imamo dva bližnja vrhova na konstantnem ozadju. Model za število sunkov z_i pri energiji E_i je:

$$z_i = B \cdot 1 + A_1 \cdot f_1(E_i) + A_2 \cdot f_2(E_i) + r_i$$

kjer je B konstanta ozadja, A_1 in A_2 sta amplitudi vrhov, f_1 in f_2 pa sta znani obliki vrhov (npr. Gaussova, Lorentzova ali Voigtova funkcija, katerih položaj in širina sta fiksna). Želimo določiti B, A_1, A_2 .

- **Vektor parametrov:** $\mathbf{x} = \begin{pmatrix} B \\ A_1 \\ A_2 \end{pmatrix}$
- **Načrtovalna matrika $\mathbf{H}$:** Za n meritev pri energijah $E_1, \dots, E_n$:

$$\mathbf{H} = \begin{pmatrix} 1 & f_1(E_1) & f_2(E_1) \\ 1 & f_1(E_2) & f_2(E_2) \\ \vdots & \vdots & \vdots \\ 1 & f_1(E_n) & f_2(E_n) \end{pmatrix}$$

- **Rešitev:** Z izračunom $\mathbf{H}^T \mathbf{H}$, inverzom te matrike in množenjem z $\mathbf{H}^T \mathbf{z}$, dobimo ocene $\hat{\mathbf{x}} = (\hat{B}, \hat{A}_1, \hat{A}_2)^T$.
- **Kovariančna matrika:** Dobimo tudi $\mathbf{P} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}$, ki je dimenzije 3×3 :

$$\mathbf{P} = \begin{pmatrix} \sigma_B^2 & \text{Cov}(B, A_1) & \text{Cov}(B, A_2) \\ \text{Cov}(A_1, B) & \sigma_{A_1}^2 & \text{Cov}(A_1, A_2) \\ \text{Cov}(A_2, B) & \text{Cov}(A_2, A_1) & \sigma_{A_2}^2 \end{pmatrix}$$

Fizikalna interpretacija kovariančne matrike: Diagonalni elementi matrike $\mathbf{P}$ so variance (kvadrati statističnih napak) ocenjenih parametrov. Izvendiagonalni elementi, $\text{Cov}(A_1, A_2)$, pa nam povedo, kako sta oceni za amplitudi A_1 in A_2 med seboj povezani.

- **Dobro ločljiva vrhova:** Če se funkciji $f_1(E)$ in $f_2(E)$ ne prekrivata dosti, je njun produkt povsod blizu nič. Posledično bodo izvendiagonalni elementi v matriki $\mathbf{H}^T \mathbf{H}$ majhni. Tudi v inverzni matriki $\mathbf{P}$ bo element $\text{Cov}(A_1, A_2)$ majhen. **Intuitivno:** Ocena amplitude enega vrha je praktično neodvisna od ocene amplitude drugega. Algoritem zlahka loči, kateri foton pripada kateremu vrhu.

- **Zelo zlita vrhova:** Če se funkciji $f_1(E)$ in $f_2(E)$ močno prekrivata, bosta ustrezna stolpca v matriki $\mathbf{H}$ zelo podobna (skoraj linearno odvisna). To povzroči, da postanejo izvendiagonalni elementi v $\mathbf{H}^T \mathbf{H}$ veliki, matrika pa postane skoraj singularna. V kovariančni matriki $\mathbf{P}$ bo element $\text{Cov}(A_1, A_2)$ velik in po navadi negativen. **Intuitivno:** Algoritem ne more z gotovostjo določiti, ali signal v območju prekrivanja pripada prvemu ali drugemu vrhu. Če fit rahlo poveča amplitudo A_1 , mora za kompenzacijo zmanjšati amplitudo A_2 , da se vsota še vedno ujema s podatki. To se odraža v močni (anti)korelaciji med parametri in posledično velikih napakah σ_{A_1} in σ_{A_2} .